WebArena：判成败时不比对动作序列，改为检查执行后网站的状态

问题 常见网页代理评测要么只在缓存好的静态页面里走，要么拿预测动作逐字比对一条参考动作序列。作者指出复杂任务常有多条合法路径，按参考序列打分会忽略替代解，也不查任务是否真的完成（§1 的论证，论文未统计误判率）。

研究动作 把四类真实网站开源实现自托管成 Docker 镜像，可复位到同一初始状态；812 个自然语言任务各配一个检查器，执行结束后读回答、页面或后台数据判定是否完成，不限定走哪条路径。

剖面 A–A：一个任务从下往上穿过三层 剖切面用斜线标出；图标为示意

A

终态判定层 L3

执行后读真实状态 §3.2 · Table 1 · A.7–A.8

r info：信息查询类，比对回答

- `exact_match` 与标注答案完全一致
- `must_include` 回答包含关键字串
- `fuzzy_match` gpt-4-0613 判语义等价（如 "2h58min" 与 "2:58"）

r prog：导航 / 内容配置类，读状态

定位器取出关键内容：数据库查询、网站 API 或页面 JavaScript 选择器；再用 exact_match / must_include 检查关键词。

按目标状态判定，不检查走了哪条路径。

```
# Table 1 #5  意图：发帖问 "whether I need a car in NYC"
url  = locate_latest_post_url(s)     # 从执行状态里找最新帖子
body = locate_latest_post_body(s)    # JS 读帖子正文
must_include(url,  "/f/nyc")  and  must_include(body, "a car in NYC")
```

作者自查只覆盖 fuzzy_match：人工核对 40 例中 39 例与人判一致；程序生成的日期、时长格式变体各 900 例，GPT-4 判断准确率 100%（A.8）。

▲ 执行结束：最终回答 â 与状态序列 s（数据库 / 页面）交给检查器

任务-意图层 L2

高层意图 + 固定初始状态 §2.1 · §2.3–2.4 · §3.1 · A.3

812 条意图 ← 241 个模板（平均每模板 3.3 例）

模板变量换实例，例："create a {{site1}} account identical to my {{site2}} one"。同一模板的实例执行轨迹可以完全不同。

三类：**信息查询**（要文字回答）· **站内导航** · **内容与配置操作**；另有**不可完成任务**，期望回答 "N/A"。

初始状态里已经有“这个用户”

每站预置用户画像并用缓存 cookie 自动登录：购物账户两年 35+ 订单；GitLab 维护者；活跃的 Reddit 用户；CMS 店主全权限。

观测：URL、多标签页、页面内容（HTML / 截图 / 无障碍树）。动作：元素操作、标签页、URL 导航、stop[答案]。

▼ 代理按意图逐步发动作（≤30 步）　　▲ 网站返回新观测；状态转移确定

可复位环境层 L1

自托管、可复位的功能网站 §2.2 · A.1–A.2

购物
OneStopShop（Magento），约 9 万件商品、300+ 类目

论坛
Postmill 版 Reddit，95 个版块、127,390 帖

GitLab
300 个仓库、1000+ 有提交的账户

CMS
Magento 店铺后台，官方示例数据

工具与知识库
OpenStreetMap 地图（美国东北部）、计算器、草稿板；离线英文维基（Kiwix，2023-05）、GitLab 与 Adobe Commerce 手册

复位 = 从原镜像重启容器
一站一个自包含 Docker 镜像（代码 + 数据库 + 数据）。任务改了数据（建用户、删帖）后，删掉容器、从原镜像重启即回到初态，每站耗时几秒到一分钟；只读任务无需复位。不依赖线上网站，避开验证码与内容漂移。

A

对比块：同一任务，两种打分

动作序列匹配误判合法解 示意

意图：在 nyc 版块发帖，问 "whether I need a car in NYC"

参考动作序列（标注者走的路）

`点 Forums` → `点 nyc` → `Submit` → `填标题正文` → `Post`

代理的路线（同样合法）

`搜索 "nyc"` → `进版块` → `Submit` → `填写` → `Post`

0 ✗
序列匹配：前两步与参考不同，判失败

1 ✓
状态检查：URL 含 /f/nyc、正文含关键句，判完成

路线为我们按 Table 1 #5 编的示意。论文只在 §1 论证此类误判，没有统计参考序列匹配在 WebArena 上会错判多少。

检查器自己也会错 示意

状态检查不等于零误判。Table 1 #4 用 exact_match 比对 URL：多带一个参数或参数顺序不同、但显示同一页面的 URL 会被判错（假阴性）。must_include 只看关键串：回答里列出多个候选、其中含正确答案，也会被判对（假阳性）。

两例是我们对检查器写法的推演，论文未报告这两类函数及 r_{prog} 的误判率。

812
任务实例 / 241 模板

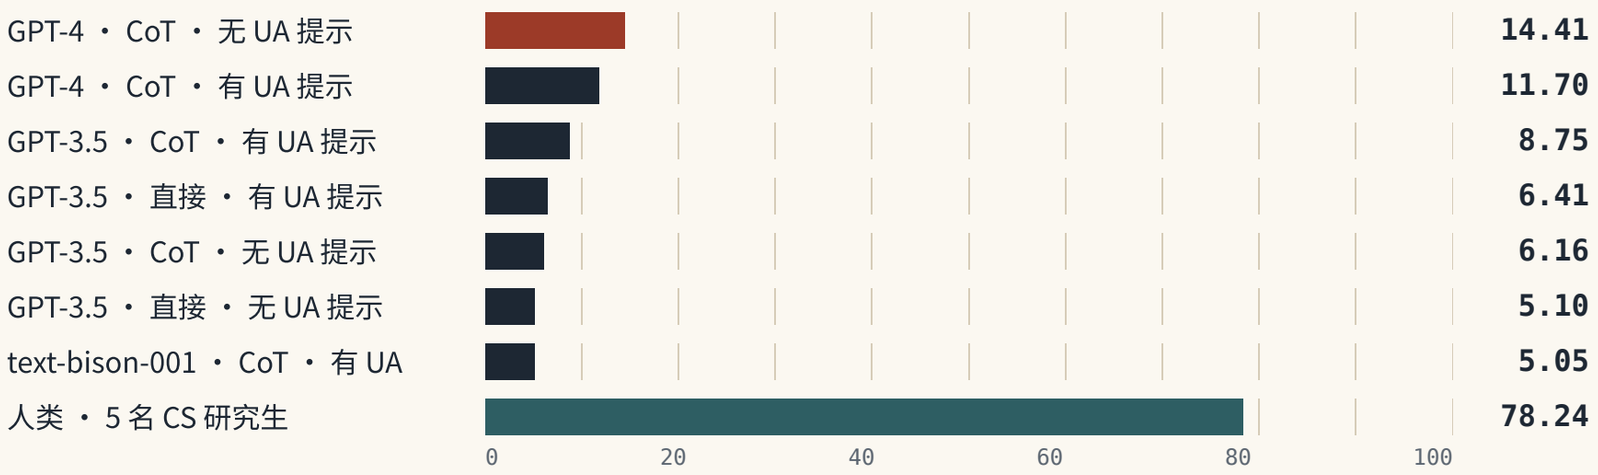
4
类功能网站 + 地图、维基、手册

170
人类基线抽样任务（每模板 1 个）

≤30
代理每任务最多状态转移

端到端成功率 SR %

Table 2 · 812 任务 · 无障碍树 + 元素 ID · 2 例上下文 · T=1.0、top-p 0.9 · 单次运行



人类分母不同：170 个抽样任务（每模板 1 个），代理是全部 812 个。人类失败约一半来自误读意图、回答不全或执行不完整（§3.2）。

同模型对照：UA 提示

UA 提示 = 指令里写“认为不可完成就答 N/A”。GPT-4 带此提示时，把 54.9% 的可完成任务判为不可能（§5.1）。

GPT-4 · CoT	SR	SR_{AC}	SR_{UA}
有 UA 提示	11.70	8.63	77.78
无 UA 提示	14.41	13.02	44.44

SR_{AC}：可完成任务；SR_{UA}：不可完成任务。去掉提示后可完成任务成功率上升，识别不可完成任务的能力下降。指令措辞本身就能明显改变结果。

限制与证据边界

核心动机未量化
“参考序列匹配会错判合法替代解”是 §1 的论证，引用的可靠性证据来自 SQL / 代码领域；论文没有在 WebArena 上对比两种打分。

检查器只审计了一类
A.8 只核 fuzzy_match（40 例 + 合成日期 / 时长）；exact_match、must_include 与 r_{prog} 的假阳性、假阴性未报告。

基线是单次高温运行
T=1.0 单次结果，无种子方差；人类与代理分母不同（170 vs 812），对比只能看量级。

是克隆站，不是线上站
开源实现 + 抽样数据，地图只覆盖美国东北部；可复现性以牺牲线上漂移、验证码等真实条件为代价。