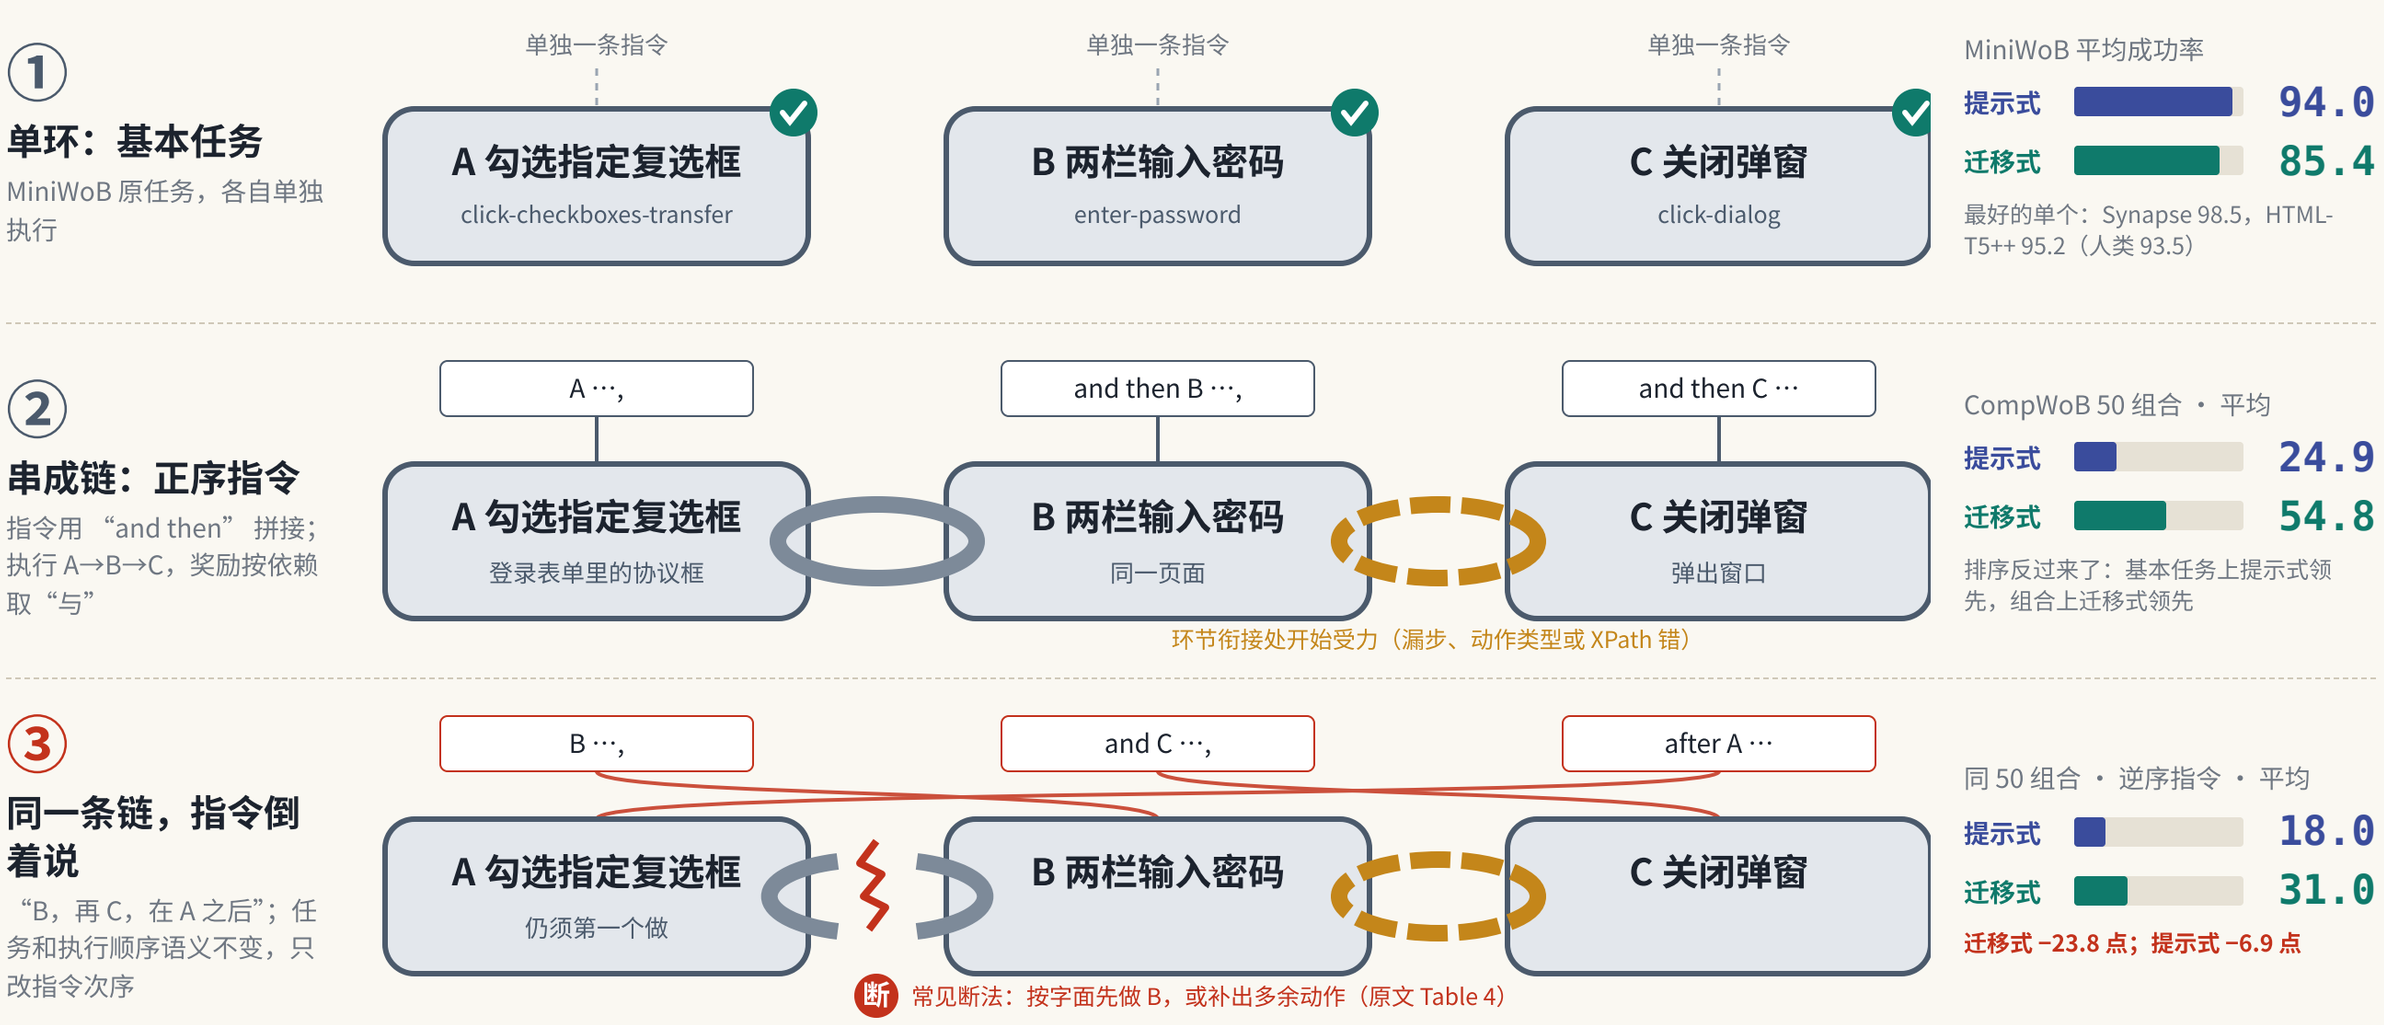
arXiv 2311.18751v3 · Furuta, Matsuo, Faust, Gur · Google DeepMind / 东京大学

每一环都会做，串成链就断；指令倒着说，断得更厉害

网页代理在 MiniWoB 基本任务上平均成功率 **94.0%**（提示式）/ **85.4%**（迁移式）。作者把 2–8 个基本任务拼成 **50 个留出组合（CompWoB）**，零样本测，每个组合跑 100 回合：成功率降到 **24.9% / 54.8%**。同一批组合只把指令改成倒述、执行顺序不变，迁移式再从 **54.8% 降到 31.0%**。

组合断裂链 示意

提示式：RCI / AdaPlanner / Synapse（gpt-3.5-turbo）三者平均　迁移式：WebGUM / HTML-T5 / HTML-T5++（3B，只在基本任务上微调）三者平均



示意 三个任务块取自原文 Figure 1 / §5 的组合例（click-checkboxes-transfer + enter-password + click-dialog），连环、断点位置和图标为自绘；右侧数字是 50 个组合的平均，**不是这一条组合的成绩**，平均值也不说明链具体断在哪一环。

同一组合，只改指令顺序

Fig.3 · Table 5 · 附录 Table 14/15

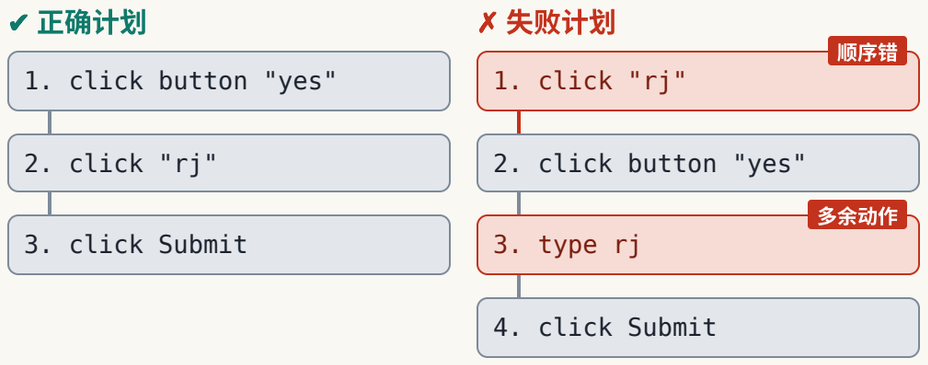
代理（50 组合 × 100 回合，零样本）	正序	逆序	0 —— 70%	变化
迁移式三者平均	**54.8**	**31.0**	●——○	**−23.8**
HTML-T5++（本文重配平数据）	61.5	34.3	●——○	−27.2
HTML-T5	56.6	29.7	●——○	−26.9
WebGUM	46.3	29.1	●——○	−17.2
提示式三者平均（gpt-3.5-turbo）	**24.9**	**18.0**	●—○	**−6.9**
RCI（组合示例 comb）	28.7	19.2	●—○	−9.5
RCI 换 gpt-4	56.0	43.5	●——○	−12.5

● 正序　○ 逆序。逆序与正序是同一组 50 个组合、同一批代理、同一奖励，只改指令措辞次序（§5.1–5.2），是本文条件最齐的一组对照。变化为百分点；本文未报告回合间方差或置信区间。gpt-4 行不计入提示式平均。

原文失败例

Table 4 · RCI · 逆序

> **Select rJ and click Submit, after clicking on the "yes" button**



动作按原文 XPath 简写。这只是作者挑出的单个例子，不代表失败类型的频率；作者的解释是：基本任务示例都是“从左到右”的指令，把代理绑在线性读法上（§6.2，作者推测）。

作者结果 还测到了什么

- 换更强模型有帮助但不够：RCI 用 gpt-4，组合 **28.7→56.0**，逆序 **19.2→43.5**（§6.3）。
- 给组合示范可以部分修复：20 个二元组合上 RCI+gpt-4+oracle 示例 **82.9%**，逆序仍降到 **71.8%**（附录 I）。
- 组合成功率与基本任务成功率乘积正相关 **R=0.691**，与指令 token 数 **R=−0.579**、HTML 子树最大深度 **R=−0.433** 负相关（§6.4）。

阅读判断 我们怎么看

- 逆序对照把“链变长”这个因素固定住了，所以 54.8→31.0 可以算在指令次序头上。
- 基本→组合那一段（94.0→24.9、85.4→54.8）同时混着链更长、指令更长、页面更深，§6.4 只给相关性，**链长与组合推理没有被拆开**。
- “迁移式更会组合”是这两组具体配置的比较：模型规模、示例检索（作者假定最优检索器）、反思次数都不同，不宜推成“微调胜过提示”。

限制与适用范围

- 只在 MiniWoB 风格的简化页面上测；50 个组合人工挑选，基本任务主要来自 easy 组。
- 没有在真实网站上验证；结论是“单任务高分不能外推到组合”，不是给出了修复办法。
- 没有运行论文代码，也没有复现；数字全部取自原文 v3。

单步 ≠ 组合 · 顺序敏感

基本任务成功率高，推不出组合能完成；同一组合只改指令说法的先后，成功率也会大跌。评测 GUI 代理时，组合留出和指令改写都应当单独测。