arXiv 2312.08914v3 · Hong, Wang, Lv, Xu, Yu … Dong, Ding, Tang(清华 / 智谱 AI)

CogAgent 的提升算谁的?
把架构和数据放上同一杆天平

原文 同为 Caption+OCR 预训练时,高分辨率交叉分支在 Mind2Web 上只比原结构 490 多 **0.7** 分,但只用 **0.43×** TFLOPs;再加入 GUI 与定位预训练数据,又多 **12.8** 分。阅读 论文改变的判断是"高分辨率不必等比例抬高大模型计算";GUI 动作预测的提升主要来自数据。

问题 GUI 上的小图标和小字在 224×224 下看不清。直接输入 1120×1120 图像,按 14 像素切块就是 **6400** 个视觉 token;这些 token 进入解码器后,自注意力的代价随 token 数平方增长(§1、§2.1)。

做法 解码器里的图像序列不加长。低分辨率主干照旧输入 224 图像(EVA2-CLIP-E,**256** 个 token);另加 **0.30B** 的高分辨率编码器(EVA2-CLIP-L,1120 输入),在解码器每层通过小隐维的交叉注意力接入(32 头 × 32 维)。见 §2.2、表 8。

天平读数 · Mind2Web 单步动作预测

表 5、表 6 · 消融设置 · step SR

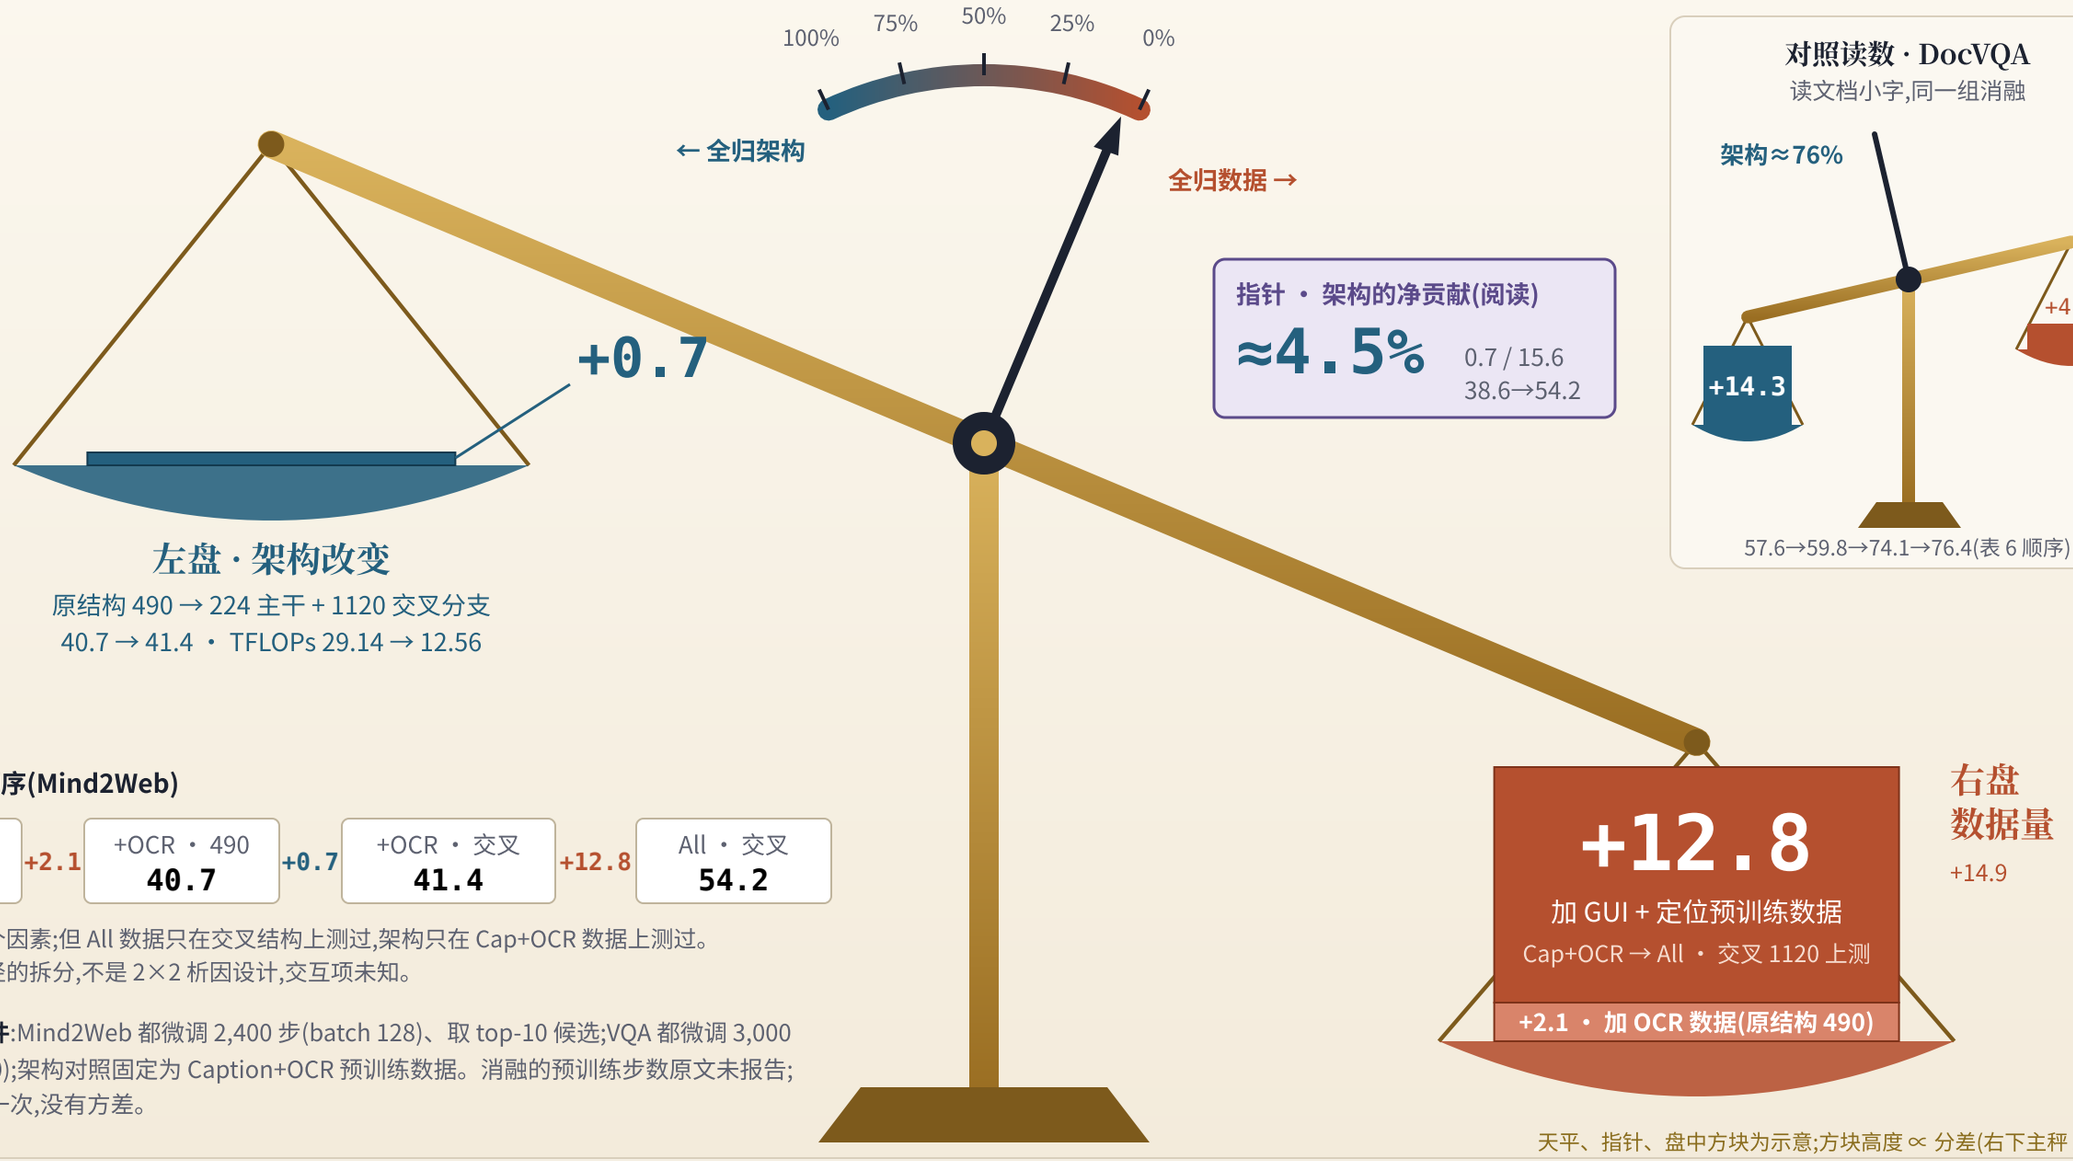


表 6 的加入顺序(Mind2Web)

Cap · 490	+2.1	+OCR · 490	+0.7	+OCR · 交叉	+12.8	All · 交叉
38.6		**40.7**		**41.4**		**54.2**

每一步只换一个因素;但 All 数据只在交叉结构上测过,架构只在 Cap+OCR 数据上测过。这是沿一条路径的拆分,不是 2×2 析因设计,交互项未知。

两盘的共同条件:Mind2Web 都微调 2,400 步(batch 128)、取 top-10 候选;VQA 都微调 3,000 步(batch 1,280);架构对照固定为 Caption+OCR 预训练数据。消融的预训练步数原文未报告;每个设置只跑一次,没有方差。

天平、指针、盘中方块为示意;方块高度 ∝ 分差(右下主秤 10px/分)

左盘 · 架构改变

原文 表 5 同为 Cap+OCR 预训练、同一套微调:原结构直接输入 490 得 **40.7**,换成 224 主干 + 1120 交叉分支得 **41.4**。前向计算从 **29.14** 降到 **12.56** TFLOPs,每步训练时间从 **6.43** 降到 **5.17** 秒。

指针 · 净贡献

阅读 Mind2Web 从 38.6 到 54.2 共 +15.6,架构这一步只占 0.7,约 4.5%。读文档小字的 DocVQA 正相反:同一组消融里,架构一步就是 +14.3,约占 76%。高分辨率主要帮"认字",不是"选动作"。

右盘 · 数据量

原文 表 6 结构同为 224 + 1120 交叉分支,预训练数据从 Cap+OCR 扩到 All(加入 GUI 与定位数据),Mind2Web 从 **41.4** 升到 **54.2**。作者原话:web 和 grounding 数据对 Mind2Web 影响显著(§4.2)。

算力条件 · FLOPs 对照

表 5 · 图 3 · 训练时间测于 A800,batch 8

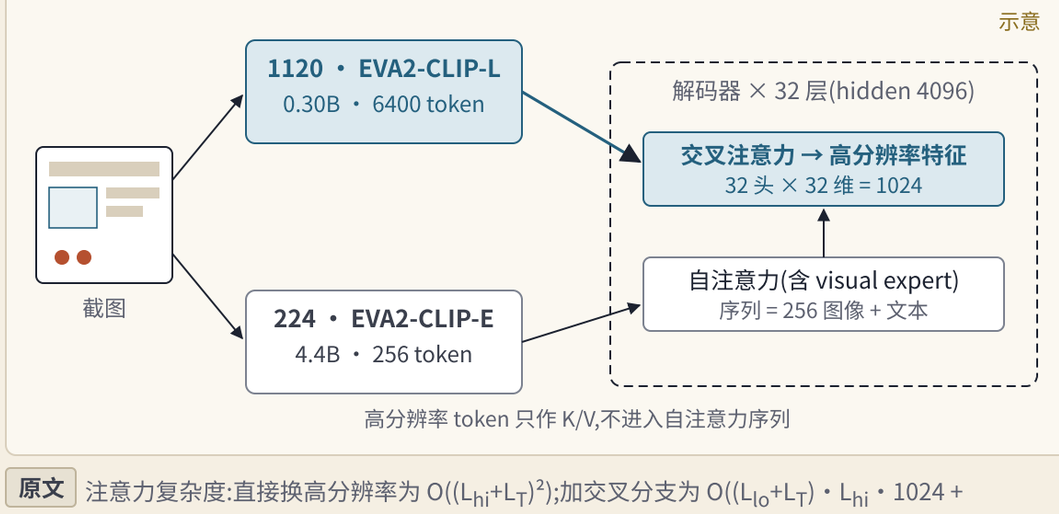
配置(均为 Cap+OCR 预训练)	TFLOPs	s/iter	Mind2Web	DocVQA
原结构 · 224	7.77	2.36	34.6	28.6
原结构 · 490	29.14	6.43	40.7	57.6*
224 + 交叉 756	10.08	3.57	40.7	62.3
224 + 交叉 1120	12.56	5.17	**41.4**	**74.1**

阅读 四组没有完全等算力的一对。交叉 756 用 **0.35×** TFLOPs 追平原结构 490 的 40.7;交叉 1120 用 **0.43×** 多出 0.7。原文 按图 3 的前向 FLOPs 曲线,原结构直接输入 1120 时,FLOPs 是交叉分支的 10 倍以上(作者描述,无数值表)。

*同一配置在表 6 写作 59.8;57.6 与表 6 的 Cap 行相同。Mind2Web 的 40.7 在两表中一致。

机制 · 解码器每层多一次交叉注意力

§2.2 式 (1)–(4)



原文 注意力复杂度:直接换高分辨率为 $O((L_{hi}+L_T)^2)$;加交叉分支为 $O((L_{lo}+L_T)\cdot L_{hi}\cdot 1024 + (L_{lo}+L_T)^2\cdot 4096)$。这只算注意力项,整模型计算见左表。

原文 作者主结果 完整训练后,只看截图的 CogAgent 在 Mind2Web 整体 step SR 为 **58.2**,高于读取 HTML 的 LLaMA2-70B(**54.4**,表 3);AITW 为 **76.88**,Auto-UI 为 **74.27**(表 4)。两者都是离线逐步匹配。消融里的 54.2 微调步数更少、只用 top-10 候选,不能和 58.2 直接比较。

限制与证据边界

§4、§5 · 我们的阅读

1. **不是 2×2。** All 数据只在交叉结构上测过,架构只在 Cap+OCR 数据上测过。高分辨率结构加上 GUI 数据后会不会多出交互收益,这组实验回答不了。
2. **+0.7 可能在噪声内。** 每个设置只跑一次,没有方差;消融的预训练步数没有报告,原文只给了微调步数。"架构对 GUI 动作几乎无贡献"不能当作定论。
3. **离线指标。** Mind2Web step SR 和 AITW 匹配分数都按单步标注打分,不是在线完成任务。作者在 §5 自述:输出坐标不精确,也不能处理多张图像。
4. **原文前后口径不一。** 表 5 与表 6 中原结构 490 的 VQA 数字不同(见左表 *)。正文说交叉 756 只需原结构 490 的"1/2 计算",按表中 TFLOPs 是 0.35,按训练时间是 0.56。

来源:Hong et al., *CogAgent: A Visual Language Model for GUI Agents*, arXiv 2312.08914v3(2024-12-27 修订版), §1–§5、表 3–8、图 3、附录 §3。初筛:run gui-pc11-20261022-01,L1 batches/p003.jsonl,L2 batches/l60.jsonl,selection2 第 7 行。 原文 = 作者报告 · 阅读 = 我们的判断(含 4.5% / 76% 的路径拆分) · 示意 = 自绘天平、方块与机制图,不是论文原图。我们没有运行论文代码,也没有复现实验。