没有检查脚本时，模型裁判先校准，再上岗

Autonomous Evaluation and Refinement of Digital Agents — 通用 VLM 评估器分别对照**执行检查**与**人工判定**，再接到下游改进看**真实**成功率

问题
GUI 任务多数没有手写检查函数，也没有新的专家示范。能否让通用模型判断一条轨迹**是否真的完成**，并把这个判定用作改进信号？

研究动作
输入 **指令 + 动作序列 + 末帧截图**（iOS 用整条轨迹逐步打分），输出成功/失败。两种实现：端到端 GPT-4V；或微调 QwenVL 写截图描述 → Mixtral / GPT-4 推理。

1 校准链：三个判定源，两条实测读数，一条缺口

两条读数来自不同基准与不同轨迹，不能相互传递或相乘。

读图
- TP 判成功 · 真成功
- FN 判失败 · 真成功
- TN 判失败 · 真失败
- FP 判成功 · 真失败

*精确率 = TP/(TP+FP)，**蓝字**为我们据原文 Fig.4 计数计算。

评估器 ↔ 人工 · Android AitW 120 任务 × 4 策略 = 480 条轨迹 — 原文 Tab.1 / Fig.4

	混淆分布（TP / FN / TN / FP）	一致率	精确率*
Cap.+Mixtral		92.9%	86.8%
GPT-4V		90.6%	79.2%
Cap.+GPT-4		89.8%	81.7%

全判“失败”也有 79.0% 计算，三个评估器都高于它。4 个策略的排名与人工 Kendall **100%**，AitW 默认的动作匹配分只有 **66.7%**。iOS 逐步判定抽 50 步，人工同意 **43** 步。

先看基率
真成功只占 WebArena 轨迹的 **11.7%**、Android 的 **21.0%**。一致率要和“全判失败”比较；若要把判定当 reward，判“成功”的精确率更关键。



执行 ↔ 人工：本文未直接测量 — 原文 § 4.1

WebArena 只有执行检查，Android 只有人工判定，没有同一批轨迹两边都判过，所以链条中段无法读数。 相邻证据只有 AitW 的**参考示范**：人工复核发现约 **36%** 的人类示范其实失败了；按动作匹配分，AutoUI-large 排在 base 前面，按人工判定的任务成功则相反。

评估器 ↔ 执行检查 · WebArena — 原文 Tab.1 / Fig.4

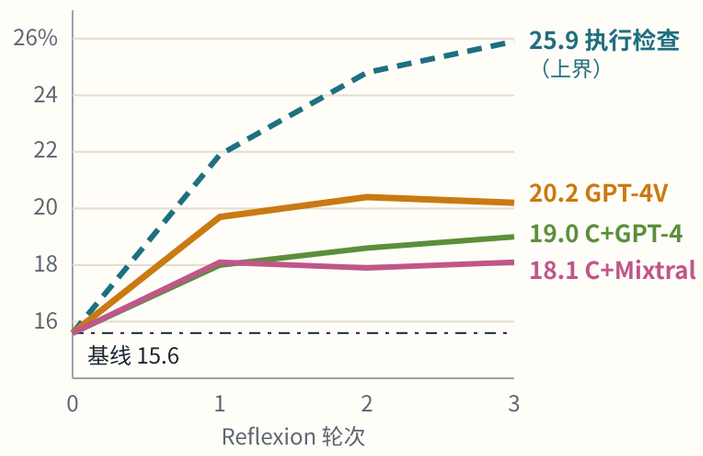
		一致率	精确率
Cap.+GPT-4		82.1%	35.3%
GPT-4V		80.6%	35.4%
Cap.+Mixtral		74.4%	28.1%

真成功只有 94/805。全判“失败”就有 88.3% 计算，整体一致率反而低于它；判为“成功”的轨迹约 2/3 实际失败。

2 下游闭环：接上改进，再由独立判定看真实成功率

推理时 · Reflexion（WebArena） — 原文 Fig.3 数值重绘

同一 GPT-4 代理，评估器判“失败”就反思重试，最多 3 轮；成功率始终由执行检查判定。



3 轮后相对基线提升 **+29%**（GPT-4V）到 **+16%**（C+Mixtral）。用执行检查本身当裁判可到 25.9，评估器只拿到这段提升中的 **24–45%** 计算。

训练时 · 过滤行为克隆 — 原文 Tab.2

Captioner+Mixtral 对自采轨迹逐步打分，只保留“有进展”的状态-动作对微调。对照组“自训练”使用同一批数据但不做过滤。

Android · AutoUI-base · 96 个测试任务（成功任务数，3 次训练均值）

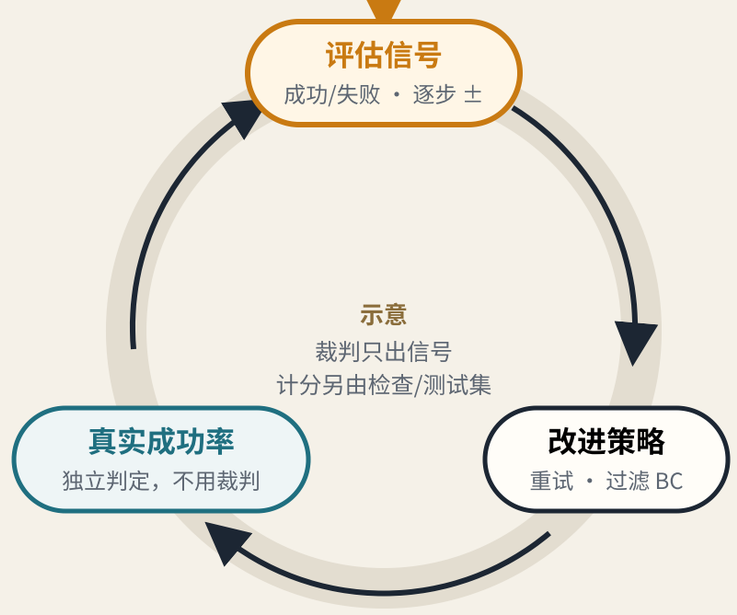
基础策略	15
自训练	18.9±1.0
过滤 BC	26.0±0.8

折合 15.6% → 27.1%，相对 **+73%**

iOS · CogAgent · 52 个测试任务（单次运行）

基础策略	8
自训练	11
过滤 BC	14

折合 15.4% → 26.9%，相对 **+75%**



假阴性比假阳性更伤（原文 § 4.2，初步观察）
FN：成功被判失败 → 被迫重试 → 几乎总会转为失败
FP：只是错过一次重试机会，封顶但不倒退
作者未给出 FN 伤害的定量数字

明确限制
- 评估器只看末帧（iOS 除外）。每个评估器抽 50 例 WebArena 判定做归因：截图理解或描述丢信息 5–10%，推理错误 50–70%，任务歧义 10–30%；判对的样本中约 10% 理由是错的。
- Reflexion 只跑 3 轮，iOS 只运行一次。没有长程优化，也没测策略会不会钻裁判的空子。下游测试集的成功由谁判定，正文未写明。

我们的读数
有误差的裁判已能支撑**有限、可独立验证**的改进：推理时重试与训练时过滤都超过同条件对照。但 WebArena 上判“成功”的精确率只有 28–35%，**还不足以说明它能直接充当无限优化的 reward**。