同一个骨干爬三级：静态模仿 → 在线过滤克隆 → 在线 RL

DigiRL — 在 Android 模拟器 + 实时网站上，用自主评估器给成败奖励训练设备控制代理。同一测试集、同一判分下，General **14.6→61.5→71.9**，Web Shopping **17.7→57.8→67.2**（%，Table 1 测试列）

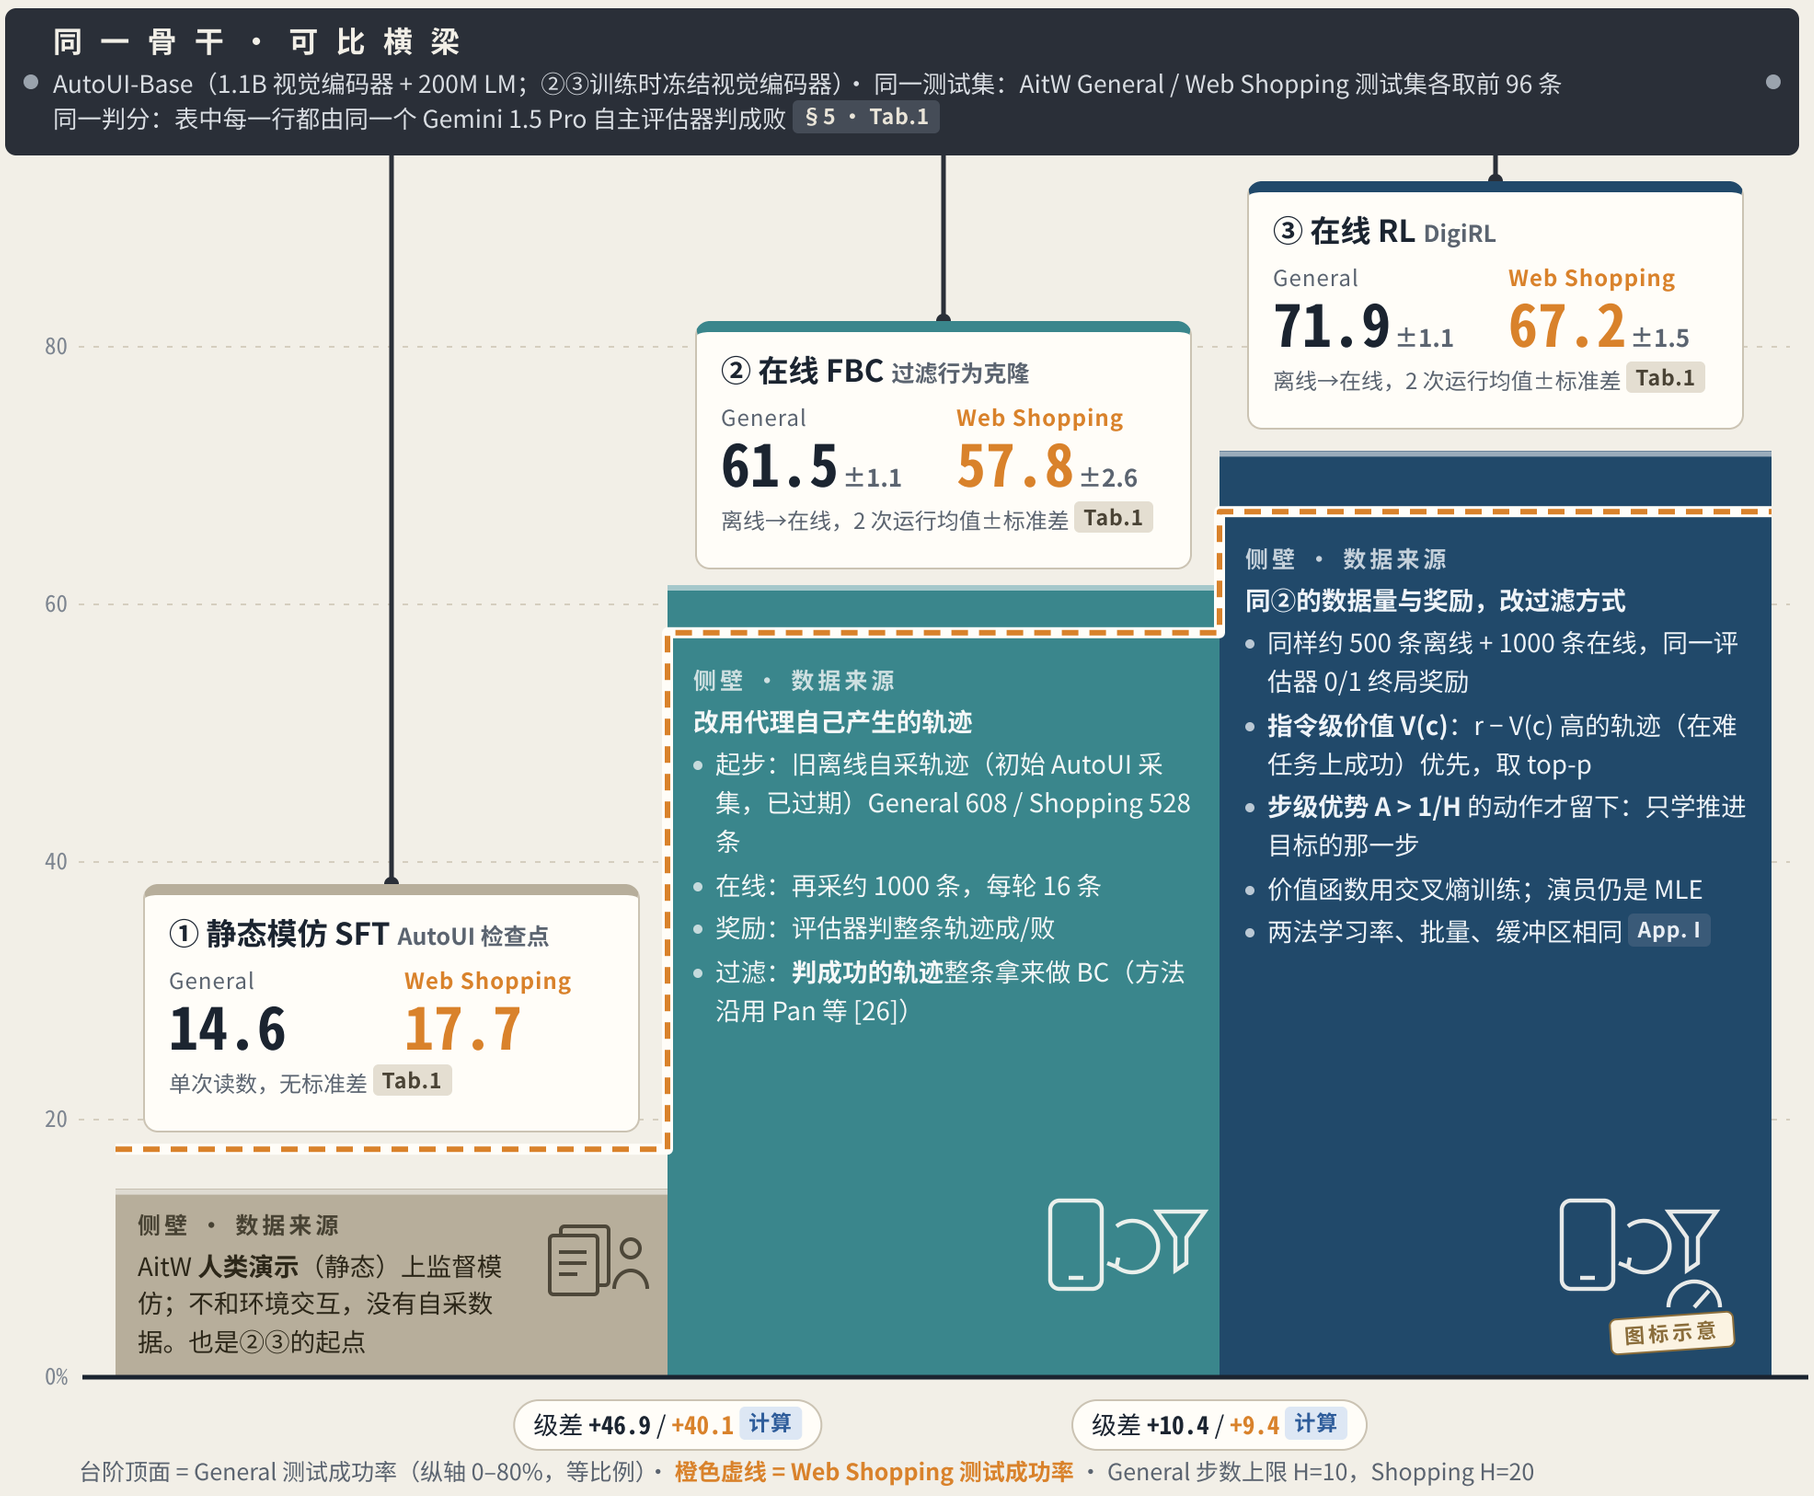
问题

用静态人类演示训练的 GUI 代理，碰到网站改版、弹窗、加载故障，一旦走偏就回不来。能不能让**同一个模型**直接用自己在设备上的交互经验、靠自动判出的成败信号继续训练?

研究动作

先离线 RL 初始化，再**离线→在线 RL**。最多 64 个 Android 模拟器并行采样；Gemini 1.5 Pro 评估器只看任务和截图，给 0/1 终局奖励；演员用 AWR 硬过滤，配**指令级课程**和**步级双稳健优势**。

1 训练范式阶梯：每上一级，换的是什么数据



台阶顶面 = General 测试成功率（纵轴 0–80%，等比例）· **橙色虚线 = Web Shopping 测试成功率** · General 步数上限 H=10，Shopping H=20

梯外读数

不上梯：口径或骨干不同。同为 Tab.1 测试列，G / S

纯离线（同骨干、无新交互）

约 1500 条旧自采轨迹（G 1552 / S 1296），与②③总量大致相同；3 次运行

	G	S
FBC 离线	50.7	45.8
DigiRL 离线	62.8	45.8

> General 上，**离线** DigiRL（62.8）已高于**在线** FBC（61.5）；Shopping 上离线两法持平。所以②→③的增量里，算法改变和在线数据两种因素叠在一起，不能全部算给“在线”。

不同骨干

	G	S
CogAgent 18B，AitW 监督	25.0	38.5

提示式专有 VLM（不训练）

	G	S
GPT-4V + SoM	13.5	8.3
Gemini 1.5 Pro + SoM	16.7	11.5
AppAgent · GPT-4V	17.7	8.3
AppAgent · Gemini	16.7	8.3

正文数字与表不一致

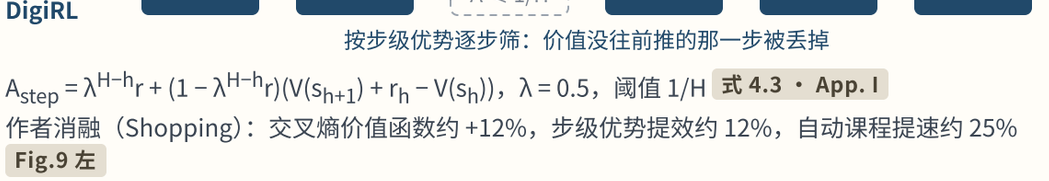
§5.1 写“17.7→71.9（General）”“57.8→61.4”“75% vs 62.8%”，§6 写“17.7→68.2”。Table 1 中 General 的 AutoUI 是 14.6，Shopping 的 DigiRL 是 67.2，68.2 是 Shopping **训练集**读数。本图只用 Table 1 测试列。

2 第三级比第二级多做了什么，为什么要在线

同一条成功轨迹，两种过滤留下的样本

示意

任务：去 bestbuy.com 搜索某商品。中途点错一次，再退回。

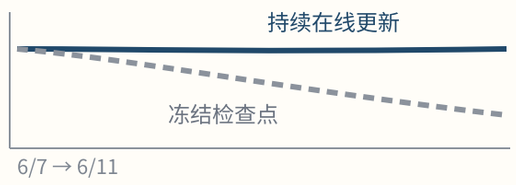


$A_{step} = \lambda^{H-h} r + (1 - \lambda^{H-h} r)(V(s_{h+1}) + r_h - V(s_h))$，$\lambda = 0.5$，阈值 1/H 式 4.3 · App. I

作者消融（Shopping）：交叉熵价值函数约 +12%，步级优势提效约 12%，自动课程提速约 25% Fig.9 左

为什么要在线：环境会变，静态模型不会纠错

网站在变 §3 · Fig.4



Shopping 上用 6/1–6/3 数据训出的检查点，6/7–6/11 冻结使用时逐渐退化；持续用新数据更新的那条保持住了。曲线为示意，原图未读数

减少最多的失败 §5.2 · Fig.7

作者组织人工标注失败类型，分三类：

犯错后无法恢复

↑ 作者称 RL 训练减少得最一致、最明显

中途卡住 · 到了错误页面就停

例：AutoUI 误触语音输入后一直退不出来，直到用完步数。DigiRL 在 bestbuy.com 上能退回重来（App. C.2）。

明确限制

- **环境**：Android 模拟器（非实体手机）连实时网站。任务只取 AitW General（信息查询、基础应用，H=10）和后处理过的 Web Shopping（5 个网站 × 去/搜/选第一项，H=20），都是短任务；测试只用前 96 条。
- **判分与奖励同源**：表中所有成功率都由训练时给奖励的同一个 Gemini 评估器判定。与人工判定差 <3%（平均误差 2.8%），但 Fig.8 每种配置只报成功率最高的那次运行；没有假阳性/假阴性分向分析，也没检验策略是否在钻评估器的空子。
- **评估器只看任务 + 当前截图**（App. G），不读模拟器内部状态，隐藏状态或中间要求无法核验。
- **重复少**：离线 3 次、在线 2 次；两次在线运行在不同日期启动。
- **①→② 预算不配平**：静态 SFT 没有任何自采数据，②③多了约 1500 条自采轨迹和评估器；最大一级跃升混合了“更多数据”和“在线”。

我们的读数

梯子上最高的一级跃升（General **+46.9**）发生在**从人类演示换成“自产在线轨迹 + 自动评估器”**这一步，FBC 已经吃到大部分收益。DigiRL 的相对过滤又在**同骨干、同数据量、同评估器**下多出约 10 个点，这是本文对算法最干净的一组对照。

不过离线 DigiRL 在 General 上已经超过在线 FBC，所以第三级不能全算给“在线”。读数都来自同一个评估器，只覆盖短任务。

这是我们的阅读判断，不是作者结论，也没有复现