arXiv 2409.07429v1 · 2024-09-11

只向过去学：工作流记忆的信息边界

Agent Workflow Memory（AWM）· Zora Zhiruo Wang, Jiayuan Mao, Daniel Fried, Graham Neubig（CMU / MIT）

问题

网页代理逐题从零摸索，做过的题不会沉淀下来；把整条示例塞进上下文，又容易照抄具体元素。能否从**已完成的**任务里归纳出可复用的子流程，让后面的题做得更好，而且**不碰未来查询**？

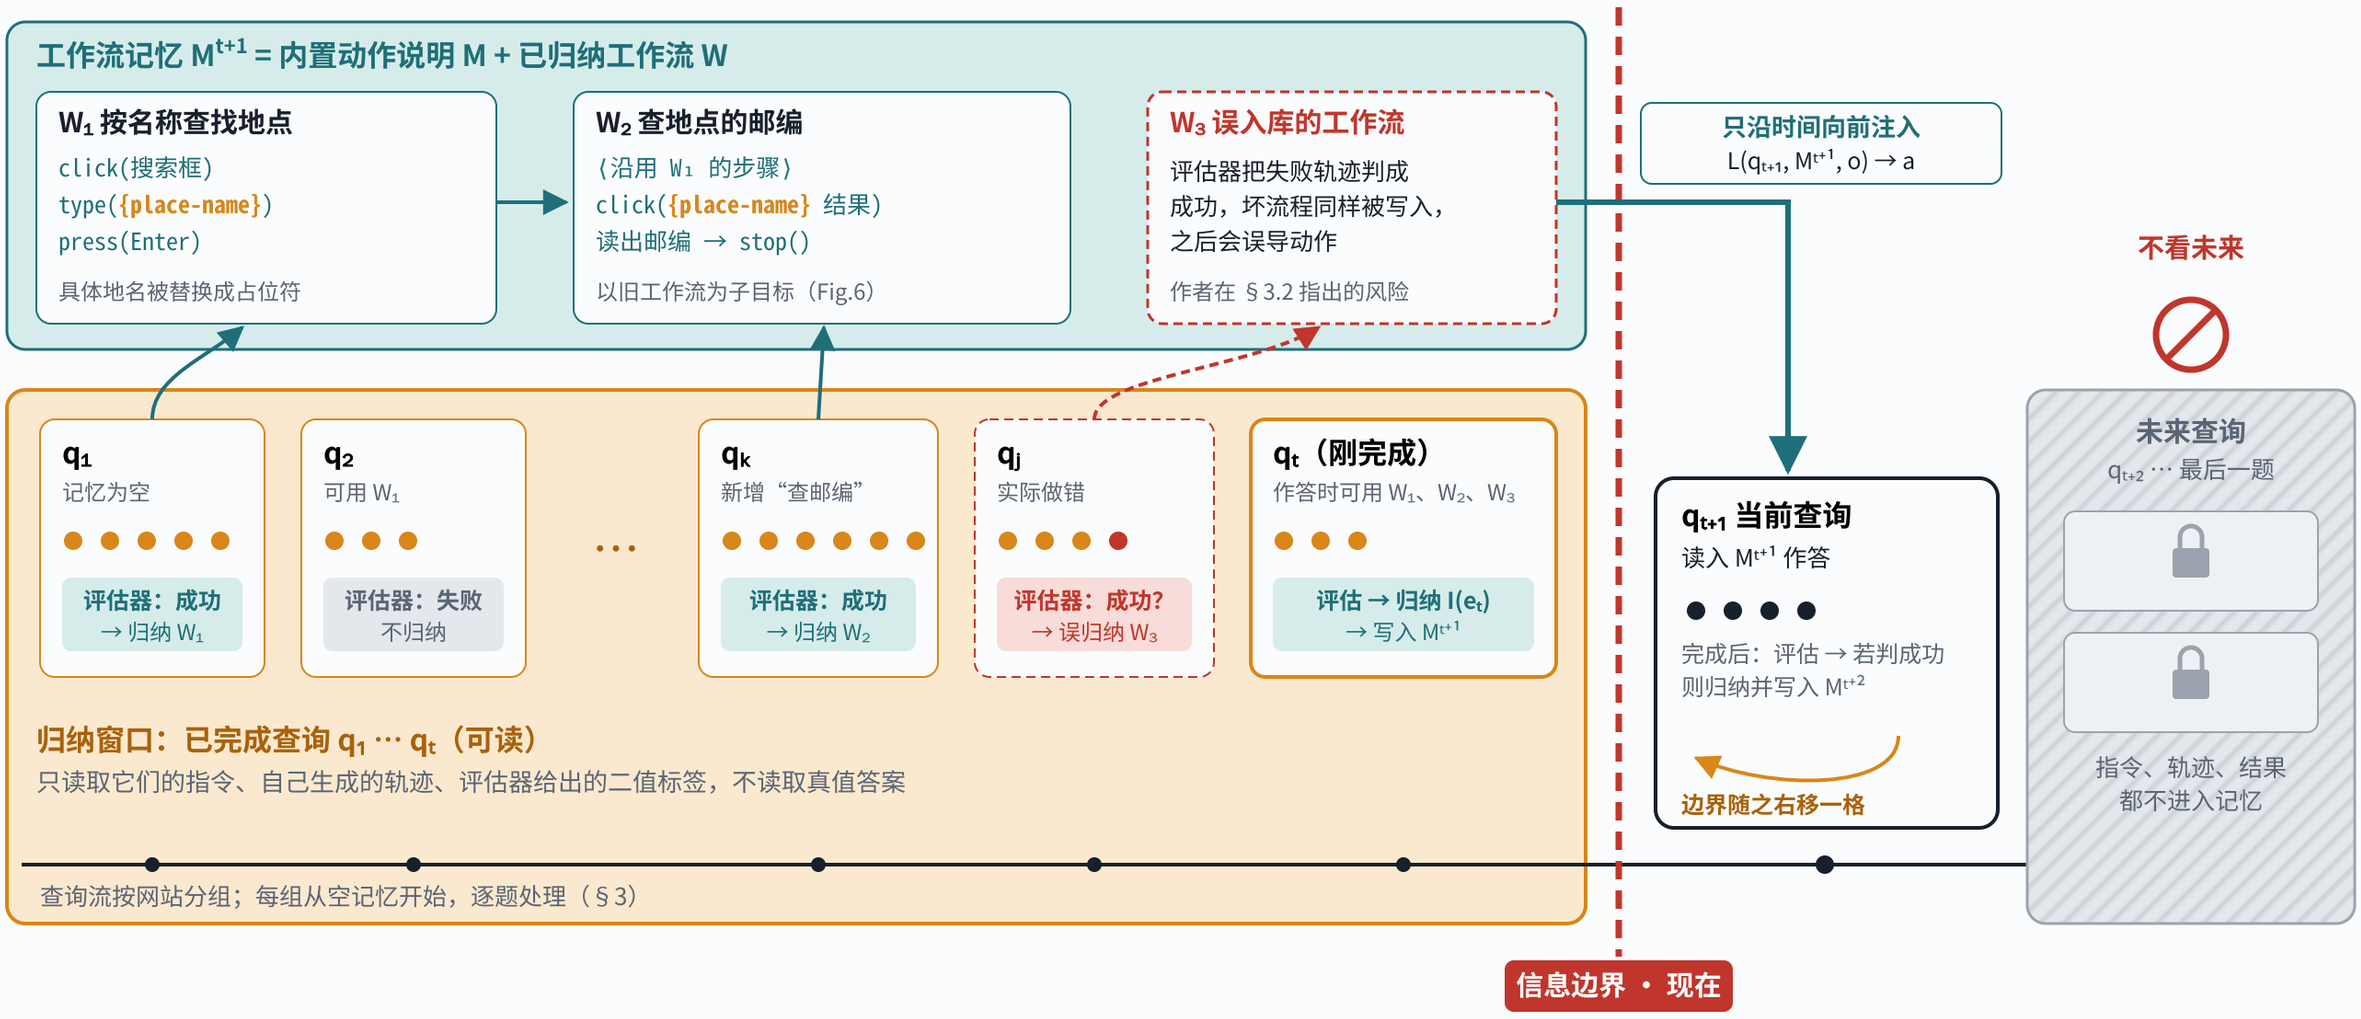
关键研究动作

把记忆更新放在查询流“过去”一侧：每完成一题，先由 LM 评估器判断是否成功；判为成功的轨迹才被抽象成带占位符的工作流（如 {place-name}），写入记忆，供**下一题**使用（§ 2.3）。

归纳窗口时序图

在线 AWM，同一网站内的一条测试查询流；工作流内容依 Fig.1 / Fig.6 的地图任务改写

示意 · 自绘



同一机制，两种窗口位置

信息访问条件不同，结果要分开读

在线 WebArena / Mind2Web

测试查询流，窗口随作答增长

窗口 = 已完成的测试查询；不需要训练数据
标签来自 LM 评估器（Pan et al. 2024），可能出错

离线 仅 Mind2Web

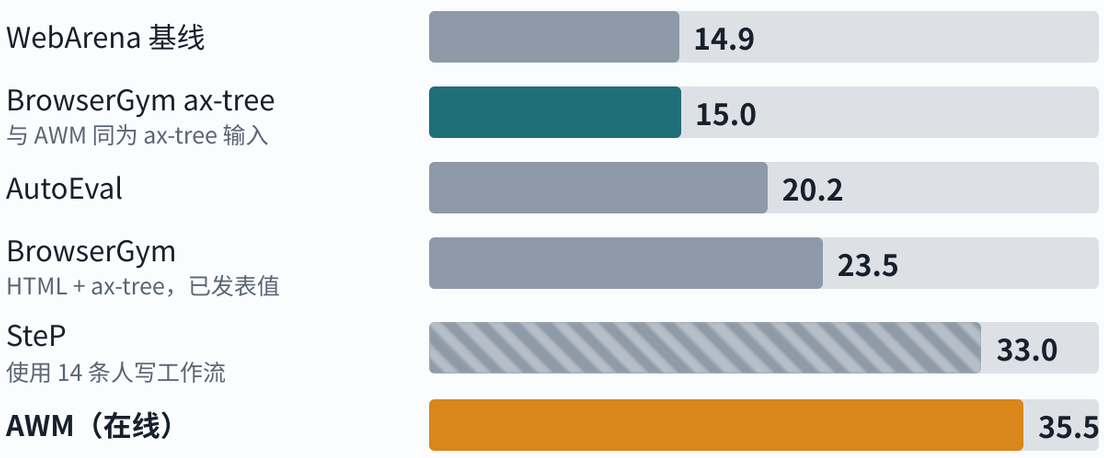
训练集轨迹 → W_offline

测试前一次归纳并冻结；全部测试题共用

两种设置都按全部测试题报告平均成功率，记忆尚空的早期题也计入（§ 2.3）。我们核对 § 2.3 的流程，没有发现读取未来查询的步骤；查询顺序如何确定，原文没有说明。

WebArena：同输入基线 15.0 → AWM 35.5

812 题 · 5 个网站 · gpt-4-0613，温度 0 · ax-tree 网页表示 · 只做在线 AWM（WebArena 没有训练集）· 任务成功率 %（Table 1）



平均步数：AWM 5.9，ax-tree 基线 7.9。论文写的“相对提升 51.1%”是拿 **23.5** 当分母；和同输入的 ax-tree 基线比，是 15.0 → 35.5（+20.5 点）。比 SteP 只高 2.5 点。

跨模板子集 · 197 题（Table 2）

20.5 → 33.2

ax-tree 基线 → AWM

WebArena 的很多题由同一模板实例化，同模板复用会抬高分数。作者从每个模板随机抽 1 题再跑一遍，AWM 仍领先（SteP 32.1，AutoEval 23.2）。**但这只是跨任务：复用都在同一网站内。**

“跨站点”到底指什么

Mind2Web · gpt-4 · 每格：步骤成功率（大字）/ 任务成功率（小字）%（Table 4）

方法	跨任务	跨网站	跨领域
MindAct	**36.2** / 2.0	**30.1** / 2.0	**18.6** / 1.0
AWM 离线	**45.1** / 4.8	**33.7** / 2.3	**32.6** / 0.7
AWM 在线	**43.6** / 4.0	**33.9** / 1.6	**35.5** / 1.7

红色：任务成功率低于 MindAct。三个划分里 AWM 的动作 F1 都低于 MindAct。

在线的“跨网站”

在新网站上从空记忆开始，只用这个网站已完成的测试查询归纳。这是在新网站上的**在线适应**，没有把旧网站的工作流搬过去。

离线才是迁移

跨网站：随机取同领域训练集归纳的工作流；跨领域：从全部领域随机取。离线在跨网站上比 MindAct 高 3.6 点，跨领域高 14.0 点（步骤成功率）。

在线相对 MindAct 的步骤成功率增益是 7.4 / 3.8 / 16.9 点。摘要写在线 AWM “高出 8.9–14.0 点”，这个区间对应的是**离线**的跨任务和跨领域增益。

边界与限制

标签区分作者报告的结果和我们的阅读判断

1. 作者 WebArena 上规则归纳（按动作序列去重、删无效步骤）35.6，LM 归纳 35.5（Table 5）；Mind2Web 跨任务两者步骤成功率为 43.4 和 45.1（Table 6）。
   判断 **WebArena 上的增益不能只归功于语义抽象。**
2. 作者 在线工作流来自模型自己的轨迹，评估器判断不一定正确，会产生降低表现的错误工作流；在跨任务上，在线 43.6 低于离线 45.1（§ 3.2）。离线加在线混合，结果落在两者之间（附录 C）。
3. 判断 WebArena 的复用都在同一网站内，跨模板不等于跨网站。在**没见过的网站上做执行式评测的在线迁移**，这篇论文还没有建立；Mind2Web 只是逐步离线评测，任务成功率最高 4.8%。
4. 判断 每个设置只报告一次运行（温度 0），没有方差；也没有报告查询流顺序对结果的影响。在线学习曲线（Fig.5）只展示了 Maps 划分。

归纳窗口 / AWM　工作流记忆 / 同输入基线　不可见的未来　信息边界 / 风险

数字均出自 arXiv 2409.07429v1 § 2.3、§ 3、§ 4、附录 A–C · 时序图为自绘示意，不是原文插图 · 本项目未复现