同一个骨干，两条说出位置的路：生成坐标 与 读注意力

Attention-driven GUI Grounding (TAG) · Hai-Ming Xu, Qi Chen, Lei Wang, Lingqiao Liu · 不做 GUI 微调，在 MiniCPM-Llama3-V 2.5 内部读出点击位置

问题　**GUI 定位失败，是模型“看不见”目标，还是它“说不好”坐标?**

截图 + 查询

共同骨干 · MiniCPM-Llama3-V 2.5（8.5B）　冻结 · 无 GUI 专用微调 · 单张 RTX 4090

高分辨率截图 ≤1344×1344 → 视觉编码器 14×14 px patch → cross-attn 压缩 → Q 个视觉 query token → Llama3 1024 个自注意力头

分叉点：只换“读出”方式

路径 A：让模型把坐标写出来

坐标直接生成

基线 = 同一骨干原生的框输出

1. 提示要求直接输出 `<box>xmin ymin xmax ymax</box>`
2. 模型逐个生成 4 个数字；预训练中坐标被归一化到 **0–1000**
3. 按 W/1000、H/1000 缩放回原图，取框中心作为点击点（附录 §6.2）

412 087 530 121

位置被压成一串文本 token

示意：数字为虚构示例。
位置信息必须经过“语言输出”这一关。

对照条件　OCG：同一 OCR 查询文本、基本相同的问句（§4.1、§6.1）；ScreenSpot：TAG 先生成元素描述（Fig 4），提示不完全等长。

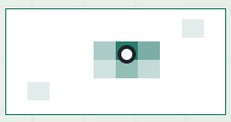
同一骨干
同一查询
机制

路径 B：从注意力里把位置读出来

注意力定位 TAG

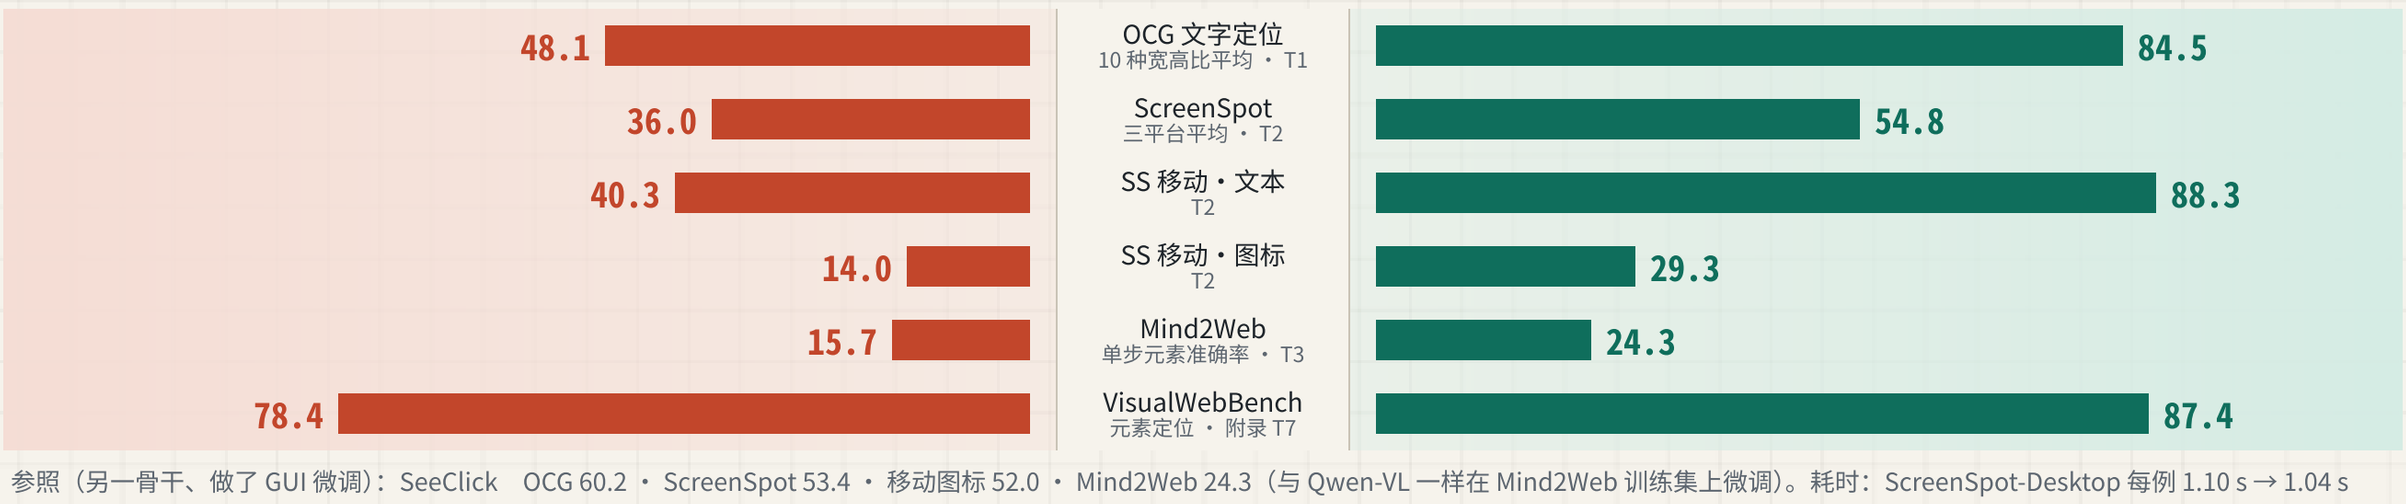
作者方法 · 无训练、无额外参数

1. **选 token**：先让模型生成目标元素的描述，用描述 token 而非原查询（§3.3）
2. **筛头**：每个 token 只留注意力总量最高的 **K=10** 个头；按幅度排序，不看真值框（§3.5）
3. **回投**：文本→视觉 query 注意力 × cross-attn → patch 热图（式 1–3）
4. **取点**：阈值 **δ=0.5** 二值化，取均值最高连通域的中心（§3.4）



示意：patch 热图 → 连通域 → 中心点。
位置直接从内部空间信号读出，不经坐标文本。

证据　同一骨干两条路径的准确率（%）　作者报告



参照（另一骨干、做了 GUI 微调）：SeeClick　OCG 60.2 · ScreenSpot 53.4 · 移动图标 52.0 · Mind2Web 24.3（与 Qwen-VL 一样在 Mind2Web 训练集上微调）。耗时：ScreenSpot-Desktop 每例 1.10 s → 1.04 s（附录 T6）。

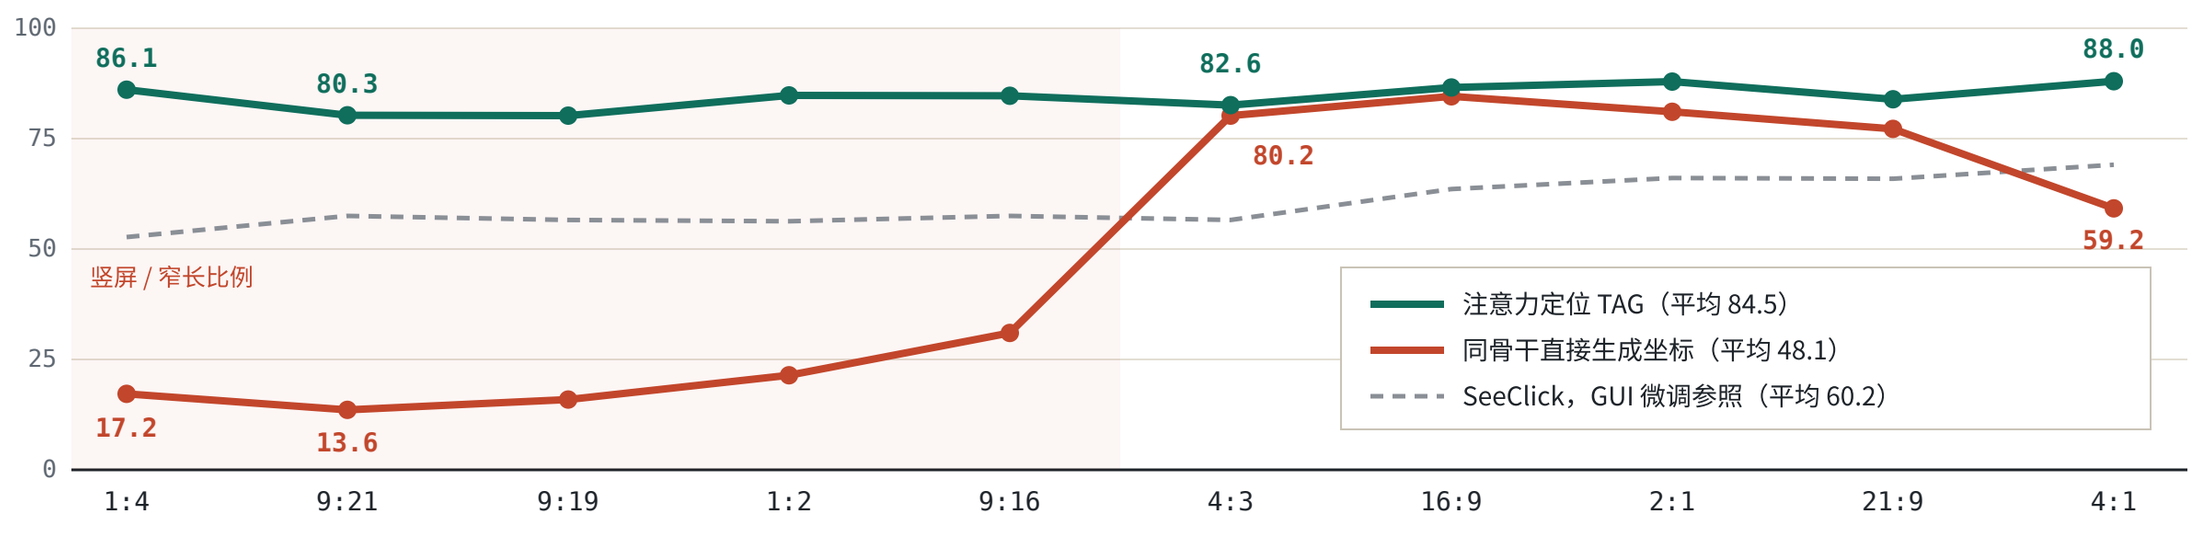
失败面

- × **竖屏宽高比崩塌**：OCG 4:3 为 **80.2**，9:21 仅 **13.6**，1:4 为 **17.2**（T1）
- × 作者推测：预训练数据未覆盖所有宽高比，坐标输出难以泛化到没见过的比例　作者推测
- × 图标：移动 14.0 / 桌面 12.1 / 网页 19.9（T2）

- × **图标仍弱**：三平台约 29%（29.3 / 28.6 / 29.1），移动图标低于 SeeClick 的 52.0（T2）
- × **K、δ 由扫描选定**（Fig 6/7），原文未说明独立调参集
- × **依赖骨干**：换到 Qwen-VL-Chat，OCG 4:3 只从 2.7 到 10.2（§4.5）

同一批截图按宽高比拆开：坐标路径在竖屏上崩塌，注意力路径不随比例变化

OCG，据 Table 1 数值重绘 · 每个比例 1030–3797 个文字目标（附录 T5）



归因分离：把“看不见”和“说不出坐标”拆开　依据作者结果的阅读判断 · 实线标签=作者报告，虚线标签=我们的阅读

① 只换读出，不加别的　作者报告 · T4

只开“注意力回投”、不生成描述、不筛头：移动文本 **40.3→71.8**，移动图标 **14.0→27.1**，桌面文本 **62.4→73.2**。描述 token 与筛头再把移动文本推到 88.3。

② 坐标崩、注意力稳　阅读判断

9:21 截图上同一骨干写坐标只有 **13.6**，读注意力有 **80.3**。目标在内部表示里是“看得见”的，失败主要落在坐标输出这一接口上。

③ 两条路都低 → 不是格式问题　阅读判断

图标在注意力路径上仍只有约 **29**，低于做过 GUI 微调的 SeeClick 移动图标 **52.0**。这部分缺口不能归给坐标格式，属于感知或语义对齐的上限。

限制与边界　K=10、δ=0.5 按性能扫描选定，原文未说明独立调参集；完整 TAG 多了“先生成描述”，与基线提示不完全一致（①是更干净的对照）；主结果只有一个骨干；Mind2Web 是给定真值历史下的单步元素准确率，不是在线任务成功。结论只说明骨干内已有可读出的空间信号，**不说明坐标 SFT 无用**。