arXiv 2503.19537v1 · WWW Companion '25

代理主动找用户：100 次开口，只有 8–19 次是该问的

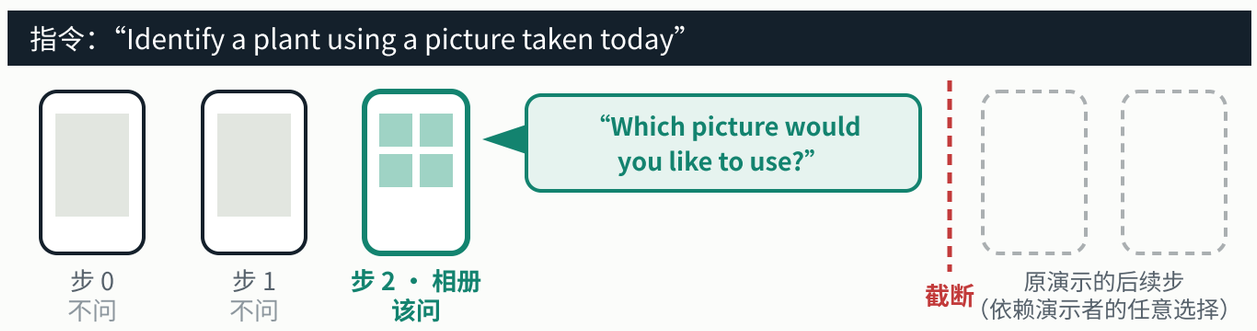
作者结果 AndroidInteraction 上，Gemini 1.5 的 **12 种配置**（输入 3 种 × 1/2 阶段 × 零样本/少样本）判断“这一步要不要停下来问用户”，**precision 只有 0.08–0.19**，recall 0.30–0.84。错误主要是**不该问却问了**。

研究动作：把“何时该问”标成逐步的二分类

- 在 AndroidControl 的人类演示上逐步标注：此步是否必须联系用户（缺信息 / 需确认 / 告知不可行），并写给用户的消息与 1–5 必要性分
- 标到首次该问即**截断**：**772** episodes · **3,605** 步 · 250+ app；**27.5%** 的 episode 含一次交互，正例约占步数 **5.5–6%**
- 2 名专业标注员，**200** 条重标：是否该问 κ=**0.64**，必要性分相关 **0.78**
- 范围外：导航求助、策略性确认、提前问、多轮对话

一条 episode 怎样变成标签

示意 · 指令与消息取自原文 Table 1 必要性 5 级例



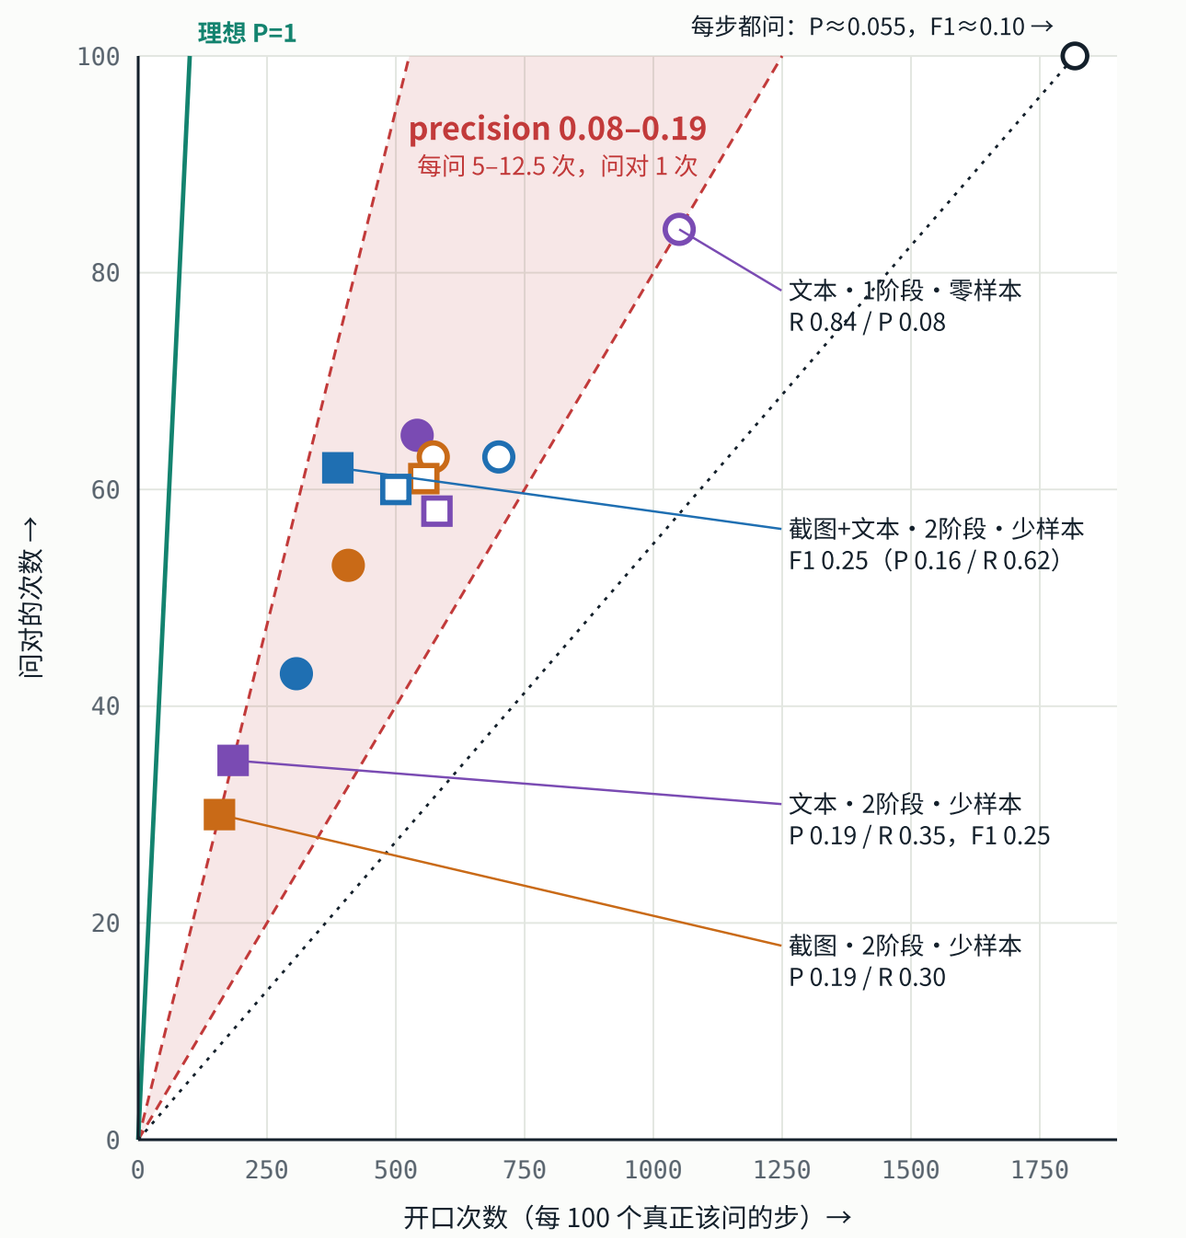
失误矩阵：错在哪一格

由 P/R 推算 以 F1 最高的 **截图+文本 · 2 阶段 · 少样本**（P 0.16 / R 0.62 / F1 0.25）为例，按**每 100 个真正该问的步**换算；每个点 ≈ 10 步。格内百分比为 **作者结果**

标注 ↓ 模型 →	问了	没问
该问	**该问 · 问了** 62 步 ●●●●●● 消息与金标准等价：**88.3%**（作者人工）/ 74.7%（GPT-4o 评） 只在这一格上计算	**该问 · 没问** 38 步 ○○○○ 漏问主因是**屏幕理解**，如选项要滚动才可见。全部分歧中 15% 可视为可接受/主观，多出现在漏问
不该问	**不该问 · 问了** ≈326 步 **多余确认 51%** · 导航提问 31% · 其他 作者解释：过于死守指令	**不该问 · 没问** ≈1,390 步 正例只占约 5.5% 的步，这一格天然最大；准确率这类指标会被它撑高（约 140 个点，图中略去）

12 种配置全在低斜率带里

由 P/R 推算 每点一个配置。x = 每 100 个真正该问的步上开口次数（=recall/precision×100），y = 其中问对的次数（=recall×100）。论文只报告 P/R/F1，未报告计数。



文本（无障碍树） 截图 截图+文本 1 阶段 2 阶段 实心 少样本 空心 零样本

读法：越靠左上越好；理想线几乎贴着纵轴。红色楔形的两条边就是 P=0.19 与 P=0.08，12 个点全部落在其中，最好的点也离理想线很远。原表 P/R 只到两位小数，推算坐标含舍入误差。

注解带 | 表面合规率掩盖低精确率

阅读判断 数字均为作者结果；“表面指标”的归纳是我们的读法

看起来：最高 recall
0.84 → P 0.08
文本 · 1阶段 · 零样本几乎处处开口：每 100 次开口约 92 次不该问。高召回是靠多问换来的。

看起来：消息正确率
88.3% → 16%
88.3% 只在“问对了”的开口上算；同一配置所有开口中只有约 16% 该问。消息好不代表时机对。

看起来：F1 最高 → 对照“每步都问”的 F1
0.25 vs 0.10
每步都问即可得 P≈0.055 / F1≈0.10（作者脚注）；最差配置 P 0.08 只比盲问高 0.025。few-shot / 2 阶段提 P 却降 R。

限制

- **只到首次交互**：episode 截断在第一处该问，不接收用户回复，不测任务完成、多轮澄清或用户负担。
- **离线逐步分类**：在人类演示轨迹上判断，非在线代理执行；所有配置同属 Gemini 1.5，不代表其他代理。
- **标签主观**：κ 0.64；导航求助与策略性确认不算该问。Table 3 未写明所用数据划分（数据集 70% test / 30% val）。

作者的解释与尝试

- 低 precision 源于模型死守指令，产生多余确认与导航提问。
- 加入过滤假阳性的 audit 组件，无显著改善。
- 推测需在更大专用数据上微调。