arXiv 2504.01382v4 · COLM 2025 · An Illusion of Progress?

旧任务在老化，捷径在抬分：换一套经审计的在线任务，web agent 成功率回落

作者主张：WebVoyager 上"接近 90%"的报告值被任务失效、搜索捷径与判分误差共同抬高；在新基准 Online-Mind2Web 上人工评，最好的 Operator 为 61.3%，其余四个约 28–31%。

具体问题

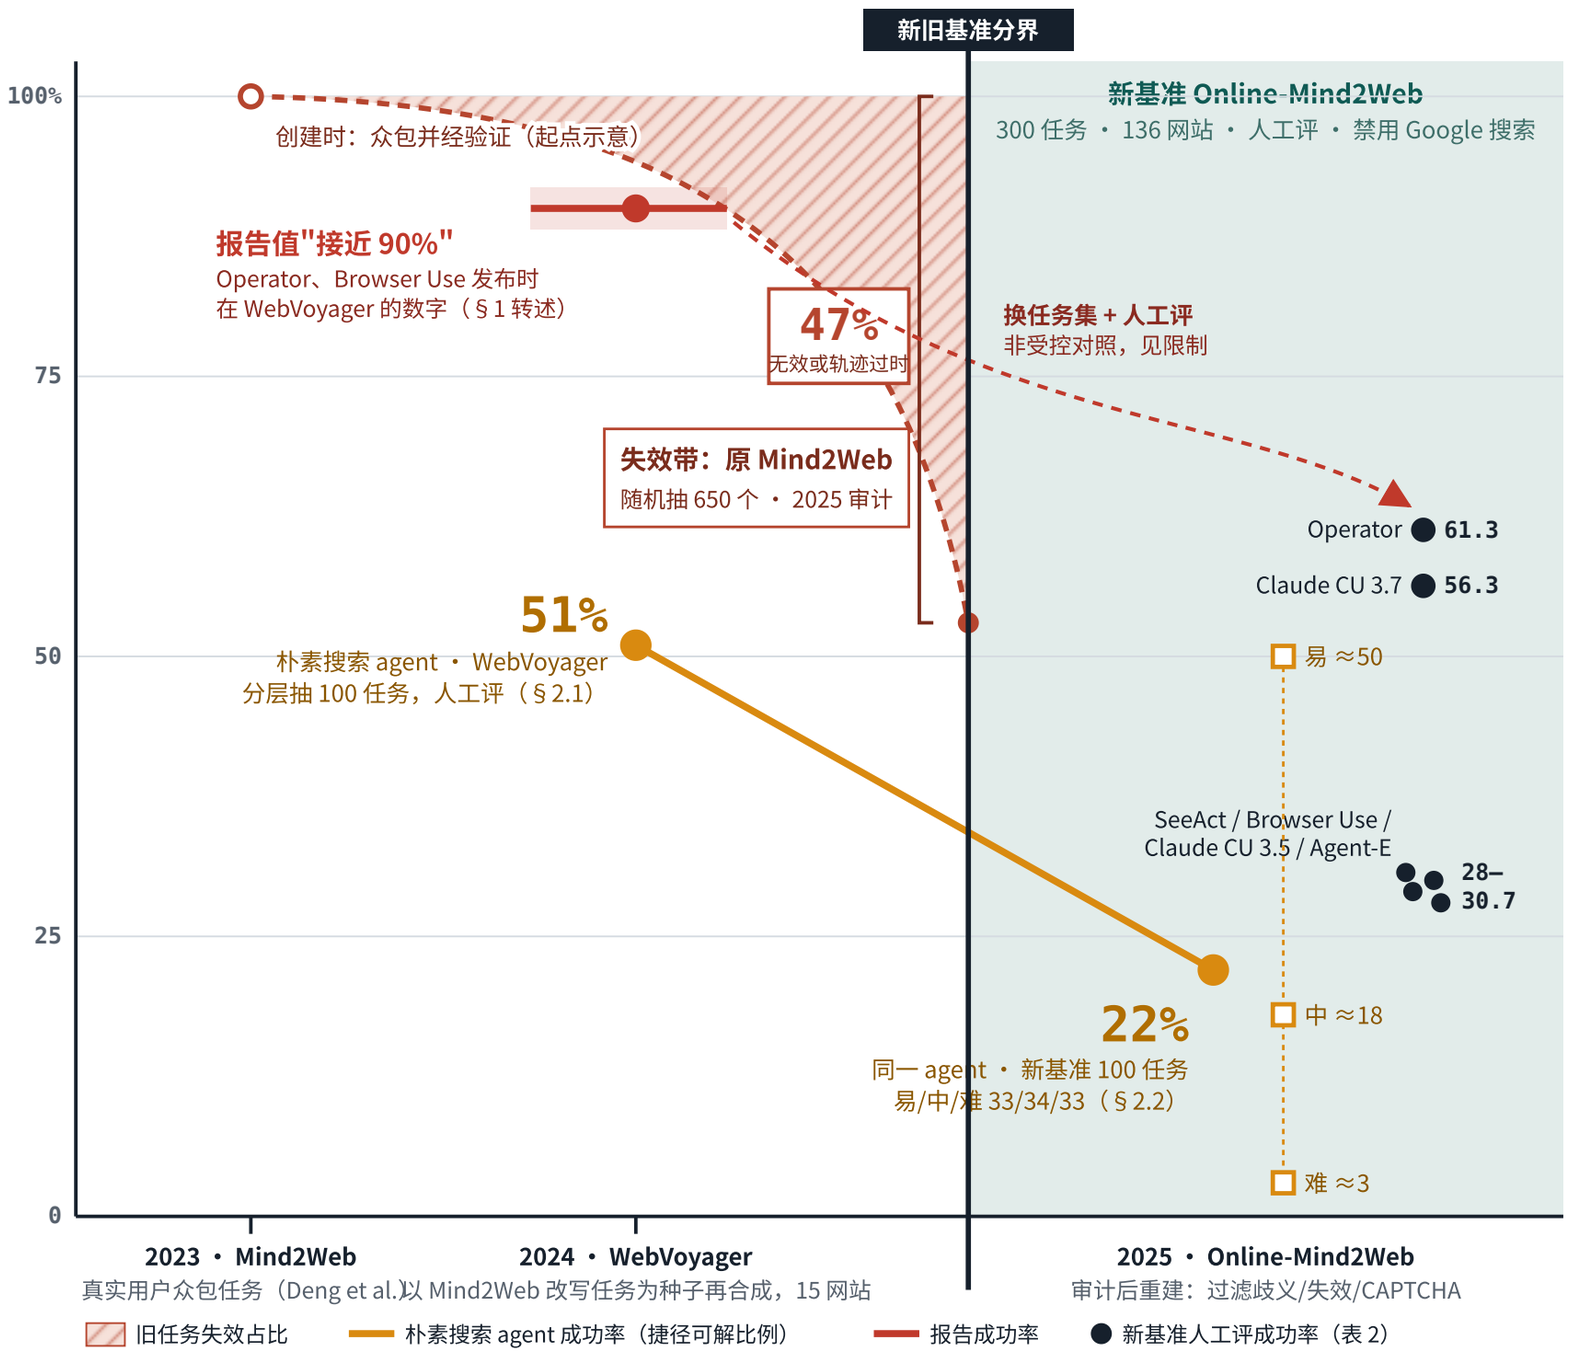
流行的在线基准沿用 2023 年 Mind2Web 一脉的任务：抽查 650 个原 Mind2Web 任务，**47%** 已无效或参考轨迹过时；WebVoyager 任务里，一个只会 Google 搜索的朴素 agent 就能做对 51%。

关键动作

先审计任务失效与捷径，再过滤歧义 / 失效 / CAPTCHA 任务，构建 300 任务、136 网站的 Online-Mind2Web；全部轨迹人工双标仲裁，并提出只看"关键截图"的自动判分器 WebJudge。

任务年代 × 成功率失效曲线 横轴按任务来源排列，非等距

示意 · 只有标点是论文数字，连线与曲面为自绘



核验环 · WebJudge §3；表 2–5



1. 由任务描述列出必须满足的关键点（如地点、评分）。
2. 逐帧摘要并打相关度 1–5，≥ δ=3 的留作关键截图：既不只看末帧，也不把上百张截图全塞进上下文。
3. 任务 + 关键点 + 关键截图 + 动作序列 → 成功 / 失败；不依赖 agent 的最终回答。

判分器（平均）	一致率	SR 差
WebJudge-7B	**87.0**	**3.9**
WebJudge · o4-mini	**85.7**	**3.8**
WebJudge · GPT-4o	**83.6**	**7.8**
只看末帧 · Autonomous Eval	**79.4**	—
全部截图 · WebVoyager 判分	**73.9**	—

后两行为 GPT-4o 版（表 3）。GPT-4o 版重复 3 次：六 agent SR 标准差平均 1.1%、最大 1.8%。
外推到 AgentRewardBench 1,302 条轨迹：o4-mini 版 precision 82.0，但**偏保守、SR 差 10.5**（表 4/5）。

同条件对照 §2.1–2.2 · 图 2

同一个朴素搜索 agent（生成 Google 查询 → 点开结果查答案，不再操作网站），两边各分层抽 100 任务，人工评：

51% → 22%

WebVoyager → Online-Mind2Web。新集按人工参考步数分难度（≤5 / 6–10 / ≥11 步），全集 83 / 143 / 74；构成 = 167 原 Mind2Web 精选 + 24 改写 + 34 Mind2Web-Live + 75 高流量站新建。

新基准上的六个 agent 表 2 · 人工评

每任务至少两名标注者，第三人仲裁冲突。

- Operator **61.3**、Claude Computer Use 3.7 **56.3**
- SeeAct **30.7**、Browser Use **30.0**、Claude CU 3.5 **29.0**、Agent-E **28.0**
- 平均成功率易 → 中降 31.6%，中 → 难再降 15.4%（原文口径）；CU 3.7 / Operator 易任务 90.4 / 83.1。

明确限制 附录 E；§4

- **步数预算不统一：**SeeAct / Browser Use / Agent-E 最多 25 步；Claude CU 3.7 最多 50 步且关闭 thinking；Operator 只能经网页界面收集，未给步数上限。截图视角也不同（整页 vs 可视区）。
- **一致率口径：**85.7% 是与人工"成功/失败"终判的二元一致，仍约 14% 不一致；不是可执行真值。
- 活网站会漂移，CAPTCHA 站点被排除；榜单是当时、该设定下的快照。

我们的阅读判断（非作者主张，未复现）

"接近 90% → 30% / 61%" 两侧任务集、判分方式和预算都不同，是多因素合并的落差；论文分别用 51%→22% 支撑"捷径"、用一致率支撑"判分"，本图也分开画。

47% 是"无效"与"参考轨迹过时"的合计，来自原 Mind2Web 抽样，不等于 WebVoyager 任务的失效率。横轴只有三个来源节点，中间无逐年数据。

附录 B.2 中 Browser Use 允许搜索 31% / 禁止 26%，与表 2 的 30.0 口径不同，不宜混用；o4-mini 版判分更严，"一致率高"不代表各场景都更好。

来源：Xue et al., An Illusion of Progress? Assessing the Current State of Web Agents, arXiv 2504.01382v4（COLM 2025）§1–4、附录 B.2 / E。曲线、失效带与核验环为自绘示意，仅标出的数字来自论文；未使用、未仿制论文原图。初筛 G4/M4/X3/E4（gui-v3-20261022-01），Opus 5.5 核对 verify_ok。