先在想象里点一下，再在真机上点：生成的未来屏幕可以拿来选动作

ViMo 把下一屏拆成「图形」和「文字」两路生成，给每个候选动作预测一张未来屏幕，再挑一个去真机执行。同一 T3A + Gemini-2.0-Flash，AndroidWorld 116 个在线任务成功率 **33.19% → 40.95%**（+7.76 个百分点）；离线对照中，大部分提升来自“先预测再选”本身，ViMo 比最好的其他世界模型多约 1 个点。

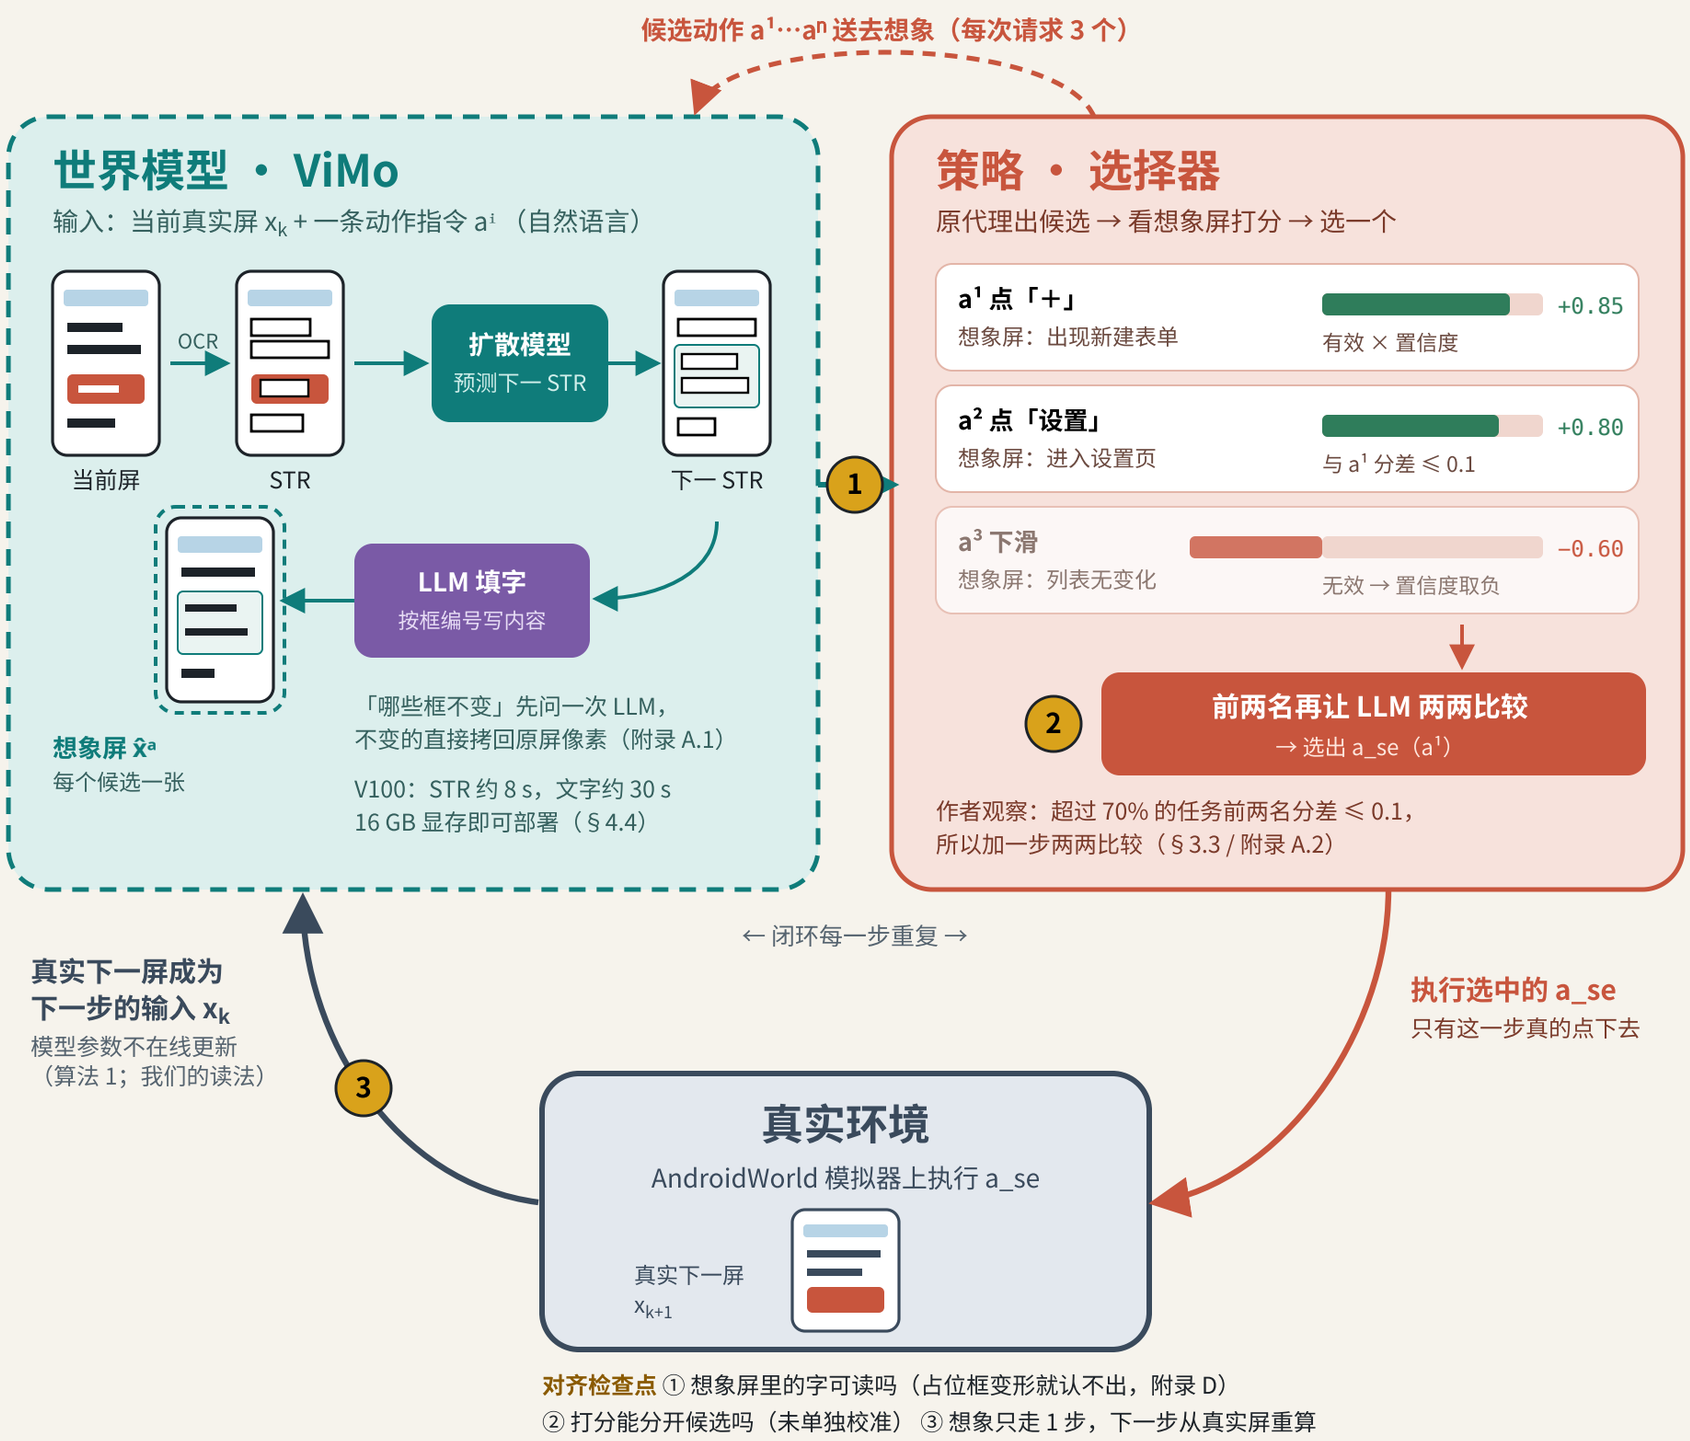
具体问题

文字型世界模型只描述下一屏，丢掉控件的**位置和颜色**；逐像素生成整屏，小字又会糊。两种“想象”都难以用来判断一个候选动作点下去会怎样。

关键研究动作

OCR 把文字盖成统一占位框（STR）。扩散模型只预测**框在哪、多大**，框里写什么交给 LLM，再按坐标渲染回去；键盘、表盘等静态文字保留为像素。

机制 · 生成—选择闭环 每一步：真实屏幕 → 想象 n 个结局 → 选一个 → 真机执行 → 新的真实屏幕 示意



真实锚点 · 何时回到真机

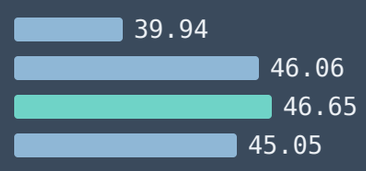
想象只用来给候选排序；动作永远在真实设备上执行。 作者结果 阅读判断

每一步都切回 作者结果

主实验只想象 1 步：每个候选生成一张下一屏，选完立即执行，下一步从真实屏重新开始（算法 1；§ 4.5 选 1 步）。

想象再深一步，收益就停了 作者结果

表 7，T3A + Gemini-2.0-Flash，离线 step acc：



条长从 35% 起画。

作者因开销选 1 步，但没有给出 2、3 步的耗时。

只靠想象走下去会漂移 作者结果

表 10：把想象屏接着喂给代理，整条轨迹仍对的比例 T+1 57.89 → T+2 36.84 → T+3 14.03 → T+4 12.28（57 条，LLM 判定）。

想象不出来的东西 阅读判断

搜索结果、新邮件、服务器返回的内容只能由 LLM 编；位置对了，字可能是假的。这类状态必须真的执行才能知道。

代价 作者结果

每次请求预测 3 个候选，约 2 分钟（含加载与通信，附录 C）。Change-text 文字模型约 5 秒。

在线：同一代理、同一 LLM

AndroidWorld 116 个任务，任务成功率（表 5）。T3A，Gemini-2.0-Flash，有无 ViMo。

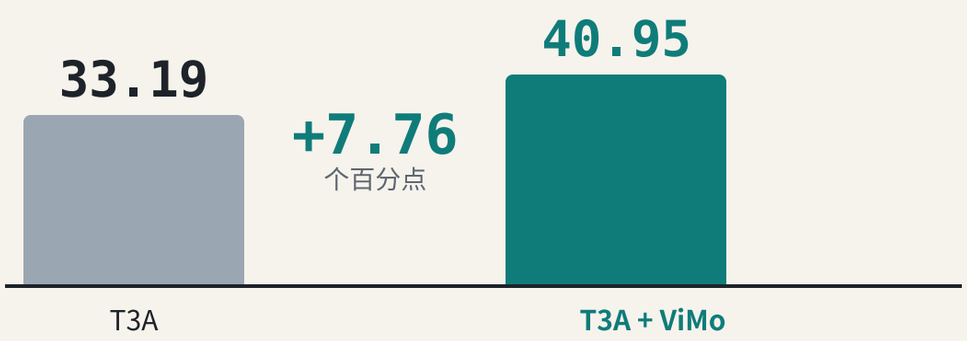


表 5 其他行（SeeAct、M3A、T3A + GPT-4-Turbo / Gemini-1.5-Pro）用的 LLM 不同，不能和这一对直接比较。在线没有和其他世界模型对照。

阅读判断： 33.19% × 116 = 38.5 题，不是整数；两数都恰好是 x/232，可能是两次运行的平均。原文没写运行次数和在线候选数。

未见过的 App（Android Control，离线 step acc，Gemini-2.0-Flash，表 4）：T3A 41.4→46.8，M3A 44.2→47.6。

离线：增益从哪来

同一选择流程只换世界模型（表 3、附录表 9）。57 个 episode、19 个 App 的抽样测试集，step acc，GPT-4o，单次运行。

	M3A	T3A
不用世界模型	46.01	43.13
文字世界模型 最好：Change-text	47.28	46.65
其他视觉世界模型 最好：HTML-vision	48.89	48.24
ViMo	**50.16**	**49.20**

条长从 42.5% 起画（满格 51%），只表示先后顺序。

ViMo 在 4 个代理上都是该组最高（表 9）。条件改用动作命令时反而低于不用世界模型（表 6，M3A 45.05 < 46.01）；不保留静态文字为 48.88。

阅读判断： 分母约 313 步（各数都是 k/313）。ViMo 比最好的替代世界模型多 **+1.27**（M3A）/ **+0.96**（T3A）个点，约 4 / 3 步；“不用世界模型”行是原代理，没有“出候选 + 打分但不预测屏幕”的对照。

限制与证据边界

1. **没有等算力对照。** ViMo 每次请求约 2 分钟；没有“同样多 LLM 调用、只出候选再打分”的基线，在线 +7.76 不能全归于视觉想象。
2. **在线证据只有一对。** 只有 T3A + Gemini-2.0-Flash；没有在线的其他世界模型对照，运行次数和候选数未报告。
3. **离线 step acc 单次运行。** 表 11 只对图像质量指标重复了 3 次，step acc 的差距（3–4 步）没有方差。
4. **70 人用户研究评的是图像质量**（一致性 / 符合指令 / 可继续操作），不是选择器打分的校准；LLM 自动评分和人工评分在 HTML-vision、UI-diffuser 上明显不一致（表 1）。

来源：arXiv 2504.13936v2（2025-05-20），§ 3.3、§ 4.2–4.5，表 1–7，附录 A.1–A.4、B、C、D；数字定位见 SOURCE.md。“作者结果”取自原文，“阅读判断”是我们的推算与读法，没有复现实验。 想象 真实执行 图标与候选分数为示意