在同一批轨迹里找“又回到这一页”：不加价值网络、不加采样的逐步信用分配

多轮网页代理只在最后拿到成功/失败，GRPO 把整条轨迹的每一步记同一个优势，分不出哪一步错。GiGPO 发现同一任务的 8 条 rollout 经常**回到完全相同的页面**，就把在这一页上做过的不同动作放成一组互相比较。WebShop 上同一套超参、3 个种子：**Qwen2.5-7B 66.1 → 75.2**，**1.5B 56.8 → 67.4**；rollout 与显存不变，每轮多花约 **0.5 秒**。

WebShop 成功率 · Qwen2.5-7B · 3 seeds

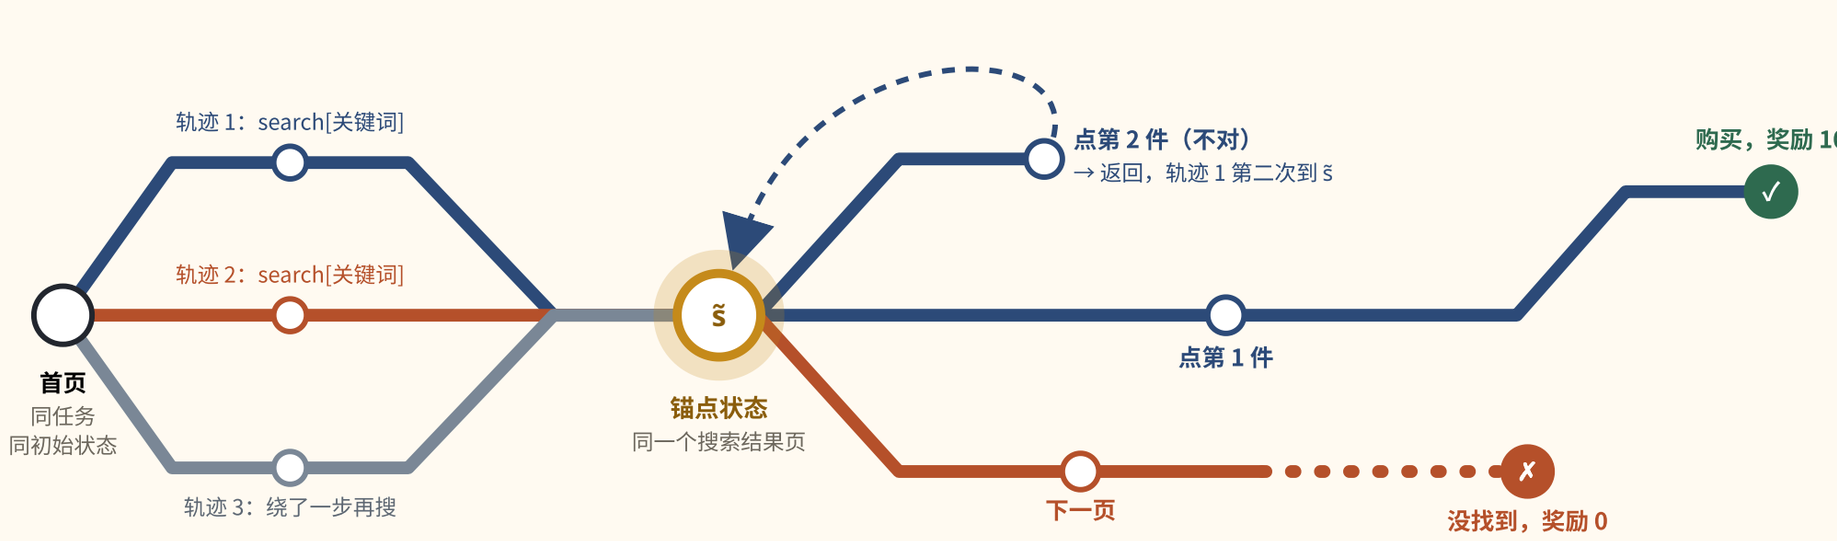
66.1 → 75.2

GRPO ±3.7 → GiGPO（不除标准差）±3.8
另一变体（除标准差）72.8 ±3.2
WebShop：HTML 文本观测的模拟购物站

01 机制 同一页面就是现成的对照组：8 条轨迹交汇处，比较各自从这里走出的路

§4.1–4.3 · 图 2–3（示意按图 3 重画）

示意 · 同一任务、同一初始页面的一组 rollout（原文 N=8，这里画 3 条）；圆点 = 一次观测，金色圈 = 几条轨迹都到过的、逐字相同的观测



两层优势相加

A^E 轨迹组
8 条轨迹的总回报减组均值（就是 GRPO 的做法）

A^S 步骤组
所有落在 s̃ 上的动作归一组，比较各自之后的折扣回报（γ = 0.95）

$A = A^E + \omega \cdot A^S$，$\omega = 1$

分组只是哈希表查找，不多跑一次模型；没有重复页面时 $A^S = 0$，退化为 GRPO

s̃ 上的步骤组排序： 点第 1 件 > 点第 2 件（同在成功轨迹里，但离奖励更远、折扣更多） > 下一页（之后没有奖励）

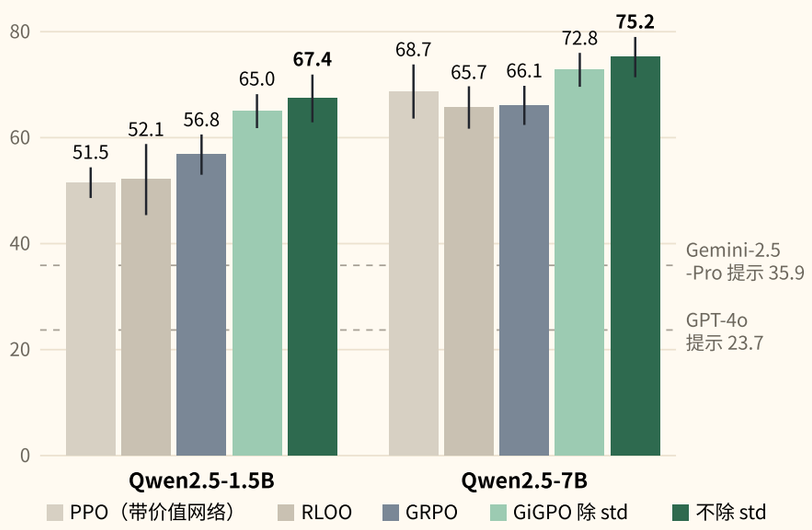
GRPO 只能给轨迹 1 的每一步记同一个分数

对照条件（附录 E.1）：所有 RL 方法同一套超参 · 组 8 × 16 · WebShop 每局 ≤ 15 步 · 奖励 成功 10 / 失败 0 / 无效 −0.1 · lr 1e-6 · KL 0.01 · 150 轮 · 观测带最近 2 步

02 结果 同一套超参、同样的 rollout 数：WebShop 上两个尺寸都拉开 7–11 点

§5.2 表 1 · §5.4 图 4 · 附录 E.5 表 5

WebShop 成功率 表 1 · 3 seeds 均值 ± 标准差



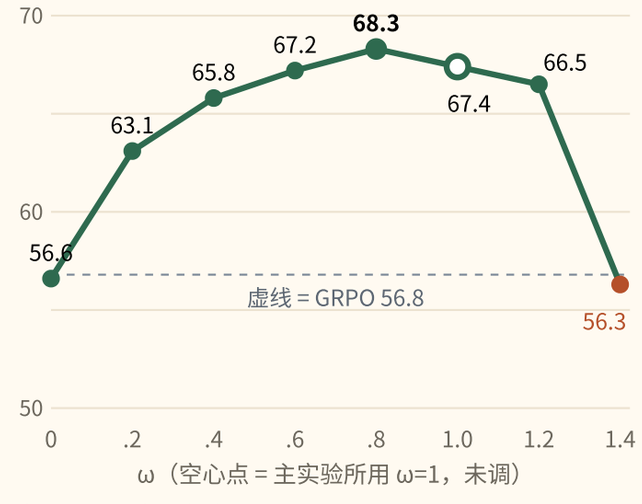
ALFWorld（家务文字游戏，非 GUI）同向：GRPO 72.8 / 77.6 → GiGPO 86.1–86.7 / 90.2–90.8。正文增益取两个变体中较好的一个。

拿掉哪一层 图 4 · Qwen2.5-1.5B · 由原文 SVG 读数

成功率 %	WebShop	Look	Pick2	Cool
完整（不除std） A^E + A^S	**67.4**	**76.5**	**79.5**	**71.7**
完整（除std）	65.0	67.5	76.4	79.8
去掉 A^S ≈ 回到 GRPO	56.8	55.3	54.6	61.0
去掉 A^E 只剩步骤组	62.5	60.1	63.2	66.0
GRPO（表 1）	56.8	53.7	53.5	59.7

两层都要：任一层拿掉都掉 5–25 点；
去掉 A^S 的 WebShop 值与 GRPO 相同（56.8）。
原图为雷达图，未标种子数与误差。

步骤组权重 ω 表 5 · WebShop · 1.5B



ω 在 0.4–1.2 之间都有 65.8–68.3；
步骤组压过轨迹组（1.4）就跌回 GRPO 水平。

03 代价与条件 便宜在哪里，靠什么成立

§5.5 图 5 · §5.6 图 6 · 附录 E.1、E.4

每轮训练时间 图 6 · ALFWorld · 1.5B

与 GRPO 共有（rollout、旧/参考概率、更新）

362.83 s

GiGPO 新增：分组 0.01 s + 步骤优势 0.53 s

0.54 s ≈ 0.15%

原文写“<0.002%”，按其给出的秒数应为约 0.15%

显存相同、rollout 数相同（组大小 8 × 16 组 = 128 个环境；PPO 用 128 个独立环境）。

重复状态有多常见 图 5 · 只报了 ALFWorld · 1.5B

训练轮次	组大小 10–49	≥ 50
第 10 轮	16.2%	5.6%
第 75 轮	12.1%	3.1%
第 140 轮	集中在 6–8（作者解读：8 条轨迹行为趋同）	

只出现一次的状态（组大小 1）始终 < 35%：
超过 65% 的状态能进步骤组。WebShop 的分布未报。

可叠加在其他改进上 附录 E.4 表 4 · E.3 表 3

WebShop · 1.5B · 成功率

GRPO	56.8
DAPO	66.1
GiGPO+DAPO	**75.0**

截图输入的小游戏 · Qwen2.5-VL-3B

Sokoban GRPO 67.1 → 81.0
格子游戏，不是 GUI；不作 CUA 证据

限制（画报口径）

- **WebShop 不是截图 GUI**：观测是 HTML 转成的文本，动作是 search[…] / click[…]，模拟站点、非实时网站。像素截图上的同一页面常因时间、广告、滚动位置不同而不逐字相同；论文只在搜索问答上试过相似度匹配（阈值 0.9）
- **同观测 ≠ 同状态**：部分可观测时，两次“相同页面”背后的购物车、筛选可能不同，会把不可比的动作放进一组；论文未检验
- 主表 3 个种子，标准差 3–5 点；两个归一化变体都报，正文增益取较好者（7B：不除 std +9.1，除 std +6.7）。消融、ω 扫描未注明种子数
- WebShop 上有多少步落进步骤组、组多大，原文未报（图 5 只有 ALFWorld），收益来自多少“重复页面”无法核算
- 只有 Qwen2.5 1.5B / 7B、150 轮训练；无跨站迁移、无真实浏览器

我们的阅读

- 早期策略的循环与无效动作（反复回到同一页）原本是浪费；GiGPO 把它变成**免费的对照组**，信用落在“在这一页上选了什么”
- 它的有效范围取决于状态能否被精确对齐：文本/DOM 观测天然友好，截图环境要先回答“什么算同一页”
- 策略收敛后组内动作趋同（组大小集中 6–8），步骤优势会变小——这是我们按图 5 的推断，原文未测
- 与已入 Reel 的 2406.11896（同骨干在线 RL 胜过模仿）互补：那篇问“要不要 RL”，这篇问 RL 里“分数记给哪一步”