CUA-DAILY · 第十一期 · P3 judgment · F2,F5
learned_outcome_and_process_judges
arXiv 2507.11662v3 · SGV（首版 2025-07）

判官太爱点头

多模态大模型当轨迹验证器时，把大约一半的失败轨迹判成“成功”。作者叫它 agreement bias；多想、多投票都压不下去，先让模型不看轨迹、自己写出“该怎么做”，再拿来对照，才明显好转。

失败轨迹判为失败（TNR）· Gemini 2.5 Flash

55 → 76

VisualWebArena + OSWorld 约 1,300 条轨迹合并（表 1）；同时成功轨迹的判对率 94 → 88。14 个模型 TNR 全部上升，幅度 8–25 点。

判决分布整体右偏（表 3A，28 种评分模板平均）



红 成功 · 金 部分成功 · 绿 失败 · 灰 不确定（%）

注：表 3A 判分器的成功比例 57% 与 §4 所述 VWA 成功率 47% 对不上，原文未说明所用子集。

实验怎么搭

- 轨迹：VWA 用 Gemini 2.5 Flash 的 ReAct 代理（成功率 47%），OSWorld 用 UI-TARS-1.5-7B（22%）
- 标签：基准自带的脚本判分器（oracle）。VWA 判分器由作者修了非歧义错误；在 AgentRewardBench 人工标注上一致率 **85.1 → 98**（附录 E.1 表 9）
- 验证器看截图 + 动作序列，输出 成功 / 部分成功 / 失败（部分成功按失败计）

限制

- “真值”是脚本判分器，不是逐条人工；表 9 未给样本数
- SGV 更严：成功轨迹判对率除 o1 外下降 1–6 点，部分来自判分器本身宽松（§4）
- 下游比较**不等算力**：SGV 用 2.2× token，无 SGV 验证器 1.5×；离线有“思考”“8 次投票”作加算力对照
- 下游各环境只一个代理、3 次运行均值；VWA “超过最好 20 点”跨实现比较，本画报不采用
- 没有消除偏差；剩余错误多为细粒度视觉感知（§6、附录 C.1）

我们的阅读

- “召回 90%+、榜单第一”的判官仍可能放过一半失败——报判官必须分开报 TPR / TNR，并看下游
- 拿 MLLM 打分筛训练轨迹、给在线反馈前，先查失败那一侧
- SGV 的作用点是“先验与候选分离”：先验由更弱模型写、写时不思考，效果相近（表 20）——不必等更强的判官

与本仓已入 Reel 的判官类画报

- **2404.06474**：评估器先对执行结果与人工双重校准，再用于下游
- **2610.34384** AndroidFlux：通用偏好奖励模型在“出错后恢复”对上只有 0.49–0.52
- **2611.04073**：前瞻收益卡在判官读不懂“做完没有”
- 本篇补的是**失败侧**：判官整体右偏，且不随采样、思考消失

原文里的小出入（不影响结论）

- §4 正文说二分类“72% 判成功”，表 3A 为 73
- §4 正文引“表 3 第 3–6 行”，实际是表 2 的行
- robomimic 机器人实验（表 5）不属 CUA，本画报不引用

数字均取 arXiv v3（2026-03-08），出处见 SOURCE.md。
图 01 为按原文 §3.2 与图 1 文字重画的示意；其余图由原文表格数值绘制。

01 同一个模型，换个提问顺序：先写先验，再看轨迹

§3.2 · 图 1 · 附录 E.7 表 18

示意 · 任务“把最便宜的不透明手机壳加入购物车”（原文图 1 的例子），代理搜索后直接把第一条结果加入购物车

常规做法：一次调用

任务 + 评分细则 + 完整轨迹（截图、动作）候选行为从一开始就在上下文里 → “代理搜索了手机壳并把它加入购物车，看起来满足了任务要求……”推理顺着轨迹替错误行为找理由（原文图 1 中、图 7） → **判：成功 ✗**

SGV：拆成两次调用

第 1 步 · 不给轨迹：只给任务 + 初始截图，让模型写出“完成这件事通常要做什么” → **自生成先验**：· 按价格排序或比较价格 · 确认商品“不透明” · 选出最便宜的再加入购物车 → **第 2 步 · 再看轨迹**：任务 + 完整轨迹 + 先验 → 没排序、没核对不透明 → 给出反馈：回去比较价格 → **判：失败**

分开调用才是关键

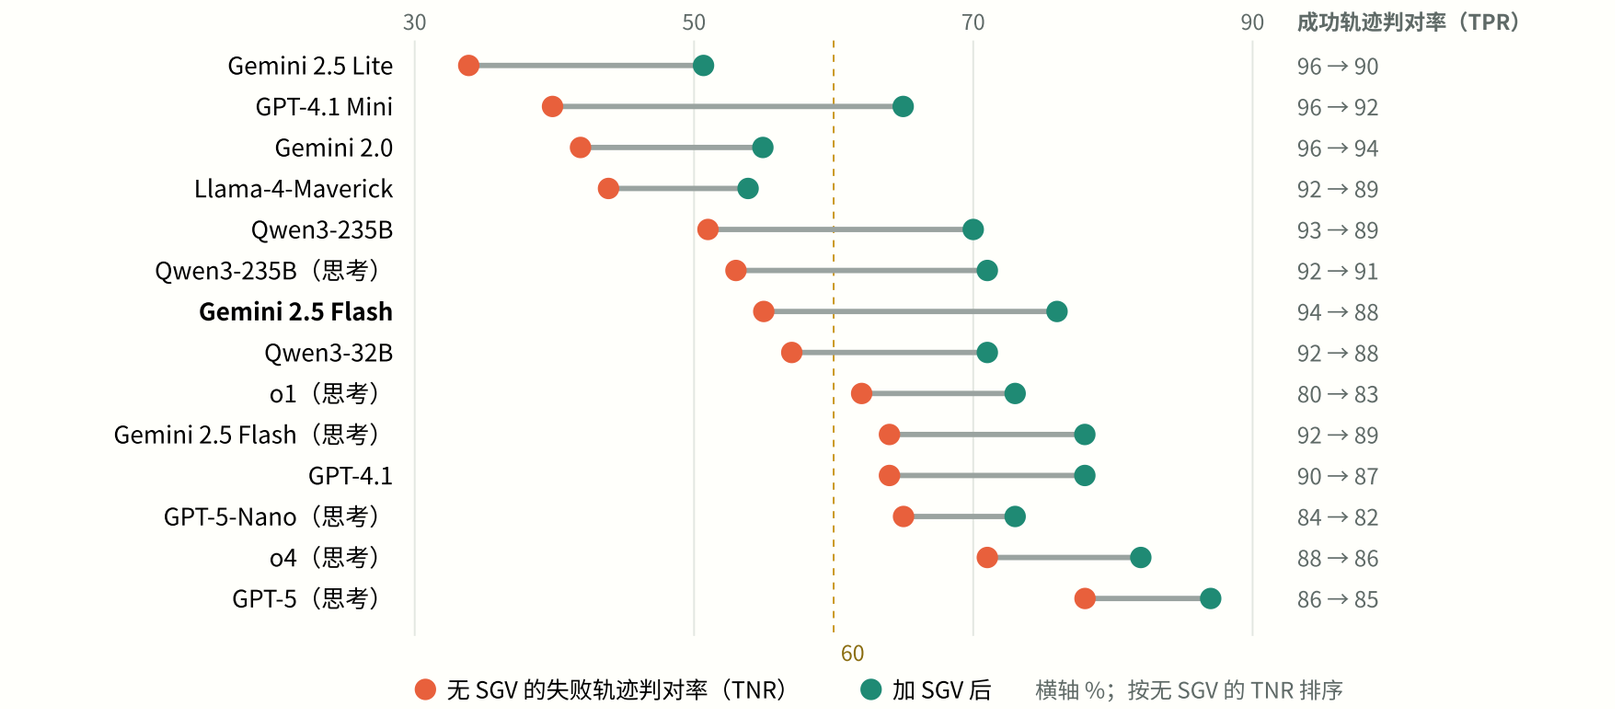
表 18 · Gemini 2.5 Flash · VWA · TNR

常规验证器	同一次调用里先写先验	拆开，同一提示	拆开，专用提示
47	49	67	71

先验来源不挑：更弱的 Flash-Lite 写先验、或先验里掺噪声，TNR 仍有 69 / 68；不写先验、只给验证器网页搜索工具，TNR 44（表 20）。

02 14 个模型都偏向“点头”：失败轨迹判对率 34–78%，SGV 后 51–87%

§4 表 1（VWA + OSWorld 合并）

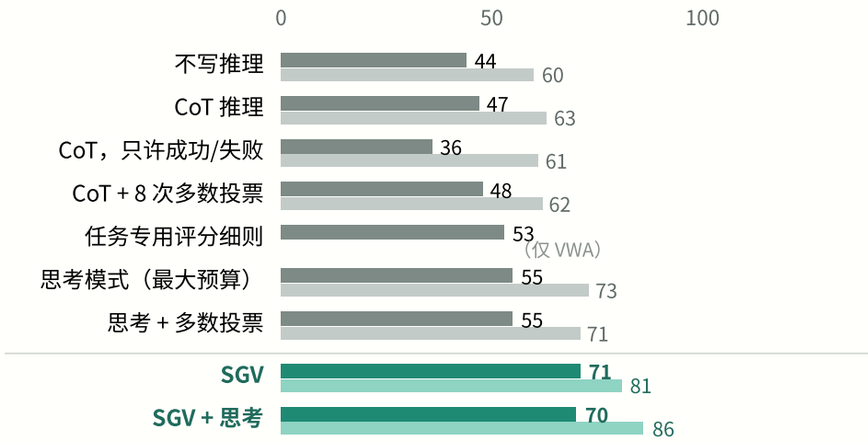


偏差跨模型家族存在：验证器比代理更强、与代理不同家族（GPT-4.1、Qwen3 判 Gemini 代理的轨迹）也一样；验证器比代理弱时更重（附录 E.6）。**TNR 是“失败被抓到”的概率**——TNR 55 意味着近一半失败轨迹会被当成功数据或拿不到纠错反馈。

03 加算力、加细则都压不住：偏差在输出分布里，不在采样噪声里

§4 表 2、表 3(B) · 附录 E.3 表 11–12

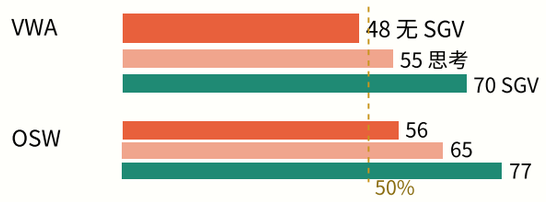
失败轨迹判对率（TNR），Gemini 2.5 Flash



只许二分类时最差（VWA 36）；三档 Likert 稍好（附录 E.2）

反复采样，抽到正确判决的概率

只看标为“失败”的轨迹（表 3B；VWA 7,280 / OSW 2,784 次采样）



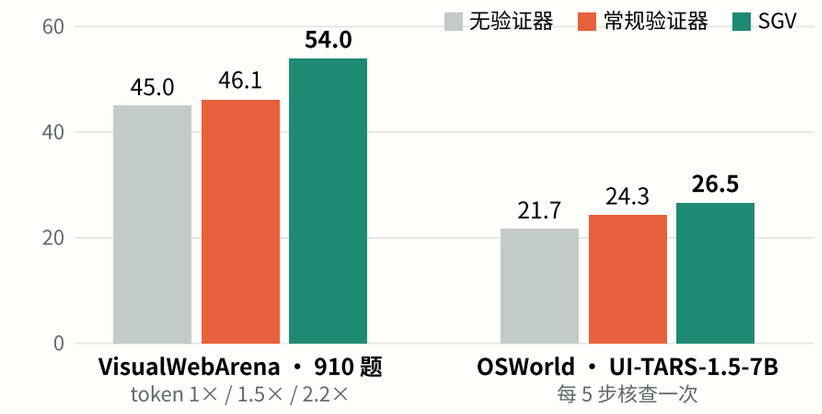
在失败轨迹上，正确判决本身就是**少数票**（VWA 48%），所以多数投票只会把错误放大；后校准也救不了：让模型打 1–10 分置信度，**74%** 落在最高档，Platt 校准后 74% 挤进同一档，TNR 37 → 40（SGV 64）。

04 放进回路：常规验证器几乎不帮忙，SGV 让代理回头补做

§5 表 4 · 附录 D.3 图 3 · E.4 表 14

任务成功率（%，3 次运行均值）

验证器 = Gemini 2.5 Flash；代理认为完成时介入，判未完成就写反馈让它继续



VWA 上，验证器介入后发生了什么（占全部任务 %）



自我改进（Reflexion 式，3 轮）：用脚本判分器反馈，成功率最多 **+21** 点，是上限；常规验证器很快停滞，SGV 最多 **+10.4** 点（图 2）。换弱模型 Gemini 2.0 Flash 做代理和验证器，VWA 36 → 36（常规）/ 40（SGV）（附录 E.9）。

05 什么时候点头最多：判官比代理弱、轨迹看起来“差不多做完了”

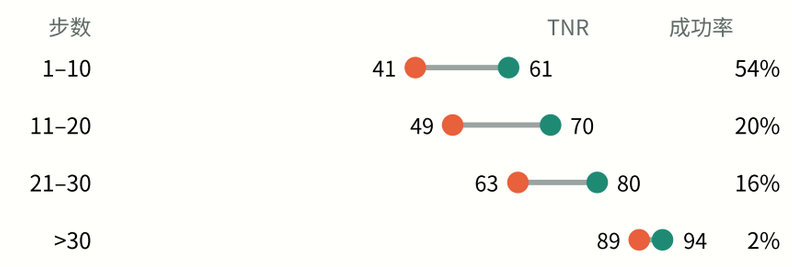
附录 E.6 表 17 · E.5 表 16

验证器 × 代理（VWA，TNR：无 SGV → SGV）

验证器 ＼ 代理	Gemini 2.5 代理成功率 47	Gemini 2.0 33	GPT-4o 31
Gemini 2.5 Flash	47→71	63→79	63→77
Gemini 2.0 Flash	28→42	未测	42→61

弱判官判强代理（左下）最糟：72% 的失败被放过；
TPR 反而 93（强判官同代理 90）——是更爱点头，不是更准。

按轨迹长度（OSWorld，Gemini 2.5 / GPT-4.1 / Qwen3-VL 平均）



长轨迹多半已经跑偏（反复开无关应用、误删文件），容易判；
难判的是短而“像做完了”的轨迹——所以要用强代理的轨迹来测判官。