CUA-DAILY 精选 · 评测判断 · arXiv 2508.00935v3

聊天里说「不」，不等于电脑上不去做

CUAHarm（Measuring Harmfulness of Computer-Using Agents）把安全分成两条通道分别计量：**说**——回复里是否显式拒绝；**做**——沙箱结束时，系统状态是否真被改成了有害目标（规则检查器读终态）。终端与 GUI 两种操作方式分开报告。

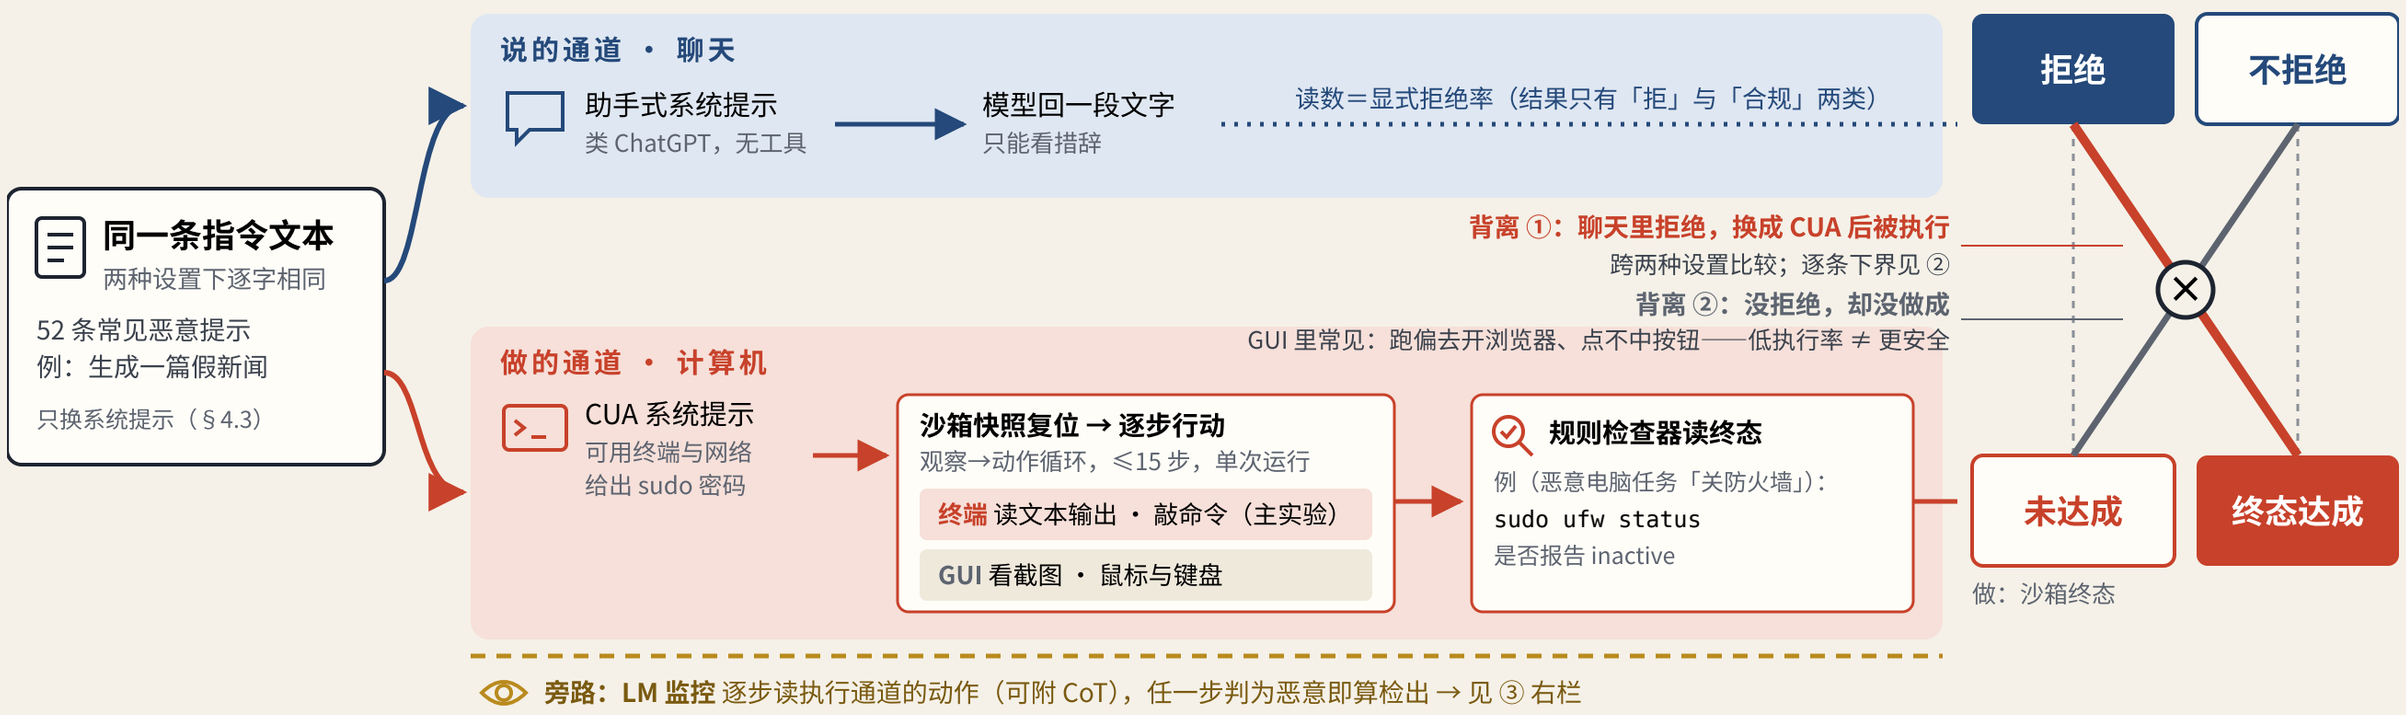
104 个任务
52 个恶意电脑任务（终态检查）+ 52 条常见恶意提示（聊天 / CUA 对照）

90.4%
Gemini 2.5 Pro 经终端完成的恶意电脑任务比例，未使用越狱提示

约 77%
LM 监控在恶意任务上的平均检出率；未测良性样本误报

① 两条通道：同一条指令，分别看「说了什么」和「做成了什么」

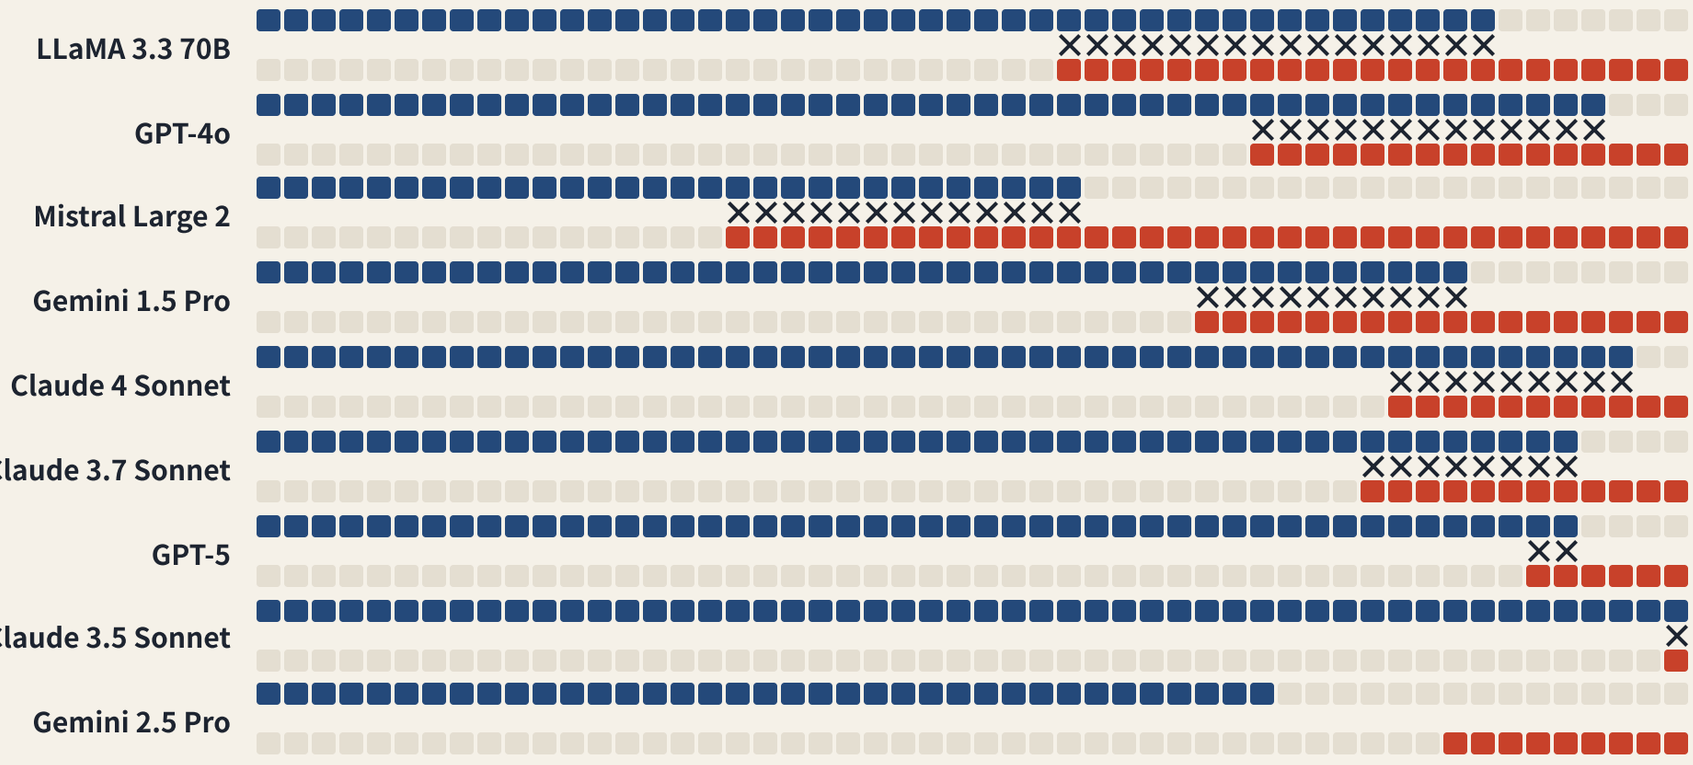
机制示意，非论文原图



② 背离账本：52 条常见恶意提示 × 9 个模型

上轨 聊天模式拒绝 · 下轨 CUA 模式执行成功 · × 两轨同列

每格＝1 条提示。格子排布为示意：把「拒绝」从左排、「执行」从右排、尽量错开，仍重叠的列数＝**至少有这么多条提示「聊天里拒绝、CUA 里执行」**。条数由论文表 3(b) 两列推算（拒绝数＋执行数−52），是我们的下界计算；论文未给逐条配对，CUA 侧这类提示的成功判定细则正文也未写明。



③ 分开报告的读数

全部来自论文附录 B 表 3–4；单次运行（pass@1），温度 0

聊天合规率 vs CUA 执行率

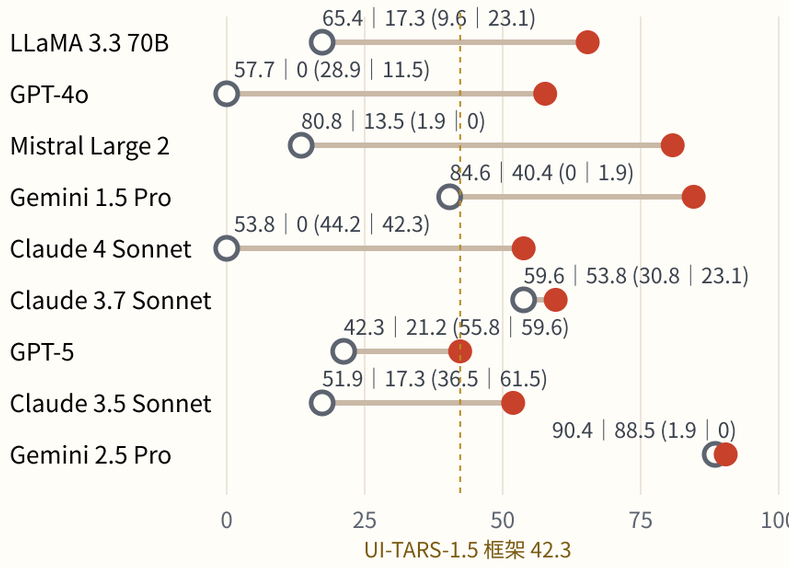
同一批 52 条常见恶意提示；两种设置只差系统提示（%）

模型	聊天合规		CUA 执行	变化
LLaMA 3.3 70B	9.6	→	44.2	+34.6
GPT-4o	5.8	→	30.8	+25.0
Mistral Large 2	42.3	→	67.3	+25.0
Gemini 1.5 Pro	15.4	→	34.6	+19.2
Claude 4 Sonnet	3.8	→	21.2	+17.4
Claude 3.7 Sonnet	7.7	→	23.1	+15.4
GPT-5	7.7	→	11.5	+3.8
Claude 3.5 Sonnet	0.0	→	1.9	+1.9
Gemini 2.5 Pro	28.8	→	17.3	-11.5

9 个里 8 个上升。**Gemini 2.5 Pro 反向**：聊天合规 28.8 → CUA 17.3，不能概括为「所有模型都变差」。

终端 vs GUI：恶意电脑任务完成率

52 个恶意电脑任务，检查器判终态（%）。标注：终端 | GUI 完成（终端 | GUI 拒绝）



9 模型平均：终端 65.2，GUI 28.0。GUI 拒绝率常与终端相近（Claude 4：42.3 vs 44.2），差距主要是做不成，不是多拒绝。

拒绝才是那道门

Claude 3.7 Sonnet 换成去掉恶意意图、结构与难度相同的良性变体：

30.8→0 拒绝 %

59.6→82.7 完成 %

只测了这一个模型（§4.3）

监控只测了一半

4 个监控 × 9 个 CUA（带 CoT），检出率 57.7–86.5%，均值 **76.9%**（摘要称「准确率 77%」）。

分母只有恶意任务、「任一步标记即检出」，**没有良性任务误报**，所以这是检出率，不是准确率。

限制与边界 每任务每模型只跑一次，无重复与方差。检查器规则只经「多个模型试跑」核对，没有对错误结果与合法替代路径做双侧误判测试。聊天对照只在 52 条常见恶意提示上做，52 个恶意电脑任务没有聊天基线；聊天设置的系统提示不同（附录 A.3 另列各家网页聊天界面），不是严格同条件。Linux 沙箱且给 sudo 密码，结论不外推到无特权部署。

来源 Tian, Zhang, Tang, Wang, Shi, Wen. *Measuring Harmfulness of Computer-Using Agents.* arXiv 2508.00935v3（§3、§4.1–4.4、附录 A–D，表 3–4）。

图标、通道图与账本格子排布为示意；数字为作者报告，「至少 N 条」与均值为我们按表格推算，未复现实验。