arXiv 2602.12276v2 · Lee, Erdogan, … Keutzer, Gholami (UC Berkeley / ICSI)

每步候选从 1 个加到 20 个，token 多花约 21 倍，真实网站上的成功率却从 22.6% 降到 15.1%

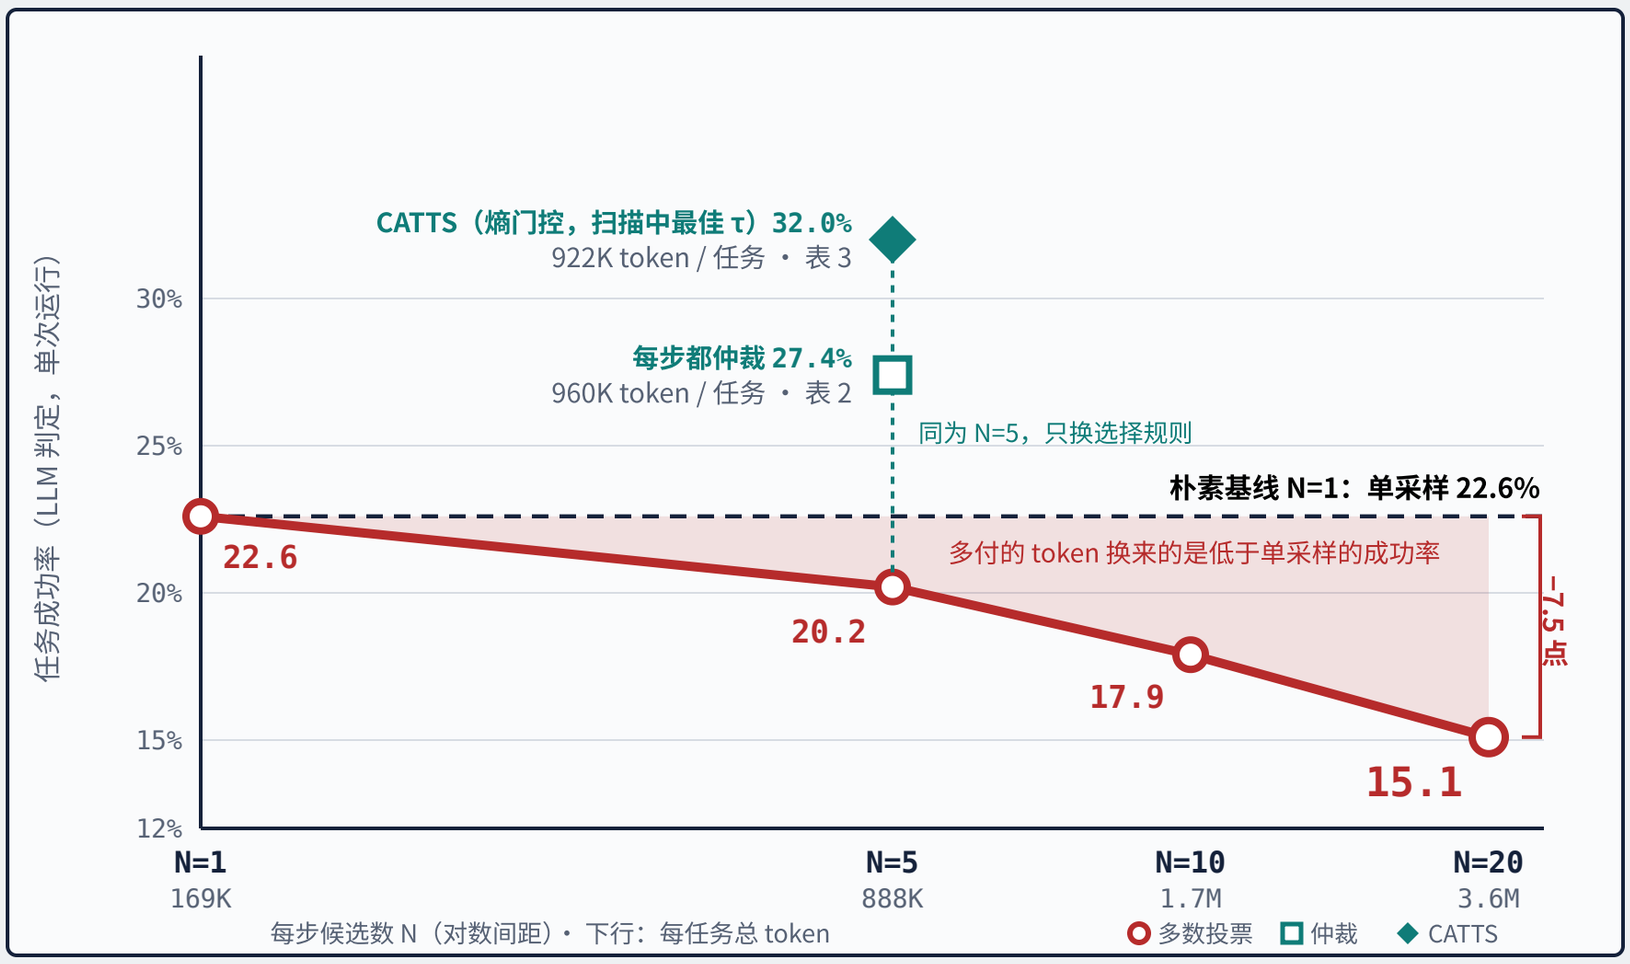
Online-Mind2Web 300 题 · gpt-oss-120b ReAct 代理 · 语义去重后多数投票 · 成本按全部调用的输入+输出 token 计

问题 把“多采样再投票”搬到网页代理：每步采 N 个候选动作，执行得票最多的。步骤一长，单步小错会累积；简单步骤多采只是重复。统一加采样，能换来更可靠的代理吗？

做法 固定代理与模型，只改每步候选数 N 和选择规则，成本全按 token 记账。再引入 LLM 仲裁者，最后提出 CATTS：用票分布的熵或前两名差距判断这一步是否有争议，只在有争议时请仲裁。

反单调曲线 · 同一代理，只加候选数

表 1 · 表 2–3（N=5 两点）· §3.2



WebArena-Lite

165 题 · 程序判定 · 3 种子



N=1→10 升 4.4 点，10→20 token 翻倍反降 0.2

GoBrowse

341 题 · LLM 判定 · 3 次



N=1→20 只在 86.9–88.0 之间（附录 M 表 12）

仲裁次数 K 也非单调

N=5 · 表 2

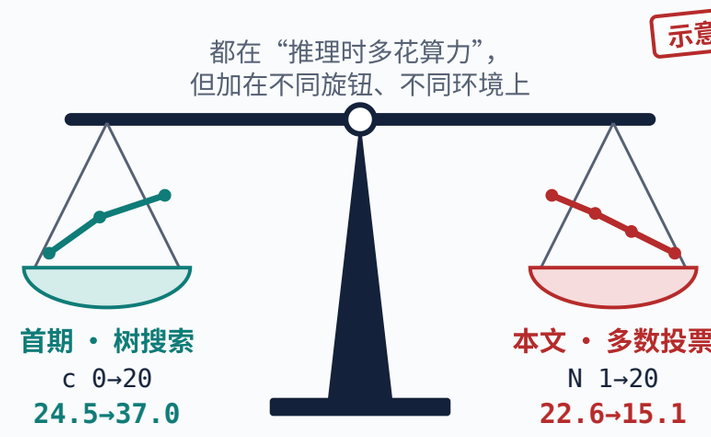
WebArena-Lite：K=10 **44.6** → K=20 **42.0**

Online-Mind2Web：K=10 **30.7** → K=20 **29.3**

K=20 的 token 为 1.4M / 2.8M

对照首期 · 加在哪里不一样

首期 2407.01476



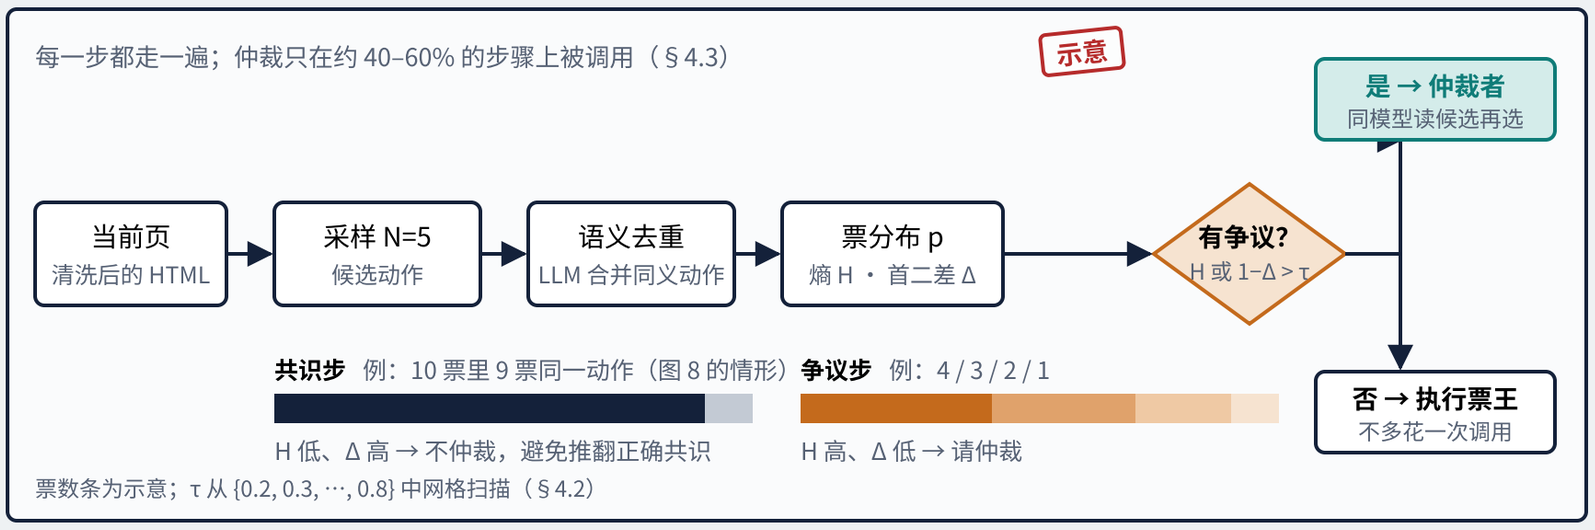
	首期树搜索	本文统一加采样
加什么	搜索预算 c（评分节点数）	每步候选数 N
怎么选	GPT-4o 价值函数 + best-first	语义去重后数票
回溯	有：重置环境再重放	无
环境	VWA 自托管，可重置	136 个真实网站
判定	程序检查	Qwen3-VL-30B
样本	200 题子集 · 单次	300 题 · 单次
趋势	上升	下降

阅读 不是同条件下的直接反证，两篇也不矛盾：首期在可重置环境里用价值函数挑分支，本文在真实网站上只靠数票。多花的算力要有能分辨好坏的选择器才可能变成成功率。

首期曲线本身也只测到 c=20、200 题子集、单次运行，作者用词是 “generally increases”；两条曲线都不宜外推到更大预算。

CATTS · 只在票分散的步骤请仲裁

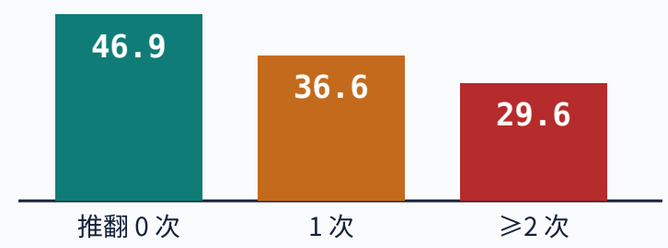
§4.2 式 9–10 · 图 1



为什么要门控

§4.1 · 图 3

495 个仲裁实验任务；按仲裁在**高共识步**（Δ>0.7）推翻多数票的次数分组：



任务成功率（%）。0 次对 ⩾1 次：46.9 vs 35.0，Fisher 检验 p=0.026；五类网站方向一致。按轨迹平均熵分组：熵 0–0.3 时仲裁净亏 4.4 点，更高熵时净赚 4–6 点。

这是对仲裁实验日志的事后分组，是相关性证据。

同为 N=5：换选择规则，不加候选

表 3 · 作者结果

	WebArena-Lite（3 种子）		Online-Mind2Web（单次）	
方法	成功率	token	成功率	token
多数投票	42.4%	460K	20.2%	888K
每步都仲裁（K=1）	42.8%	442K	27.4%	960K
CATTS 熵门控，最佳 τ	45.5%	409K	**32.0%**	922K
CATTS 差距门控，最佳 τ	**47.9%**	405K	30.0%	906K

原文 OMW 上 +11.8 点（对多数投票）、+4.6 点（对每步都仲裁）；WebArena-Lite 上 +5.5 点且 token 少 12%。把 τ 扫描中所有取值平均，WebArena-Lite 仍有 45.6%。

结论边界

我们的阅读

阅读 **可以确认**：在这套代理与成本口径下，每步统一加候选、按票选，不保证更可靠——WebArena-Lite 和 GoBrowse 很快走平，Online-Mind2Web 一路下降。

阅读 **还不能确认**：CATTS 的“最佳 τ”是在同一批测试任务上扫出来的；作者用 10% 任务做校准的自助法实验报告 regret ⩽1.1 点（附录 I），但没有独立的留出集。下降的原因“票被同义动作拆散”是作者的推测，主实验已做语义去重，仍然下降。

原文 换成 Plan-and-Act 代理（附录 E）也非单调：GoBrowse 上预算 1→8，83.3% → 80.6%。

限制与适用范围

§3.1 · 附录 C · 附录 I · 附录 N

1. **反单调曲线只跑了一次。**OMW 因算力限制单次运行，由 Qwen3-VL-30B 按 WebJudge 协议判定；未报告该判官与人工的一致率和方差。
2. **只改了“单步候选 + 选择规则”。**无价值函数、无回溯，不是整轨迹搜索；观察为 HTML 文本，主实验只用 gpt-oss-120b。
3. **阈值靠扫描。**表 3 取扫描中最好的 τ；换模型后 τ 也要重选，附录 N 的 Gemini、Qwen 只测了 WebArena-Lite。
4. **不是“算力越多越差”。**WebArena-Lite 上 N=1→10 仍升 4.4 点。结论是“统一加不保证更好”，不是反向的单调规律。

来源：Lee et al., *Agentic Test-Time Scaling for WebAgents*, arXiv 2602.12276v2（HTML 版 2026-08-14）：§3.1–§4.3、表 1–3、图 3、附录 C、D、E、I、M、N。初筛：run gui-pc11-20261022-01，selection2.md 第 3 篇，L2 见 batches/l31.jsonl。**原文** = 作者报告的结果 · **阅读** = 我们的判断 · **示意** = 自绘：CATTS 流程图、票数条、天平与图标是示意，不是论文图 1 / 图 8 的复刻。首期数值取自 2407.01476v4 §5.1（200 题子集）。没有运行论文代码，也没有复现实验。