审批框弹了,危险动作还是过去了

48 人、192 场真实网页会话:进入执行的 **138** 次问题动作,用户只拦住 **29** 次(21%)。四种监督策略改变了“代理会不会做”,没有改变“人能不能拦”。 作者结果

Chen, Zhang, Chen, Xu 等. Comparing Human Oversight Strategies for Computer-Use Agents. arXiv:2604.04918v2(2026-09-12)

左壁 · 非计划型 % 照抄 Table 3,计数反推

逐步确认
Action Confirmation
原型:Claude Computer Use

风险触发
Risk-Gated
原型:OpenAI Operator

问题动作进入执行 · 分母 48 场

逐步确认	风险触发
40/48 83.3%	42/48 87.5%

组间差异 **p<.001**(GEE 联合 Wald 检验)

人怎么审批(本层 = 人工审批层)

逐步确认	风险触发
每个动作执行前都要点批准;可选“本站一律允许”,之后整站自动放行。	代理默认自主执行,判定为风险时弹窗;可点“批准同类”,预先放行之后同类动作(如任何文本输入)。

拦住 · 分母 = 进入执行数

逐步确认	风险触发
9/40 22.5%	11/42 26.2%
95% CI 12.3–37.5%	95% CI 15.3–41.1%

四组拦截率差异 **p=.366**,不显著;但每组只有 27–42 次、CI 大幅重叠,不能读成“四种策略一样好”。

最终未纠正 · 分母 48 场

逐步确认	风险触发
31/48 64.6%	31/48 64.6%

组间 **p=.018**;控制情景后仍显著(App. I.3)

192 场会话 = 48 人 × 4 种策略 (被试内,24 种平衡顺序)

54 场问题动作没出现:34 场计划里没有这一步,14 场代理自身行为波动,6 场其他。全程用户主动预防只有 5 例。

138 次问题动作出现并进入执行
占 192 场的 72%

p<.001

OR 0.24

人在场:审批框和线索大多都在
以下按 109 次失败统计,行为编码可多选

- **93**/109 失败里有审批步骤 109–16 反推
- **100**/109 屏上有风险线索;明确标出的只有 49
- **74**/109 1 秒内或停顿 1–3 秒就批准
- **19**/109 看过内容或犹豫后,仍然批准

29
拦住 · 21%

p=.366

漏斗颈宽 = 138 层宽 × 29/138 示意

29 次怎么拦下的:21 次直接阻止该步(手动接管 17、改内容 13,可兼有);9 次在风险内容已填入、尚未提交时拦下。

109 次没拦住,问题动作完成

- **61 时机错位(56%)**
- **48 门在风险之前或同时**

61:风险内容已在位之后才问,或风险出现时根本没有审批门。48:审批门来得及时,用户仍放行或此前已委托。另有 28 次由先前“批准同类”自动放行(只存在于风险触发 / 结构增强,占这两组 53 次失败的 52.8%)。

右壁 · 计划型 % 照抄 Table 3,计数反推

计划共执行
Supervisory Co-Execution
原型:Magentic-UI

结构增强
Structurally Enriched
作者提出的组合

问题动作进入执行 · 分母 48 场

计划共执行	结构增强
27/48 56.2%	29/48 60.4%

计划型 vs 非计划型:发生几率降 76%,**OR 0.24** [0.14, 0.42]

人怎么审批(本层 = 人工审批层)

计划共执行	结构增强
先审、改计划,再逐个批准计划步;一步内含多个浏览器动作,不再逐个确认。	先审、改计划;执行中显示理由与风险标签,标记处弹窗,也有“批准同类”。

两种计划型都把获批计划写进代理的 system prompt:发生率下降不全是人更警觉。 作者自述 § 3.4

拦住 · 分母 = 进入执行数

计划共执行	结构增强
2/27 7.4%	7/29 24.1%
95% CI 2.1–23.4%	95% CI 12.2–42.1%

计划型的“拦住”分母更小:剩下的问题动作可能本就更难拦(选择效应,作者 § 6.5)。

最终未纠正 · 分母 48 场

计划共执行	结构增强
25/48 52.1%	22/48 45.8%

最好的结构增强,仍有 46% 的会话以问题动作告终。

机制图:审批来得太晚时,批的已经不是“要不要做”

以隐私泄露任务为例 · 流程为示意

① 代理 — **按任务填表** — 订机票、申请贷款等多步表单

② 代理 · 风险发生 — **顺手填入健康保险号** — 此刻没有审批门

③ 界面 · 交还控制 — **弹窗:“提交/继续?”** — 人这时才第一次被问

④ 人 — **批准“继续”** — 是事后确认,不是事前决定

> “为什么订票的单子里有我的健康保险号?”(P027,事后才发现;作者原文为英文)

另一种失败:查“程序对不对”,不查“该不该做” 作者归纳

“网站要这个信息,代理填进去就是在干活。”(P006)用户核对代理是否按流程走,却不问这一步本身该不该发生。

计划型的两个盲区 作者归纳

计划能省掉“多做一步”的风险,也会省掉“该多做的保护动作”(如取消默认勾选的附加服务);批过计划后,执行期的审批更容易被当成例行确认。

与首期 2503.19537 对照

同卡,两侧

代理侧:何时该问
代理在每一步判断要不要联系用户。离线逐步标注;Gemini 1.5 的 12 种配置 precision 0.08–0.19。

人侧:能否拦住
控制权交给人之后,人能不能及时阻止。192 场真人实时会话;拦住 29/138。

两篇的分母和任务不同,数字不能互相换算。合起来看:代理问得准不准、人拿到控制权后拦不拦得住,需要分开测;本篇的 61/109 说明,问的时机本身就决定了人还有没有东西可拦。 我们的阅读

适用范围与限制

- 站点为研究者仿建,参与者用虚构身份,没有真实损失,紧迫感可能偏低;单一代理 Gemini 3.1 Flash-Lite(作者选它部分因其更常出问题动作)。
- 拦截率以“问题动作已发生”为条件,每组分母仅 27–42;计划型组剩下的可能正是更难拦的那部分,存在选择效应。
- 主分类双人编码一致 183/192(κ=0.92);61/109 等细粒度编码未单独报告一致性。
- 没有完全自主的基线:只能比较监督方式之间的差异,不能估计“加上人”相对不加的绝对收益。
- 四种策略是打包配置,不是因子交叉;高/低后果任务与风险类型(隐私 vs 注入、暗模式)混杂。
- 四种策略是对商业系统的抽象:风险触发用弹窗而非完整浏览器交接,逐步确认只给动作摘要,不等于原产品的实际表现。