arXiv 2606.12666v2 · cs.CR · 2026-06

截图上传前，遮住无关的隐私，留下任务要用的

CAPED：移动 GUI 智能体的上下文感知隐私暴露防护（Shen, Xu, Diao, Zhang）

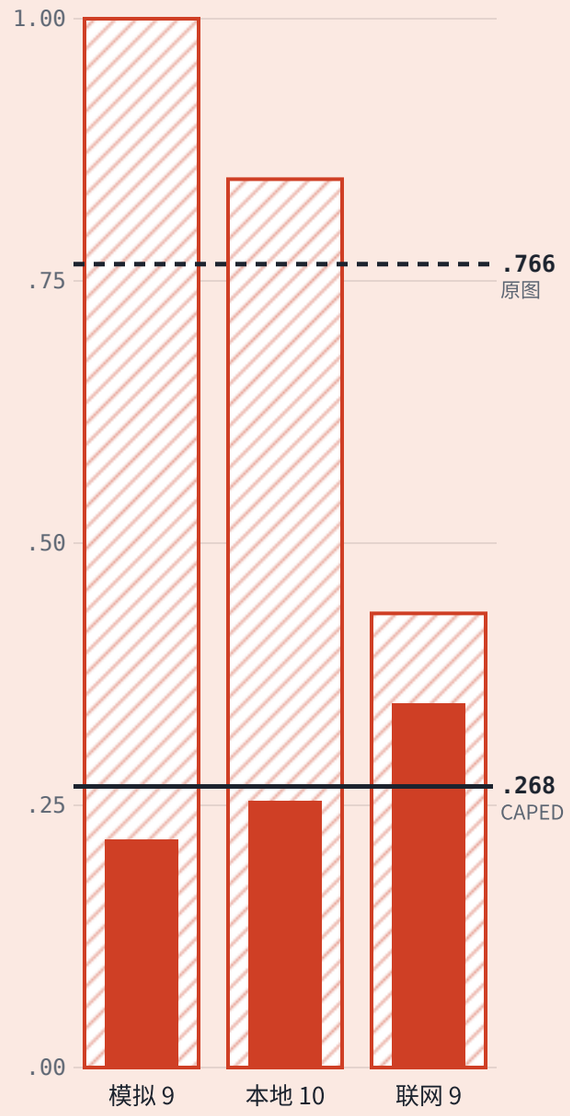
> 远端多模态模型每一步都拿到整屏截图。用户只要求“把海滩照片发给 Bob”，截图里却还有别的联系人、消息预览、无关照片和健康提示，作者称之为**顺带的视觉隐私暴露**。把敏感区域全部遮掉，又会挡住智能体找目标、点按钮要用的画面。所以要决定的不是“这块敏感吗”，而是**这块在这个任务、这一屏里需不需要**。

泄漏率 WSLR ↓

任务无关的预置隐私中，远端仍能从轨迹读出的加权比例（只算完全成功的运行）

~~.766~~ **.268** −0.498

粗线 = 28 任务总体值；三栏 = 三类应用



	模拟 9	本地 10	联网 9
原图	1.000	0.847	0.433
CAPED	**0.217**	**0.254**	**0.347**

斜线框 = 原图（No Protection），实色 = 完整 CAPED。28 任务 × 5 方法，表 III / IV。

① 本地读任务（每条指令一次，原文不出手机侧）

“把海滩照片发给 Bob” → `{相册, 海滩照片, item}`

`{消息, 〈人物_1〉, person}`

实体换成占位符；三元组只写“需要什么”，不写它在屏上哪里。示意

手机侧看到的原屏



遮蔽窗口
逐元素决定
露 / 遮 / 换名

远端收到的截图



遮蔽　任务需要 → 放行　功能控件保留　（界面为示意）

被遮掉的：无关照片、其他联系人、消息预览 → 左柱泄漏下降

被放行的：目标照片、占位符联系人、按钮与布局 → 右柱效用没掉

每一屏：先给默认姿态，再按任务逐个放行 §III，图 3

② **屏幕上下文先验**：按包名 / Activity 定级 Public 全露 · Privacy 遮图（相册、文件、金融）· Text-Privacy 文字图像都遮（消息、联系人、信息流、健康）

③ **解析元素**：OCR + UI 检测切成 文本 / 图标 / 图像 框，图标多为控件

④ **元素核验**：文本按名称匹配或本地语义相关放行；图像要过 VQA 核对主体或导航作用才放出像素

⑤ **渲染**：放行原样、遮蔽区块、或同一套占位符；被遮内容可在动作需要时临时揭开并记录

设备—云边界 ---------- **只放出：匿名任务 + 遮蔽后截图**

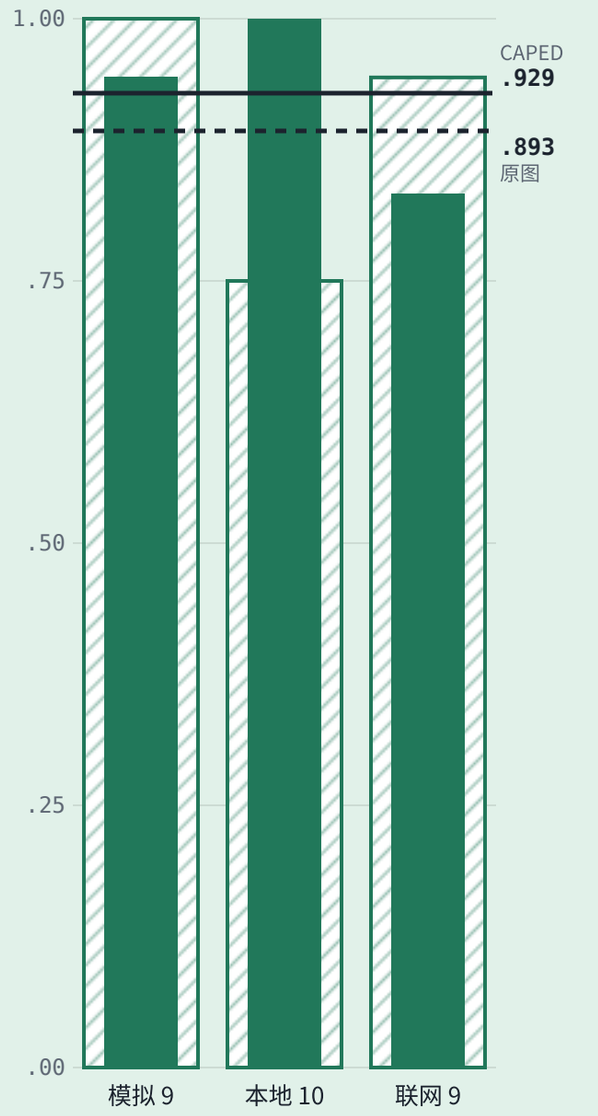
远端 GUI 智能体（评测用 GUI-Owl-7B）：按协议返回动作，但“诚实而好奇”，可能留存、查看收到的截图。

任务效用 ↑

预置隐私任务的平均得分（含 0.5 部分得分，全部运行都计入）

~~.893~~ **.929** +0.036

粗线 = 28 任务总体值；三栏 = 三类应用

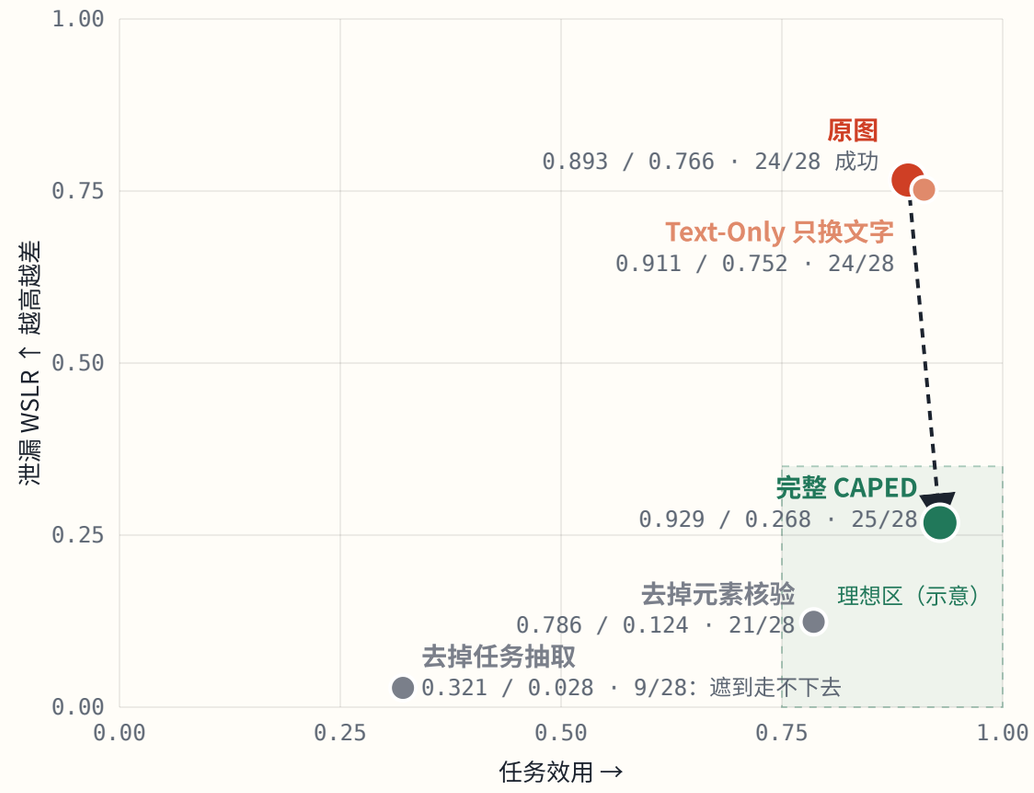


	模拟 9	本地 10	联网 9
原图	1.000	0.750	0.944
CAPED	**0.944**	**1.000**	**0.833**

均值微升只是描述：28 任务里 23 个与原图同分，联网应用反而 .944→.833。

隐私与可用性绑在一起：五种方法

作者结果（表 IV）。横轴效用，纵轴泄漏；理想点在右下。只遮得多不算赢。



我们的阅读：结论成立的范围

- **泄漏的分母不同**：WSLR 只在完全成功的运行上平均，原图 24/28、CAPED 25/28，比较的不是同一批轨迹。作者另给不加权口径：.773 → .288，方向一致。
- **广义效用有代价**：AndroidWorld 116 任务，原图 77（66.4%）→ CAPED 64（55.2%），差 11.2 个百分点；19 个退步里作者把 7 个归为受 CAPED 影响的轨迹。预置隐私任务上的“微升”不能外推。
- **联网应用只有 9 个任务**：WSLR .347，对 Text-Only 的 .402 相对降 13.7%，作者自己说是趋势证据。
- **残余泄漏主要来自开放式任务**（“看最新一封”“浏览最近照片”）：13 条事实、权重 33/80；未覆盖的 App 默认映射为 Public，偏可用、不是隐私保守。
- **不是手机实测**：原型在 AndroidWorld 主机/服务端运行；每步隐私组件 2.325 s，占 22.6%（主要是检测器 1.811 s）。泄漏由 gpt-5.4 按预置事实表判定。
- **判官较稳，但只认可见证据**：28 条轨迹重复判 3 次，136 个条目仅 1 个翻转（0.74%）；跨屏组合推理作者自认只部分覆盖。

来源：arXiv 2606.12666v2（2026-06-16）§I–IV、§VI-A，表 I/III/IV/V/IX，附录 A/D。WSLR＝任务无关预置隐私中被读出的加权比例（权重 1/2/3），已剔除任务本身需要的信息。−0.498、+0.036 为我们按表 IV 相减。

原图　CAPED　阅读判断　示意

run gui-pc11-20261022-01 · P3 · capability · F4,F0 · 未分配主卡 · 我们未复现，数字均为作者报告。