下一屏只给教师看，学生部署时照样不看未来

GHD（门控事后蒸馏）：同参数教师在训练时多看一张真实的下一屏，只在**学生失败、且教师复原出示范动作**时，才把它的逐 token 分布蒸馏给只见前缀的学生。

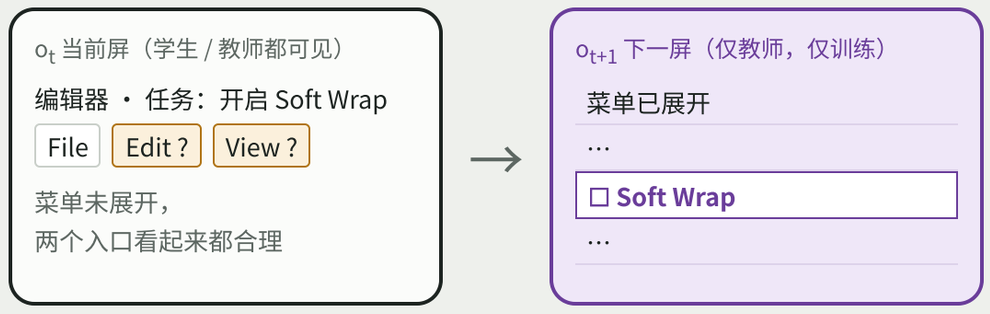
Gated Hindsight Distillation
arXiv 2608.06065v1 · 2026-08-06
The Next Screenshot Knows

实线框 = 作者报告　虚线红 = 我们的阅读判断
图标 / 手机屏 / 管道 = 自绘示意

① 问题 · 动作标签只记“点了什么”，理由在下一屏

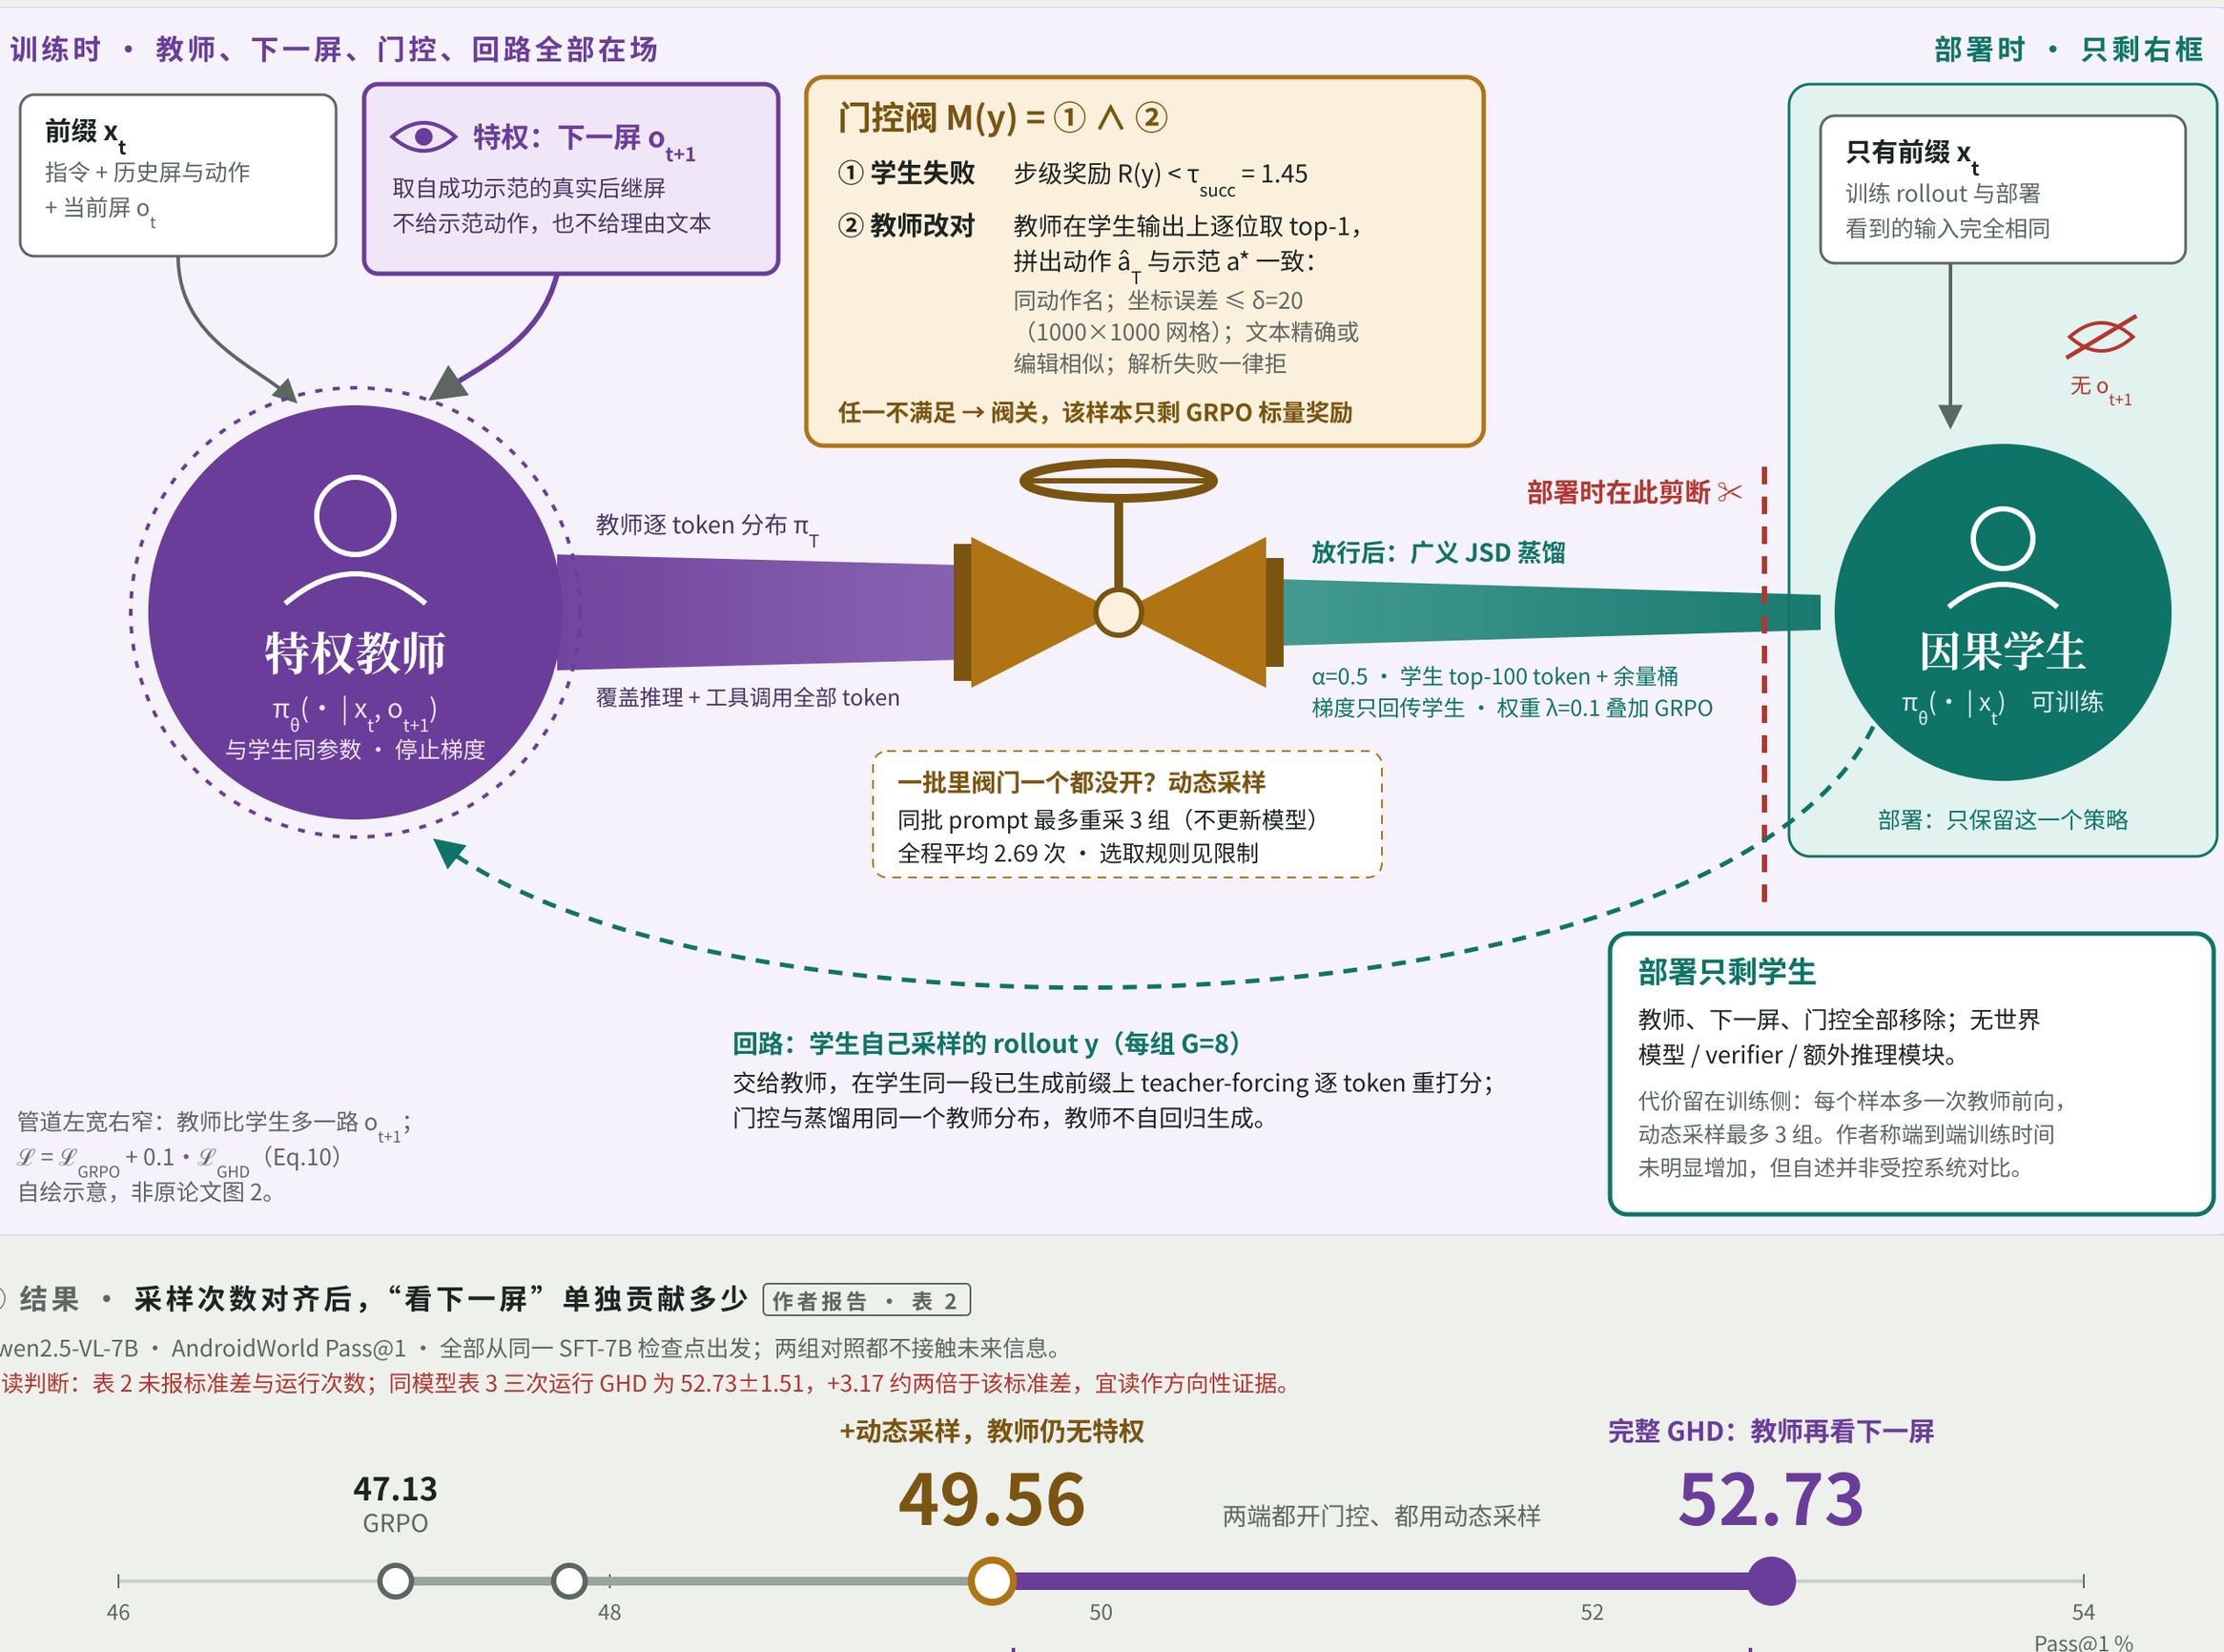
离线训练把成功轨迹切成“前缀 → 动作”对，**下一屏 o_{t+1} 被丢掉**。可很多动作的依据恰恰只出现在点完之后：想开 Soft Wrap，菜单打开前看不出该点 Edit 还是 View。标量 verifier 奖励只说对错，不说为什么。

问题因此变成：**训练时让教师看下一屏**，能不能教会一个部署时只看过去的**因果学生**，而不把“偷看未来”的依赖带进部署？



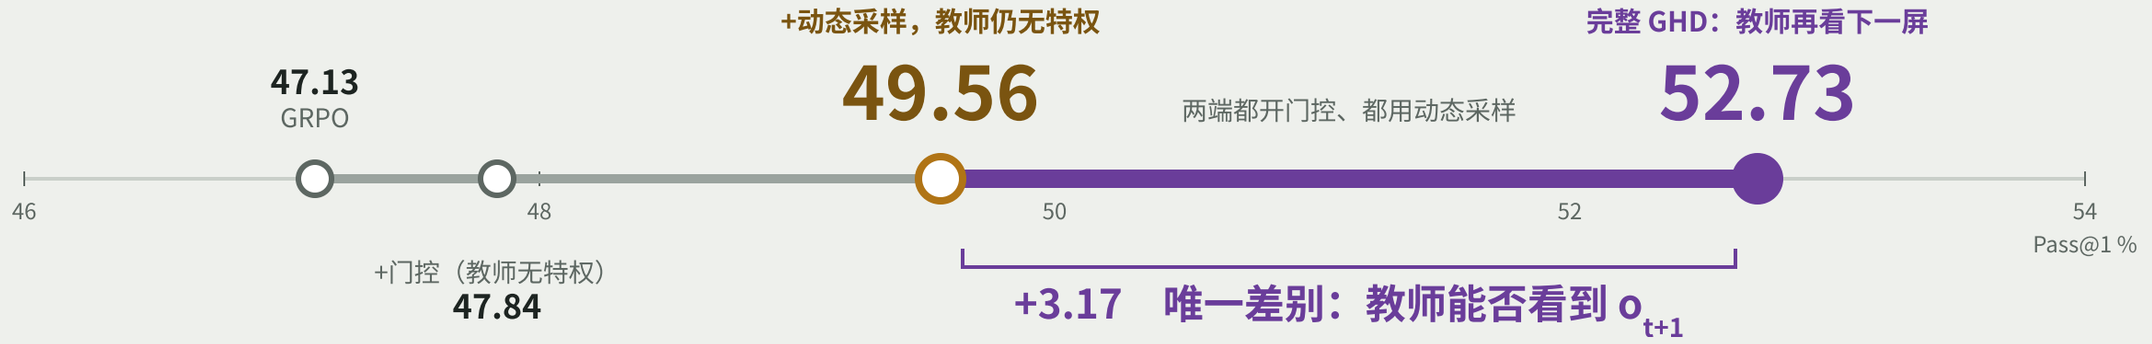
示意：例子取自摘要 Soft Wrap 一句；界面为自绘，非原文截图。

② 关键动作 · 不对称信息管道 + 门控阀（自绘示意；依据 Method 节 Eq.5–10、图 2）



③ 结果 · 采样次数对齐后，“看下一屏”单独贡献多少　作者报告 · 表 2

Qwen2.5-VL-7B · AndroidWorld Pass@1 · 全部从同一 SFT-7B 检查点出发；两组对照都不接触未来信息。
阅读判断：表 2 未报标准差与运行次数；同模型表 3 三次运行 GHD 为 52.73±1.51，+3.17 约两倍于该标准差，宜读作方向性证据。



另一组同条件对照 · Qwen3-VL-8B　作者报告 · 表 3、表 5

方法（三次独立运行 均值±std）	AndroidWorld	AndroidLab
SFT（同起点，单值）	59.05	39.13
GRPO	61.35±1.08	37.43±0.42
GHD 无动态采样（与 GRPO 同 rollout 预算）	63.64±2.04	51.93±0.84
GHD	**66.47±0.68**	**54.11±1.11**

同数据 / verifier / 评测环境。Pass@1 为交互式模拟器任务成功率；训练本身是离线轨迹 + 步级 verifier，非在线 RL。

限制 · 阀门只验证“动作对上”

门控只检查教师逐位拼出的**动作**是否与示范一致；但放行后蒸馏覆盖**全部 token，含推理**（Eq.7）。动作一致不能证明教师的理由真实，错误解释可能随正确动作一起被教给学生。　阅读判断

- 训练集为 SFT 一次未解出的难子集（27,360 → 6,968 / 5,982），截图降至 420×896；结论限于此配方。
- 动态采样规则原文两处不一：方法节“首个含放行样本的尝试即停”，表 5 图注“保留门控监督最有用的一次”。
- 8B 上 GRPO 在 AndroidLab 低于 SFT（37.43 vs 39.13），AL 大增益需结合这一弱基线看。