CUA-Daily · GUI 定位测量审计　2608.21794v1 · cs.CL

检索器把 UI 元素排到第一，有多少只是在“认出目标上的那几个字”？

Lexical Coupling in GUI Element Grounding: Sentence Embeddings Track Labels across Mobile and Web

Qijia Chen & Giulio Jacucci（赫尔辛基大学）· arXiv 2026-08-22 · 作者定位：评测方法审计，不提出新的 grounding 模型

关键研究动作：固定同屏候选集，一次只改一处

- 每个动作步 = 一次**同屏排序**：同一指令，候选为当前屏全部可见元素（AndroidControl 中位 62 个）
- 词法（BM25 / Jaccard）与 5 个现成句向量编码器读**同一份元素文本串**
- 逐层施加条件：遮蔽目标文字 · 换成无标签目标 · 多检索器融合
- 配对差全部用 episode 簇 bootstrap（B=2000）给 95% 区间

示意 · 非原文图



遮蔽条件 × 检索器 级联矩阵

数值均为 R@1（目标排第一的比例）　词法　现成编码器　微调　相对本层参照丢失的部分

	词法	现成单向量句编码器（22M–0.6B）					任务微调
	BM25 每屏独立 IDF	**MiniLM** 22M	**MPNet** 110M	**BGE-large** 335M	**E5-large** 335M	**Qwen3-Emb** 0.6B	**MiniLM-ft** 对比学习 1 轮
0 原样排序 AndroidControl clean-main，**n=32,646**（表1） 随机 .022 · Jaccard .547 BM25 高于全部 5 个编码器，配对区间均不含 0（附录 E）	**.557** 最高	.489	.467	**.520** 编码器最高	.507	.481	不在此集评测（见层 1′）
1 隐藏目标的可见文字 只清空目标的 text 与 content_description，查询与非目标不动 等配额三层抽样 **n=3,000**（附录 G 表6） 虚框 = 同批样本遮蔽前	**.125** 原 .508 **−.383**	.165 原 .487 **−.321**	.139 原 .434 **−.296**	.188 原 .503 **−.315**	.159 原 .470 **−.311**	.251 原 .466 **−.216**	未在此样本评测
1′ 同一遮蔽 · 微调对照 完整对照 held-out 测试子集 **n=2,949**，同协议（表11–12） 微调后未遮蔽 .694，比 BM25 高 13.6pp LCC 仍为 **.877**（零样本 .865）	**.134** 原 .558 **−.423**	.178 零样本 原 .518 **−.340**	本层只测 BM25、零样本 MiniLM 与微调 MiniLM				**.151** 原 .694 **−.542** CI [−.562, −.520]
2 目标天生没有可读标签 全部 DB 行按目标标签类型分层（表2） 虚框 = 只有可见文字 **n=21,539** 实柱 = 只有 resource_id **n=9,669**；末行 = 无任何标签 n=13,132（随机 .027）	**.064** 文字 .624 无标签 .013	.085 文字 .520 无标签 .016	.085 文字 .504 无标签 .011	.099 文字 .563 无标签 .006	.095 文字 .552 无标签 .006	.124 文字 .507 无标签 .020	未分层报告

3 把检索器合起来

clean-main **n=32,646**（表8，此表 BM25=.555）
灰 = 目标感知 oracle：每步挑排得最好的检索器，**知道答案，不可部署**
绿/红 = 真实 RRF 融合（可部署）



+.151 vs −.009

同一组 7 个检索器：oracle 说明嵌入确有 BM25 漏掉的信号；但标准 RRF 合起来反而掉分（作者称“破坏性融合”）。验证集调参的线性融合在 4 个编码器上只多拿回 +1.5–2.8pp，BGE 为 0，远低于各自 oracle 的 +6.0–6.9pp（附录 J）。

作者结果（原文主张）

- 现成句向量相似度单独不能当作语义 grounding 证据：命中可由词法秩、候选池大小、标签类型预测，LCC 在三语料为 .825–.882
- MoTIF、Mind2Web 上同样没有编码器在 R@1 显著超过 BM25
- 建议报告：同池词法基线、按标签类型分层、目标文字遮蔽、oracle 与可部署融合分开报

我们的读法（非原文结论）

- 原样条件下 BM25 压过全部现成编码器；拿掉目标文字后（层 1、层 2）所有方法一起塌落，编码器虽略高于 BM25，仍远低于有文字时——“高相似度”首先是“标签被认出”
- 微调确实把 R@1 拉高，但遮蔽后跌得最多：提升主要还附着在目标文字上
- 读 GUI agent 的文本元数据定位分数时，先找同池 BM25 和分层结果再谈“语义”

明确限制

- **只评文本排序**：候选是无障碍树 / DOM 文本，不是截图、OCR 或像素级 grounding，也不评在线 agent 行为
- 遮蔽需先知道哪个是目标，属诊断操作而非部署场景；层 1 为等配额抽样均值，非语料加权
- LCC 是描述性 AUC，不是因果量；仅测单向量编码器与 RRF / 线性融合

数值来源：2608.21794v1 表1、2、6、8、11–12 及 §4.1–4.5、附录 E/G/J/K、Limitations；各层样本与分母不同，只比较同一层内的跌落，不跨层比较绝对值。全部图形为依据原文数字自绘（含“示意”屏幕），未使用原文图片；本画报只阅读原文，未运行代码，不构成复现。CUA-Daily · gui-v3-20261022-01