测试全过，成片仍输：剪辑代理过得了规格，过不了剪辑师

56 个真实剪辑任务（原始素材 + 简报 → 成片），16 个代理各跑 1 次。771 个未解决运行里 **562 个通过了交付、内容和简报的全部测试，只差质量门**。质量门由三位多模态判官打分，按 43 位剪辑师 2,582 次盲评校准：**在代理这一级与人一致（ρ=0.93），单片只有 κ=0.15**。同一 GPT-6 Astra 改为看屏幕、用键鼠在 DaVinci Resolve 里剪：**解决 2/56，代码版 12/56**。

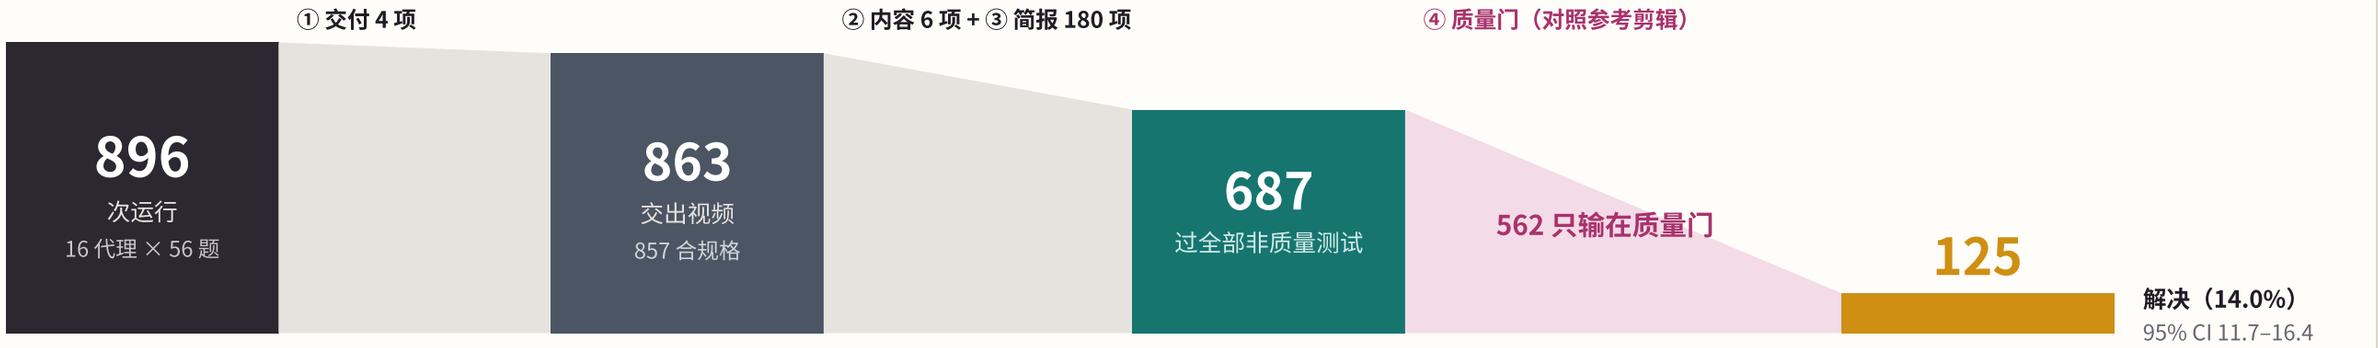
562 / 771

未解决的运行中，**只**输在质量门（73%）；16 个代理里 15 个的失败有 61–90% 属于这种。

§6 · 图 4a · 每个代理 56 题各 1 次，共 896 次运行

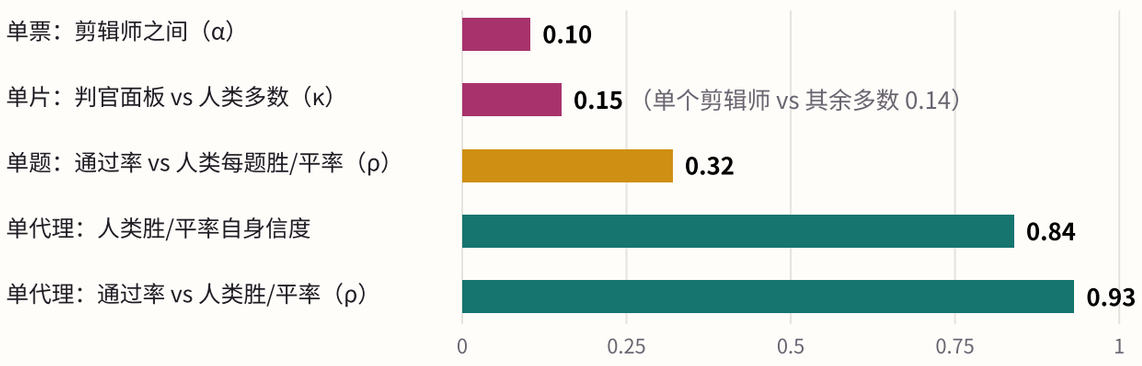
01 四道门：前三道查“做没做到”，第四道查“好不好”

§2.2、§3.1、§3.3、附录 C–E、J.1；数字为全部 16 个代理合计



02 质量门在哪一级可信

§3.2–3.3、§5、附录 D.3–D.4、G.1

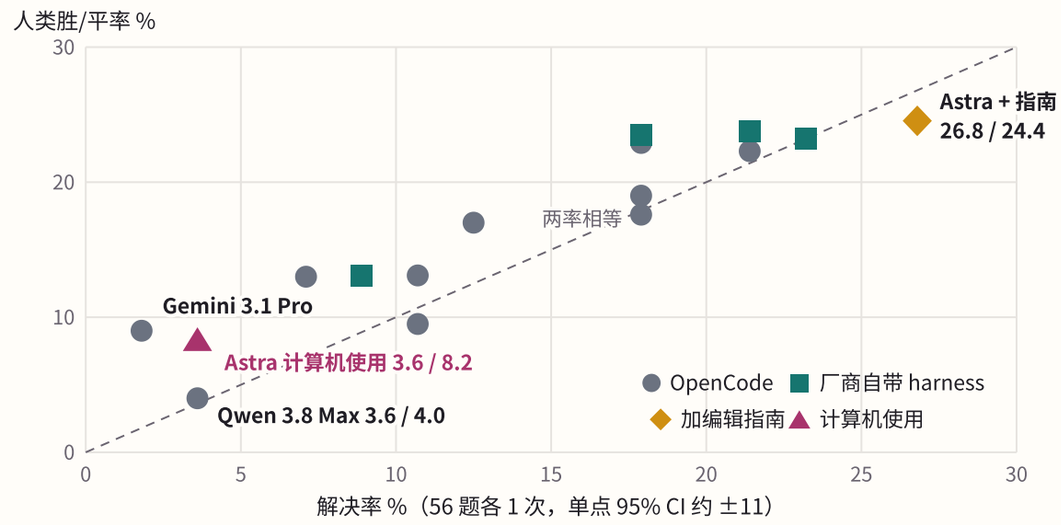


统计量不同（α / κ / ρ / Spearman–Brown 信度），只比较量级；0.93 为阈值留一代理重拟后

阈值规则：让每个合集的通过率尽量接近、但**不超过**人类胜/平率。所以它适合给代理排名，不适合判某一条成片好不好——作者在限制节也这样写。判官之一 GPT-6 Astra 同时是被测代理的模型。冻结阈值（判官标准差）：Cinestudy 0.30 · Commercial 0.52 · EditStock 0.21 · UGC 1.54；全部为正，代理片须**高于**参考片才通过。

03 16 个代理：解决率 vs 人类胜/平率

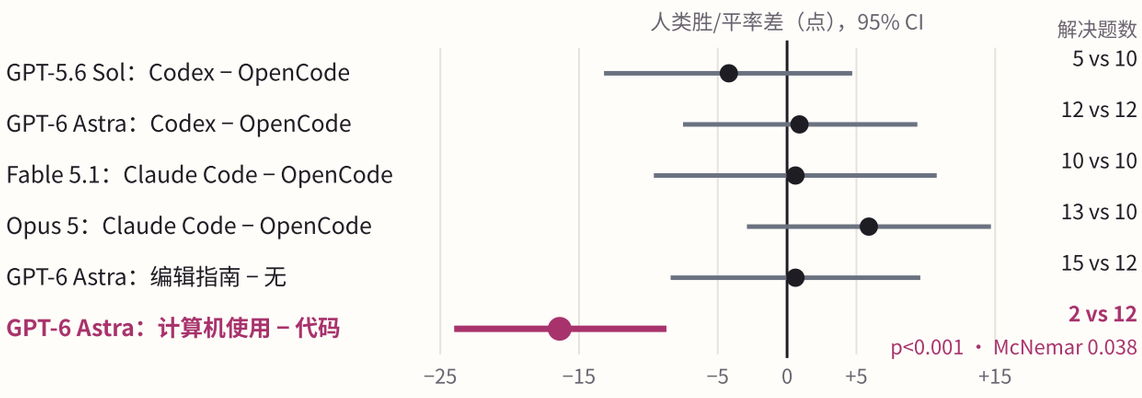
§5 表 1、附录 I 表 8



35 题没有任何代理解决（若成功随机分布约 5 题）；Rasch 模型中题目难度方差是代理能力的 2.6 倍（附录 J.3）。

04 只改一个部件的配对对照

附录 I.1 表 9 · 前者减后者



换 harness、加 1,909 字编辑指南都分不出差别（Holm 校正后 p=1.00）；只有“计算机使用”一项显著更差：−16.4 [−24.0, −8.7]，n=53。

05 计算机使用这一臂差在哪

§4.1、§6、附录 B、H.3、J.1–J.2

GPT-6 Astra，同一批简报	屏幕 + 键鼠（Resolve）	代码（Codex CLI）
解决 / 人类胜 · 平	**2/56 · 8.2%**	12/56 · 23.8%
漏掉简报要求的台词	**41.5%**	5.9%（全部代码代理）
输掉的片里留了场记板 / 现场对话 / 重拍	**18.5%**	1.4%（人评前 6 的代理）
输掉的片里有重复素材	**18.5%**	3.6%（同上）
运行时长中位 / 每次成本	52.7 min · $41.61*	19.6 min · $8.71*

不是只换界面：macOS + Resolve 免费版（项目与素材已导入）vs Linux 容器 + FFmpeg / Remotion / 转写命令；没有 shell；作者写明它“听不到声音”。所以只能读作“这一套计算机使用配置在这批任务上更差”，不能归为 GUI 操作本身。*Codex 按 token 估价。

06 代理在检查什么

§6、图 5、表 2、附录 J.2、K.3 · 15 个代码代理的 111,636 个动作

54% · 17% · 9%

动作用于**看素材 · 查自己的渲染 · 搭剪辑**。98% 的看素材发生在第一次渲染之前，第一次渲染出现在运行的 72–90% 处。素材多以静帧（83% 的读取）和转写来“看”。

5.5% vs 66%

自查后报告修复的问题里，涉及**节奏、故事、选镜**的只占 5.5%；剪辑师的评语里占 66%。15 个代码代理中 14 个在 86–100% 的运行里自查过，查的是缺陷。

93% · 95.5%

最终消息声称“全部完成”的运行占 93%；在**没过某项测试**的片子里也有 95.5% 这样声称（由 Claude Opus 5.5 标注、作者核对）。

0.72× · 1.5×

按题配对：代理换镜头频率是参考剪辑的 0.72 倍，最长静止镜头 1.5 倍。换镜频率低于参考时每减半，胜/平率掉 6.6 点（95% CI 3.2–10.0）；切得更快不扣分。

07 作者的能力读数

§6 表 2（作者归纳；括号内为我们摘的证据）

交付与显式要求 — 可靠
857/863 合规格；762 过全部简报测试

声音 — 只能借工具
漏台词 5.9%；计算机使用 41.5%

时间线整洁 — 大体可靠
前列代理落败中 1–7%；计算机使用 18.5%

检查自己的剪辑 — 只查缺陷
86–100% 自查；5.5% 关乎节奏故事选镜

判断自己的剪辑 — 缺失
93% 声称成功，含 95.5% 未过测试者

故事组装 — 初现
代理获胜多靠故事；叙事场景合集最好 28.7%

节奏与选镜 — 弱
换镜 0.72×；29% 的落败评语提选镜

收尾 — 弱
图形、转场、声音、调色：19–47% 评语称参考更好

限制与证据边界

- **每代理每题 1 次。**单代理解决率 95% CI 约 ±11 点，前几名分不开；未含运行间方差。
- **质量门的校准与验证共用同一批人类票**（留一代理缓解）；单片 κ=0.15，不能当逐片真值。阈值整体下移 0.1 个标准差会多解决 27 个运行，排名基本不变（ρ=0.96）。
- **判官与被测重叠：**GPT-6 Astra 既是判官也是最佳代理的模型；人评另报，二者趋势一致。
- **参考剪辑是专业作品，不是认证真值；**剪辑师不看简报，只看一行受众与用途说明。
- 计算机使用只有 1 个配置，OS、工具、听觉通道同时不同。

我们的读法

- 改变的是**反馈 / 评价**这一环：在没有唯一正确产物的长程任务里，“过全部规格测试”不等于完成；任务完成率需要一个按人校准、并写明有效层级的质量信号。
- 代理的自查只覆盖它“看得到”的通道（静帧、转写、响度），所以只查得出缺陷；计算机使用臂连声音都没有。
- 主卡 online_evaluation_methodology、learned_outcome_and_process_judges；问题族 F2。
- 可读顺序：§3 → 图 4 → 附录 D.3–D.4 → 表 9 → §6。