只编码一次截图,够不够?

ReLaViS:在同一份视觉 token 上循环收拢空间注意力,4 步后读出点击坐标

基于 **Qwen2.5-VL-7B** · GroundCUA 随机 **100K** 训练 · 单轮交互,推理时不裁图、不重编码、不用框标签或 UI 树 · 仅静态点击定位评测

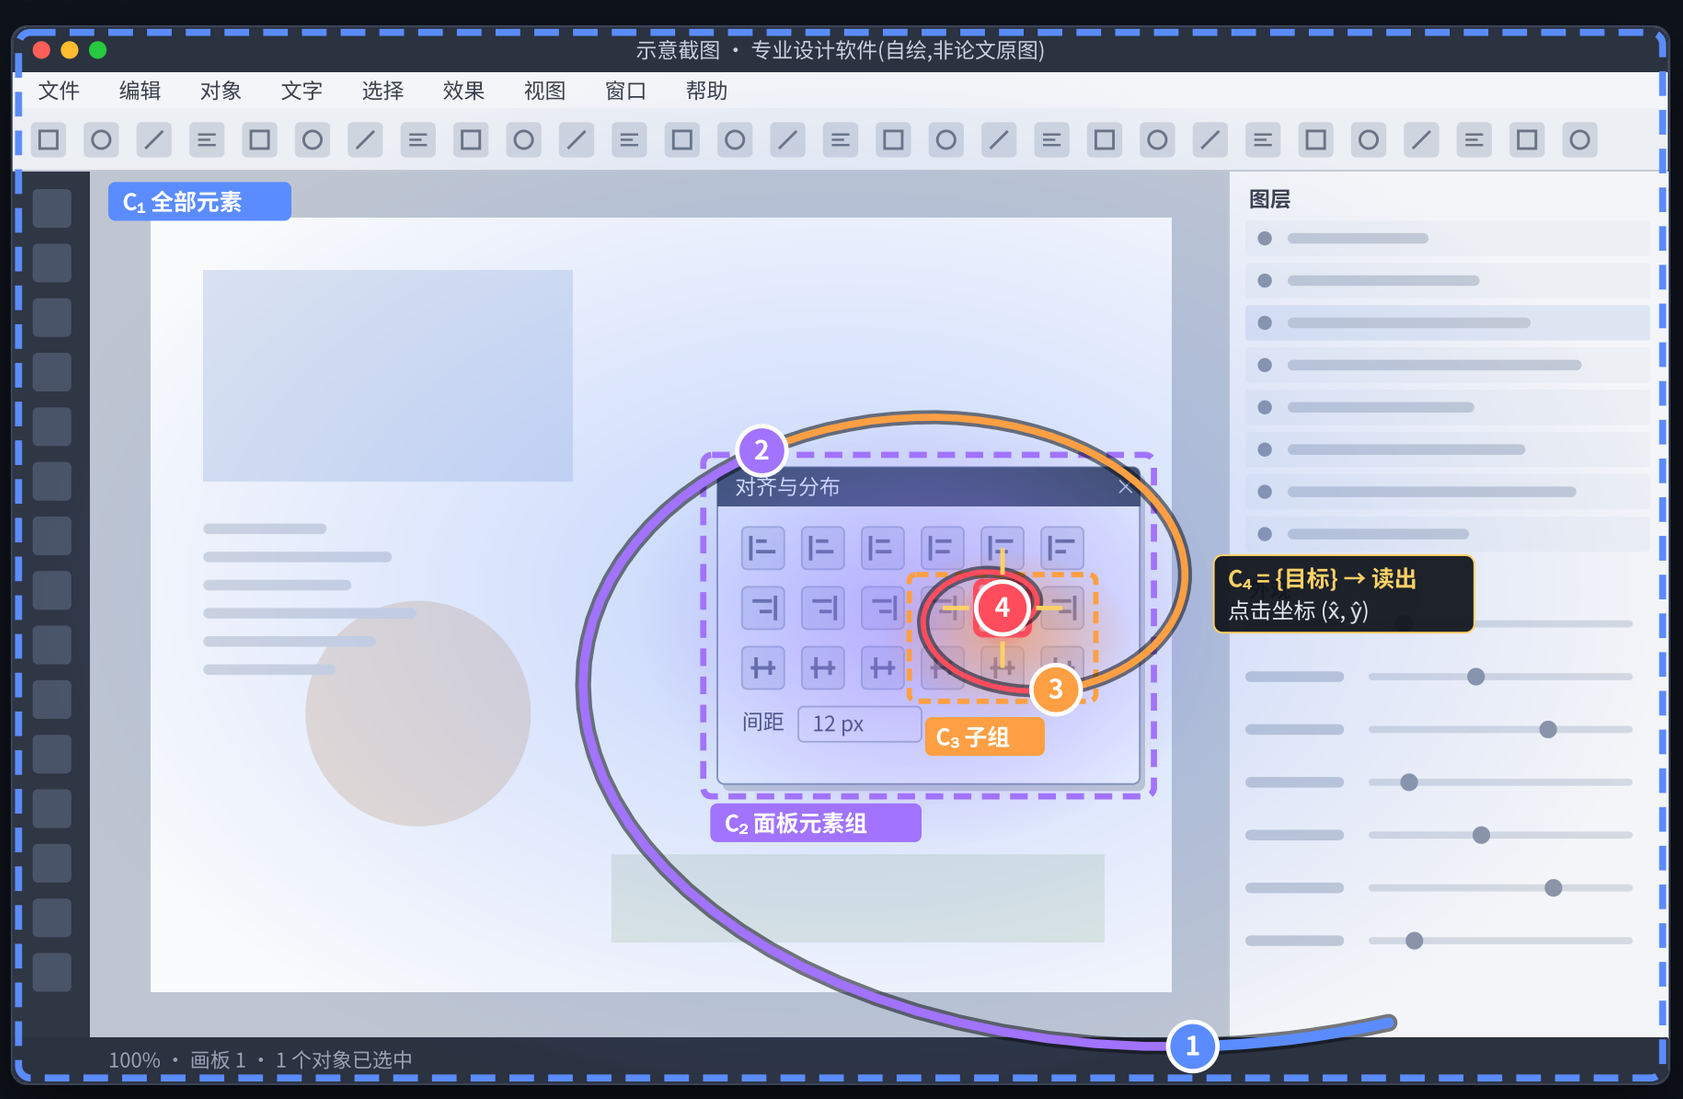
问题 · §1
单步直接输出坐标,在**高分辨率、小目标、密集布局**上容易点错。

现有多步搜索 · §1
文本思维链与视觉空间不对齐;外部 zoom-in / 裁图要**多轮交互 + 重新编码图像**。

本文的问法
能不能把多步视觉搜索变成模型内部、在同一张截图编码上显式进行的空间过程?

收拢轨迹

示意指令「把选中对象右对齐」· 截图、热区、螺旋轨迹与候选框均为**自绘示意**;卡片中金色数字为作者图 4(ScreenSpot-Pro 均值)



1 t=1 · 全局界面 — C_1 = 全部元素
s_1 铺满整屏;z_1 回填第 1 个 LVS-SLOT。
作者 · 目标概率质量 ≈0,期望距离 0.345

2 t=2 · 元素组 — $C_2 \subseteq C_1$
C_2 来自递归二分:选两侧外接矩形面积和最小的切分,沿含目标的一支往下(如工具栏、面板)。

3 t=3 · 子组 — $C_3 \subseteq C_2$
只保留候选数下降明显的关键步,压成 T=4 步轨迹。
作者 · 单步干预:第 3 步影响最大,第 1 步最小

4 t=4 · 目标 — $C_4 = \{e^*\}$
FGP 让 s_4 峰值靠近目标中心,再做 3×3 峰值读出。
作者 · 熵降至 3.06;目标质量 0.497;距离 0.091

每一步发生了什么(§3.1,图 2)

编码 1 次
截图 I + 指令 q → 视觉 token V(N 个),整个搜索都复用它

→

空间搜索头
$s_t = \mathrm{softmax}(Q_t K^T/\sqrt{d})$
Q_t 取自上一位置隐状态 h_t:「现在看哪里」

→

潜在视觉证据
$z_t = s_t{}^T V$
原始视觉嵌入的凸组合,替换第 t 个 LVS-SLOT 的输入嵌入

z_t 进入同一自回归序列,产生 h_{t+1},再算 s_{t+1} · 重复 T=4 步

监督:平面元素标注递归二分 → $C_1 \supseteq C_2 \supseteq C_3 \supseteq C_4$(§3.2) · CWC:每个候选质量 ⩾ $1/|C_t|$ · FGP:末步 KL 塑形到目标中心 · 三阶段训练(§3.4)

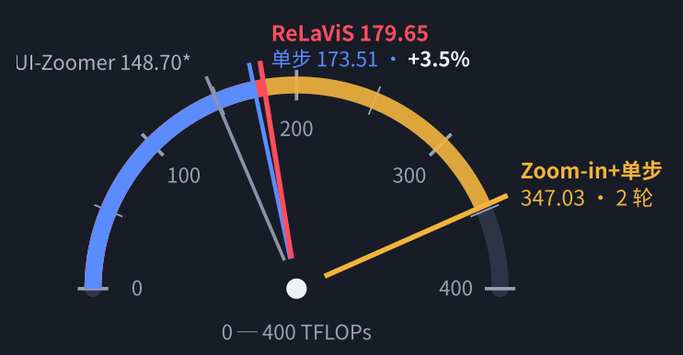
确定性峰值读出 示意



最大概率 token 的 3×3 邻域
按概率加权平均 token 中心 → $(\hat{x}, \hat{y})$

减小 patch 量化误差;不采样、不生成文本坐标(§3.4)。

径向成本标尺 · TFLOPs/样本 表 5,ScreenSpot-Pro



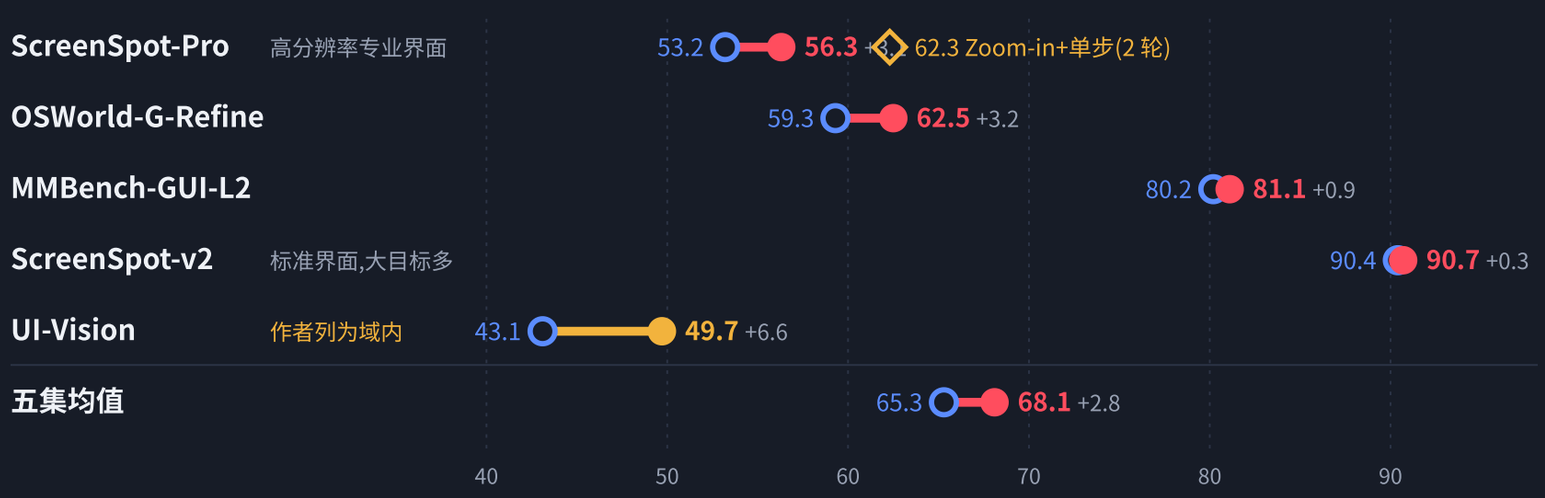
延迟 s/样本:单步 **2.06** → ReLaViS **2.19**(+6.3%)· Zoom-in+单步 4.28(2 轮)· UI-Zoomer* 2.34 · 峰值显存 18.78 → 19.54 GiB · 单张 L40、BF16、batch 1。*外部方法为官方实现下的参考值。

结果与边界

以下数字均为作者报告(表 1、表 2、表 4、表 5);我们只读原文,未复现

同骨干、同 100K 数据:单步 coordinate-free → ReLaViS

表 1 受控对照,3 个随机种子均值;单步基线即 ReLaViS 的 T=1 变体。点击坐标落入目标框算对。



同样走 4 步,只拆掉其中一个设计 · ScreenSpot-Pro(表 2)

ReLaViS 完整	**56.3**	仅终点监督	**54.0**
回馈 h_t 而非 $s_t{}^T V$	**55.2**	每步都监督目标	**53.9**
回馈固定 SLOT 嵌入	**54.5**	几何线性缩放轨迹	**53.8**
单步 T=1(基线)	**53.2**	打乱前三步顺序	**53.5**

多算几步本身只到 54.0;GUI 感知的粗到细顺序才到 56.3。干预(图 3 右):把前 3 步 s_t 换成对准目标的高斯,五个基准**升 2.0–13.1 pp**;换到相反位置**降 4.7–14.2 pp**——后续步确实在用前步的空间状态。

限制 · 先看这一列

作者数据 + 附录;判断部分已在下方虚线框单列

1. **最大增益在域内。**UI-Vision **43.1→49.7**,但附录 B.5 作者因它与 GroundCUA 应用重叠而列为**域内**,不能当跨域证据。外部集上 ScreenSpot-v2 仅 **+0.3**,MMBench-GUI-L2 **+0.9**。
2. **外部 ScreenSpot-Pro 上 zoom-in 仍更高。**Zoom-in + 同数据单步 **62.3** > ReLaViS **56.3**,代价 2 轮、347.03 TFLOPs、4.28 s;Zoom-in + ReLaViS **63.5**。GUI-Cursor 报告 56.5 也略高。
3. **「更省」要分对象。**相对同骨干单步只多 3.5% FLOPs;但 UI-Zoomer 延迟 2.34 s 接近,FLOPs 148.70 反而更低(官方实现参考值)。
4. **训练更贵。**约 88 h vs 单步 69 h(4×L40),多出的在 Stage 3 无梯度探测(表 4)。
5. **范围窄。**只做点击动作的静态离线定位;不代表在线代理任务成功,拖拽等动作留待后续(§5)。

我们的阅读判断(非作者主张)
回答标题:相对同骨干单步,「一次编码 + 内部 4 步收拢」以近乎持平的推理成本换来稳定提升,且对照拆开了「多算几步」与「粗到细监督」;但在外部高分辨率集上,重新取一张放大视图仍更强——内部搜索与外部放大是互补,不是替代。