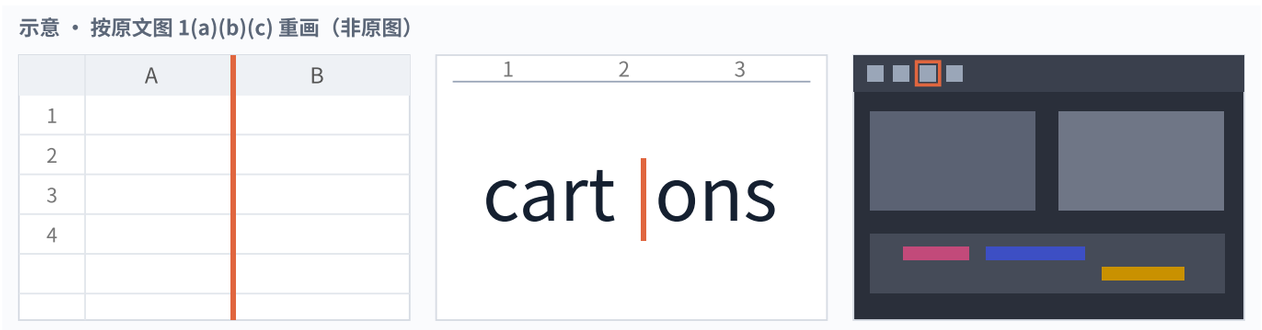
点得中单词，点不准字缝：目标细到字符、插入点、框选区域，最强模型 90% → 70 / 65 / 56%，专用 grounding 模型只剩一到三成

ScreenSpot 一类基准测的多是常规控件。PointerBench 用 1,500 张 1024×768 合成截图、像素精确的目标几何，单独测三类细粒度定位：**表格的细边线与角**（Sheets）、**六语言文档里的字符与插入点**（Text）、**100 个专业软件界面**（Pro，界面也是生成的）。37 个通用多模态模型用同一条“绝对像素坐标”提示，39 个专用 grounding 配置用各自原生提示与坐标约定。只测单步静态定位，**不执行点击或编辑**。

01 · 被测的“细目标”有多细



目标面积中位数（占全屏）：Sheets **0.215%** · Text **0.0286%**（约为 Sheets 的 1/7.5）· Pro **0.129%**

怎么判对 §3 · App. C

点　落在标注区域内即对

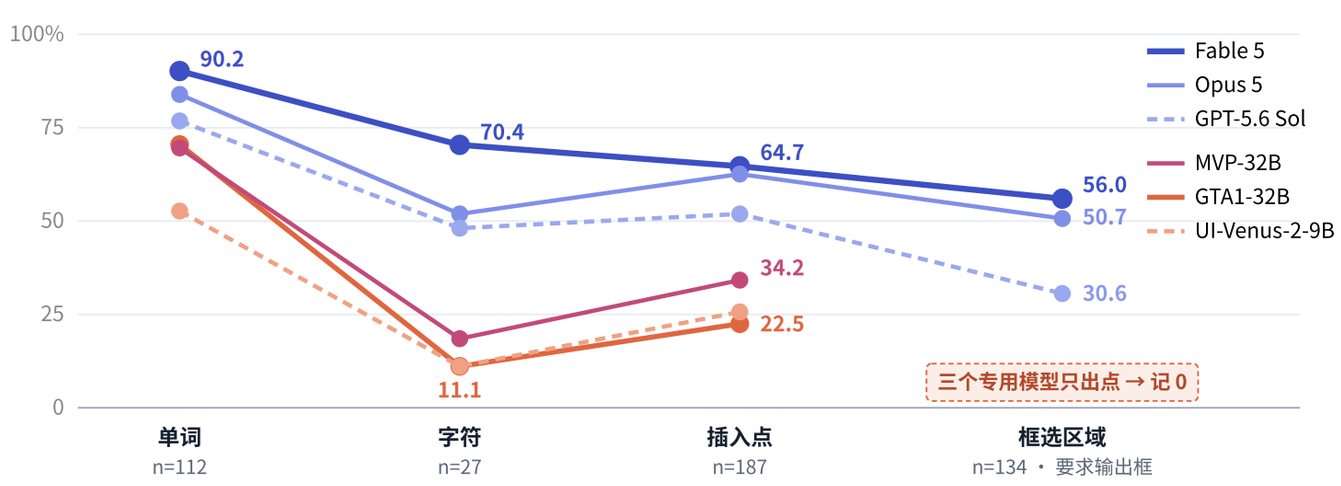
框　覆盖目标 ≥ 0.90 且框内精确率 ≥ 0.70（宁可略大，不能裁掉）

格式　固定 1024×768 绝对像素；输出畸形算错；被过滤或超预算不重试

Text 的 500 题怎么分 App. B 表 5

187	插入点（词前/词后/词间/字间/行首……）
134	框选区域（词、行、字符、段落、发票字段）
112	单词
27 / 23 / 17	单个字符 / 标点 / 界面文字（样本少）

02 · 粒度阶梯：同一批模型，目标越细越点不中（Text，表 3）



读这张图要分开两件事

感知上的掉落：同一模型从单词到字符、插入点都是点任务、同一判分，掉落是真的——Fable 90.2 → 64.7，专用模型 52.7–70.5 → 11.1–18.5（字符）/ 22.5–34.2（插入点）。

输出能力的缺口：框选区域要求输出框。只会出点的专用模型按点判、在 134 题上全记 0，这**不是**“看不准”的证据；会出框的 UI-Venus-Ground-7B 得 11.2，GUI-G2-7B 12.7。

前沿模型在框上的失败也各不相同（App. E 表 12）：Fable、Opus 多是框**画大了**（26.1%），Sol、Luna 多是**裁掉了**一部分（39.6% / 41.8%）。

字符 27 题、标点 23 题，样本小；单次运行无区间。英语与非英语各 250 题，Fable 都是 69.6%。

03 · 插入点放在哪：词边上最难（图 2，按原图 SVG 柱高换算，与 k/n 一致）

插入位置（题数）	Fable 5	Opus 5	Sol	MVP-32B	GTA1-32B	Venus-2-9B
词与词之间（22）	45	45	45	9	23	14
词后（45）	49	47	47	11	11	11
词前（21）	43	48	48	24	10	10
字与字之间（36）	72	61	39	28	19	17
行尾（17）	94	100	65	53	29	41
行首（10）	100	80	100	100	40	50
段尾（9）	56	89	44	89	67	78
段首（11）	91	100	73	91	64	73
句子边界（15）	80	60	53	27	0	27

单位 %。另有“空行”1 题，六个模型都对，未列。

粗结构好找，细位置难找

段首、段尾这类结构性位置，专用模型也有 64–91%；一旦要放在**某个词的前后或词间**，前沿模型都不过 50%，专用模型都低于 24%。字与字之间，最强的 Fable 72%，专用模型 17–28%。

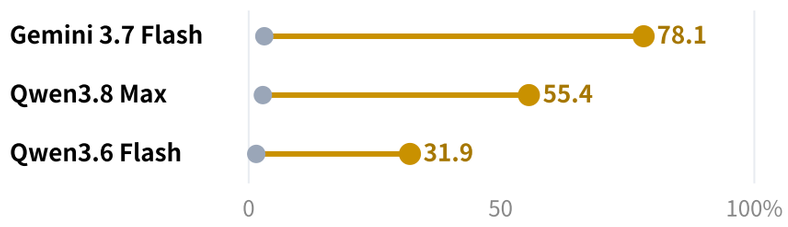
原文附录另报：**目标越小越难**，但只能部分解释——各模型与题组上，面积最大四分之一比最小四分之一平均高 10.7 点。

插入点总分（表 3）：Fable 64.7、Opus 62.6、Sol 51.9；MVP-32B 34.2、GTA1-32B 22.5、UI-Venus-2-9B 25.7。

我们的提醒：真实编辑里，插入点也可以用键盘（Home/End、方向键、查找）放到位；本基准没有测这些替代路径是否让这一缺口失去阻塞性。

04 · 总分会骗人的另外三处

坐标约定把分数打到个位 §3.3 · App. E 表 13



灰点为官方分 3.1 / 2.8 / 1.5：明确要求绝对像素，它们仍输出 0–1000 坐标；统一换算后才是金点。换算分不进排行榜。

排行榜 37 个系统里 22 个平均 ≤10.2%（我们按表 14 数），只核了上面 3 个；其余是否同因，原文未报。

98% 的 Sheets 里藏着边线 §3.3 · 表 9

100　Fable 单元格/表头/颜色

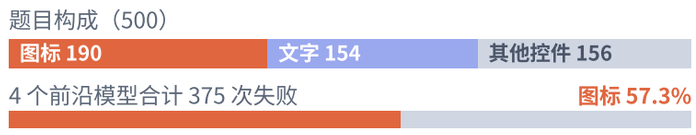
78.1　Fable 行高拖柄

89–100　UI-Venus-2-9B 单元格/表头

3.0　UI-Venus-2-9B 相对偏移

同一专用模型在边线/拖柄上 31.6–55.8%。前沿四个模型边线 81.0–98.3%。

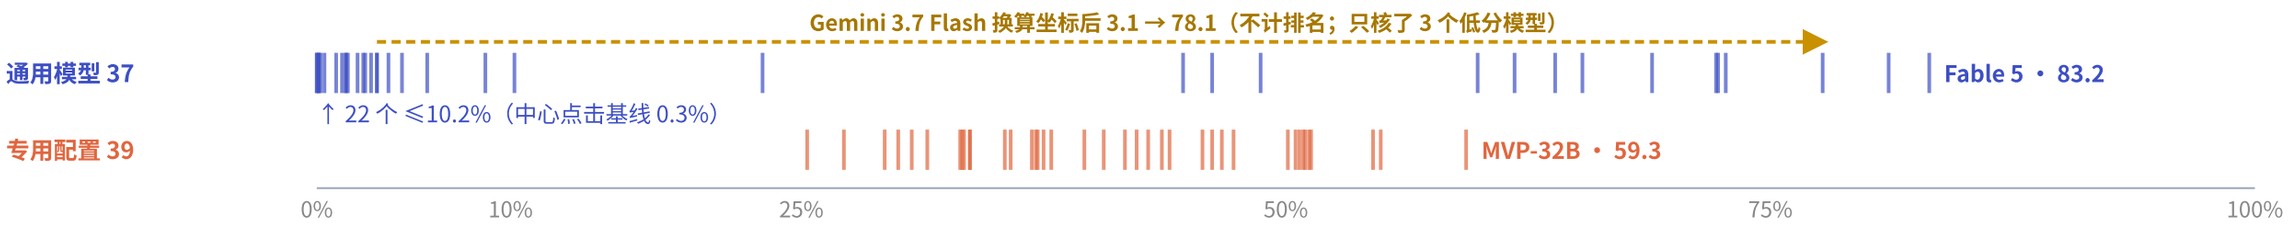
Pro：图标 38% 的题、57% 的错 表 10



图标 190 题、失败 215 次；图标准确率 70.0–75.3%，文字元素 89.0–92.9%。

推理预算（App. D，同题配对 McNemar）：低推理比关闭，Luna **+19.2**、Sol **+9.8**，Sonnet 反而 **−1.8**（p=0.002）。

全榜一瞥：平均成功率分成两团 表 14 通用模型（统一绝对坐标）· 表 15 专用配置（原生约定）；每条竖线一个系统



限制（画报口径以此为界）

- 单步静态定位：不点击、不拖动、不编辑，静态分数不能读成编辑任务成功率；键盘等替代操作未测
- 截图全是合成的：Sheets、Text 程序渲染，Pro 也是“生成的专业软件界面”；与真实截图的差距未量化
- 两张榜的提示、坐标约定、推理设置不同，只宜各自内部比较
- 每个模型一次运行、无区间；字符 27、标点 23 题；无人类基线与标注误差审计

我们的阅读

价值在**把总分拆成操作原语**：常规控件近满分，不代表能把光标放进字缝、抓住 2 px 的边线；排行榜低分里可能有不少是坐标约定。会不会卡住真实任务，要靠在线编辑任务回答。