模型看到的不是屏幕：工具层让代理的“所见”与真实界面静默脱节

作者结果 40 个开源 GUI 代理应用，约 2,000 个 issue 中确认 99 个工具层缺陷，跨应用复现成 **335 例失败**，归为 11 种模式；**90%** 的应用有两种以上模式，**119 例**做错了却没有任何停止或报错信号。

一个具体问题
模型不直接操作 GUI：截图/UI 树、动作执行、执行回报都经工具转手。工具没核对就把状态交给模型，代理就在一份过期或错位的界面上做决策——失败常被算到“模型推理”头上。

研究对象
40 个应用
Web 16 · 桌面 17 · 移动 7
2026-01-01 时的最新版本

证据
62 个任务 × 20 次 = 1,240 次运行，录屏、DOM、调用与返回全记录；3 人独立分类 κ = 0.95

工具
MalvaGuard：部署前静态契约检查，在**另 20 个应用**上评估（与 40 个不重叠）

一圈交互，四处断点　每个相位里，工具在哪一步没做核对

P4 反馈 61 例

时序反馈错配 20%
8 个 app 出现
按键事件先回 success，OS 还没渲染完，下一张截图仍是旧界面（cua）

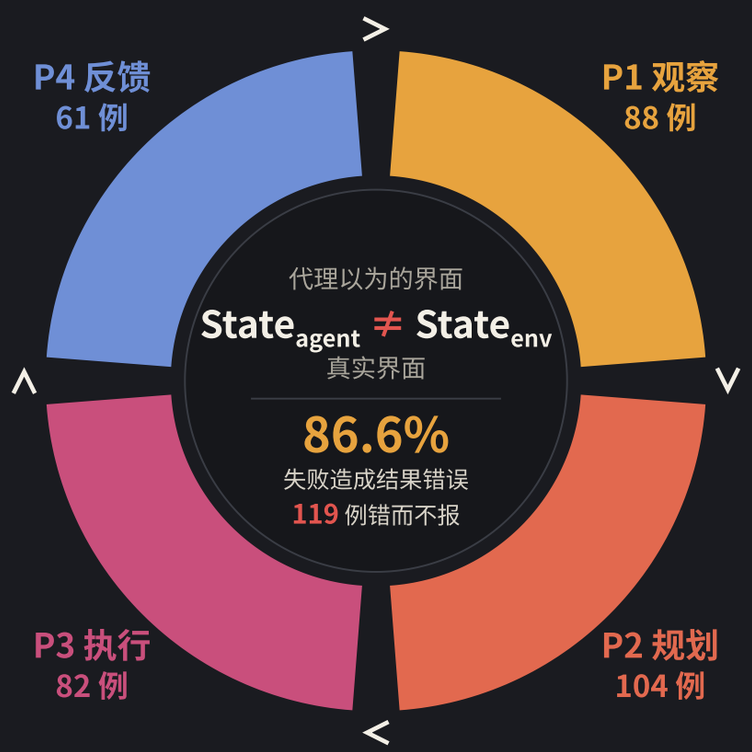
生命周期传播失败 58%
23 个 app 出现
代理自己按的 ESC 被监听器当成“用户停止”，任务直接终止（desktop-agent）

P1 观察 88 例

观察幻觉 33%
13 个 app 出现
AppAgent 只检测到 66 个元素却发出 tap(70)；gemini-browser 没写文件就报“完成”

目标绑定错误 38%
15 个 app 出现
LaVague 目标中心被盖住就判无效；UI-TARS 前后端坐标取整规则不一致

状态暴露缺口 18%
7 个 app 出现
截图里看得见按钮，但工具不报告最上层窗口归属（见下方案例）



P3 执行 82 例

工具模式不匹配 63%
25 个 app 出现
输出带 ```json 包裹，或 x=331 y=79 少了逗号，解析器直接报错退出

参数语义错误 25%
10 个 app 出现
请求滚动 200 px，适配层换成系统值 500 px（autoMate）

缺执行前置条件 33%
13 个 app 出现
终端还没打开就发命令（Surf）；VM 未就绪就取句柄（cua）

P2 规划 104 例

进展检查缺失 65%
26 个 app 出现
截图动作把下拉框关掉，循环无限重开（computer_use_ootb）

升级边界失效 5%
2 个 app 出现
CAPTCHA 被当成普通页面继续操作，直到步数耗尽（WebVoyager）

上下文预算溢出 48%
19 个 app 出现
整页 HTML 转 Markdown 塞进上下文：约 53 万 token，上限 12.8 万

一圈 = 一次工具中介的交互：观察 → 组上下文选动作 → 解析并执行 → 回报效果。条形 = 40 个应用中出现该模式的比例；四相位例数之和 = 335。
§II-B Fig. 2 · §IV Table II · 各相位例数见 §IV-B–E 首段；模式名为本栏目翻译；举例为原文案例的转述

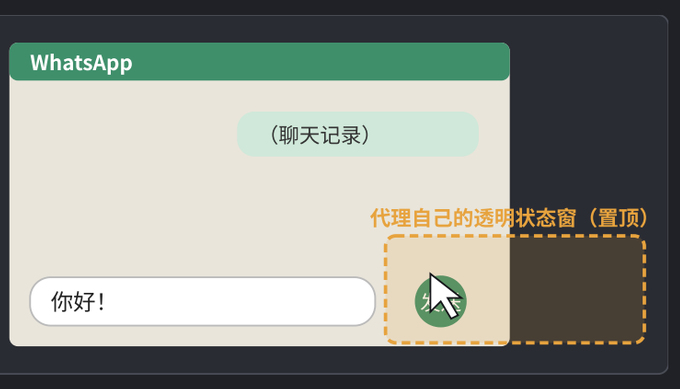
335 是怎么来的

- **~2,000** 个 issue（40 个应用）
- 关键词 + GPT-4o 初筛 + 人工 → **208** 个候选（open 104 / closed 104）
- open issue 派生 **62** 个任务，各跑 20 次，3 分钟超时
- 确认 **99** 个工具层缺陷（open 43 + closed 56）
- 在其余 39 个应用逐个检查同类工具行为并复现 → **335** 例

别这样读：335 是 99 个缺陷跨应用复现之和，不是 335 个独立 issue；只出现在少数运行里的故障被筛掉了，比例不是部署发生率。

§III-B–D · Fig. 3

案例：点“发送”，点到了自己



① type 成功：输入框没被挡　② click 按“看到的坐标”点发送

③ OS 把点击投给最上层的覆盖窗，消息没发出。工具只给视觉坐标，**不核对哪个窗口持有焦点、谁在最上层**——属于 P1“状态暴露缺口”。

§I-A Fig. 1 (UI-TARS-desktop)· 按原文描述重绘，示意

MalvaGuard：只查“该有的护栏在不在”

在交互代码所在函数（及同文件 helper）里找对应护栏，缺了就告警；497 处告警合并为 150 个缺陷。另 20 个应用，人工建 oracle 112 个真实缺陷。

报告 150	命中 86	误报 64
真实 112	找到 86	漏 26

precision 57.3% · recall 76.8%

护栏与触发代码同在局部作用域的 4 类全召回；进展检查、前置条件、目标绑定召回低（跨文件）；升级边界 0 报告（属运行时屏障）。

§V-A–D · Fig. 14 · 告警 ≠ 已验证的错误

限制：结论只到这里

- **样本来自 issue**：只覆盖有人报告、能复现的故障；比例描述的是这份缺陷库，不是代理在部署中出错的频率，也没测基准失败里有多少源自工具层。
- **范围**：开源应用，Windows 11 与 Linux VM；闭源产品可能另有缓解。分类一致性 κ = 0.95 只针对模式归类。
- **MalvaGuard**：局部静态分析；只给“补哪类护栏”的建议，不是自动修复，修复效果未评估。
- 原文“4 种模式合计占 63.0%”与 Table II 反推的例数对不上，本页不使用该数。

我们的阅读　判断，非作者结果

- F1 归因：GUI 代理的失败未必属于模型。同一个模型，换一套不核对焦点、不检查进展、提前报成功的工具，就会在“正确的计划”上做错事。
- F2 信号：执行回报本身可能是假的（提前 success、没写文件就报完成），依赖它的反思与停机判断跟着失效。
- 评测代理系统时，工具契约应当和模型一样被单独报告与检查。