目标还没露出来：GUI 代理卡在“让它出现”，不在“认出它”

作者结果 601 个任务里，目标一开始都看不见或点不了。Qwen3-VL 完整做 **30.8%**；只告诉它该用哪类动作，**33.9%**；把显露动作替它做完、只让它点最后一下，**81.9%**。

一个具体问题
静态 grounding 基准默认目标已在截图里；真实界面里它可能在视口外、藏在悬停/折叠状态后、被弹窗或可拖动元素挡住、或延迟后才可点。导航基准又把这一步混进端到端成功率。

基准
601 个任务
16 个确定性仿制 Web 应用
3 类约束 · 7 个子类

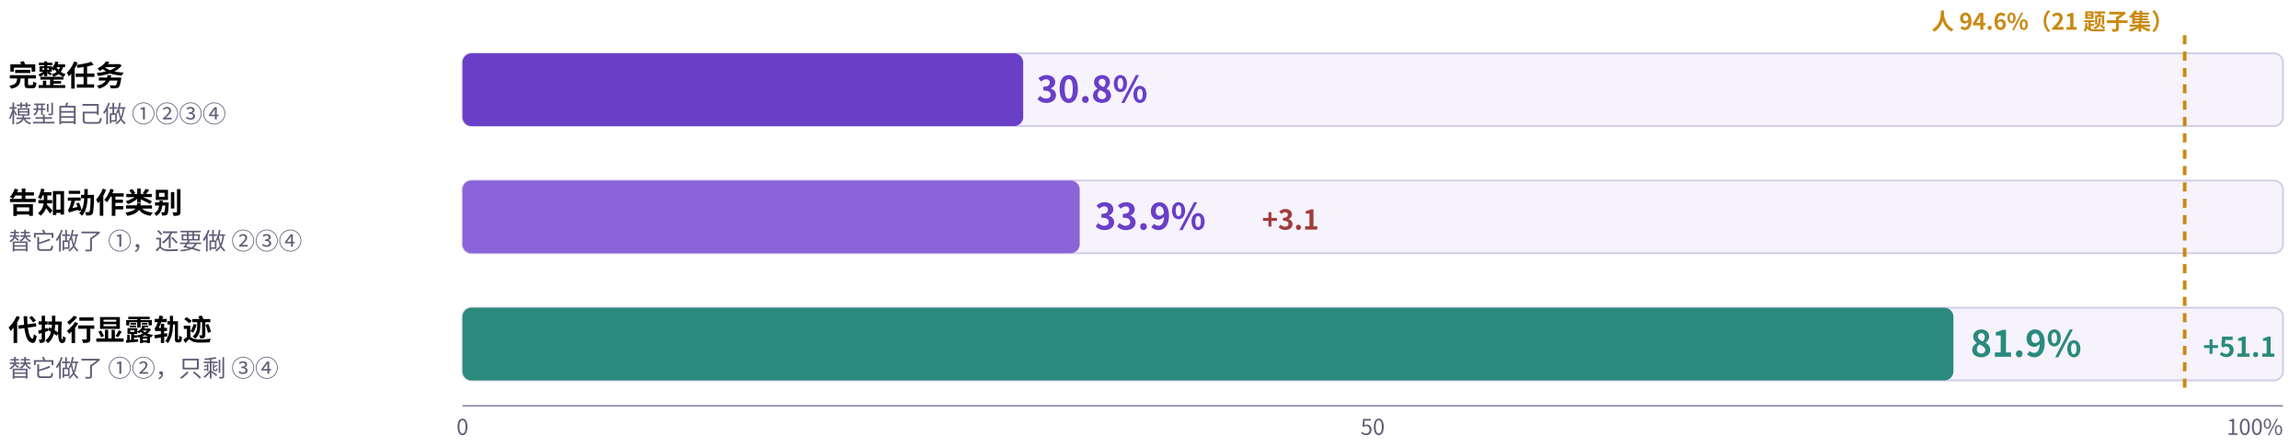
动作与判定
只给 Scroll / Move / Drag / Wait / Click 五种动作、8 步预算；点击时比对实际被点元素的 ID

信息隔离
模型只看截图、指令、动作历史；DOM、目标 ID、参考轨迹只给评估器

把一次点击拆成四步，再逐级替模型做掉前几步　§3.1 分解 · §4.3 Table 4

① 选显露动作：滚动？悬停？关弹窗？拖开？等？（动作类别）
② 在哪儿、多少：位置与参数，并把动作执行对（例：拖哪张便签、拖到哪里）
③ 认出目标：目标露出来以后识别它
④ 点准：最终一次 Click 被计分

显露（visibility recovery）：IGG 新测的一步　　与静态 grounding 相同的部分



同样的两次干预，GPT-5.4 Mini（Low）： 完整 72.4% → 代执行显露 90.4%（未做“告知类别”）。附录另测“指令里直接写出操作步骤”：Qwen3-VL 升到 56.9%，但仍 0/8 解出留出集的可拖动遮挡任务。

柱长按百分比；Qwen3-VL-8B，全部 601 题，每题一次、greedy。“代执行”条件把 ① 和 ② 一起拿掉，没有把“选位置/参数”和“动作执行”再拆开。

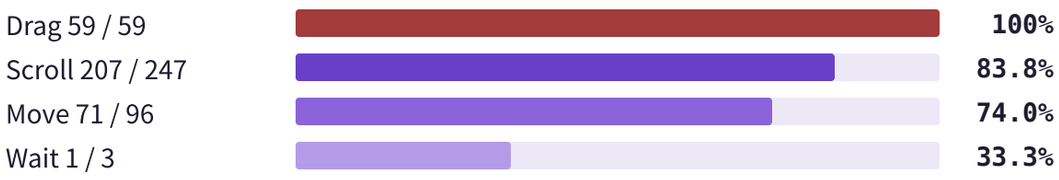
哪种遮挡最难　Table 2 · GA %

子类（所需显露动作）	Qwen2.5-VL	Qwen3-VL	GUI-Owl-1.5	GPT-5.5
视口约束				
视口外（滚动）	10.8	15.0	15.0	86.2
多状态约束				
靠悬停区分（Move）	18.0	22.5	27.0	86.5
藏在折叠/标签页	9.6	26.0	23.1	87.5
可关闭的弹窗遮挡	18.9	56.6	54.7	98.1
时间与操纵约束				
延迟才可点（Wait）	85.7	95.7	94.3	95.7
轮播/滚动条目	32.8	25.9	36.2	37.9
可拖动遮挡（Drag）	1.7	1.7	1.7	40.0
全部 601	22.3	30.8	31.6	79.4

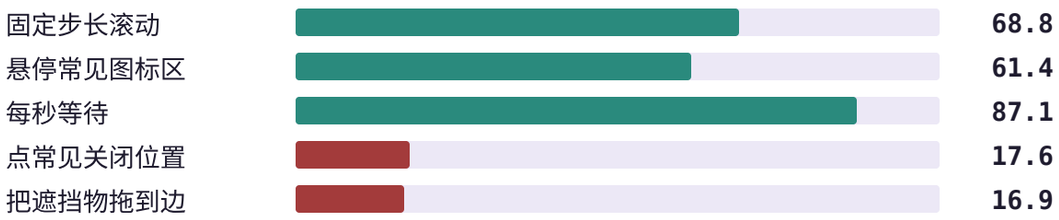
子类名为本栏目翻译；颜色深浅按数值，红底 = 几乎全错

失败轨迹里少了哪一下　App. F.2–F.3

作者结果 Qwen3-VL 失败任务中，参考轨迹需要、但模型**一次都没做**的显露动作：

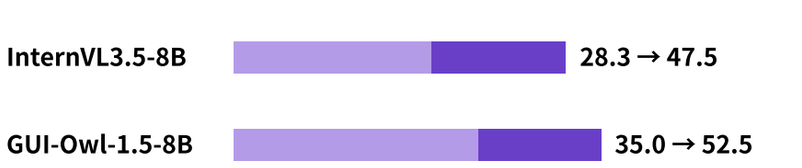


作者结果 不看目标的固定规则能显露多少（各自对应子类）：



难的是要先判断**哪个元素控制可见性、该怎么动它**；滚动、悬停、等待靠固定规则就能解决一大半。

能学会吗　§4.4 · Table A8 · 120 题留出



浅 = 基座，深 = SFT + 在线 GRPO 后的增量（GA %）

GRPO 只有从**按动作频率加权的 SFT** 起步才有效（普通 SFT 起步不涨）：基座从不输出 Drag，SFT 先把它放进策略的采样范围。

可拖动遮挡

4 → 5/8

留出集里 8 个需要 Drag 的任务：三个开源基座在留出集上一次 Drag 都不输出；加权 SFT 后 7/8 题会用 Drag、解出 4/8，再 GRPO 解出 5/8。分母很小，只说明这一动作先验能学进去。

§4.4 Results · App. C.3

任务本身可解吗

94.6%

15 人做 21 题（每子类 3 题）共 315 次，298 次成功；但人的预算只数点击和拖动，滚动与悬停不计，和模型的 8 步不完全可比。

§4.5 Table 5 · App. H

限制：结论只到这里

- **仿制环境**：16 个确定性 Web 仿制应用、固定 1440×900；仿真—真实配对只有 16 题（每应用 1 题），4 个模型的排序一致。
- **单次运行**：主评每题一次、greedy，没有置信区间。
- **训练留出**：120 题与训练题共用同样 16 个环境，不是新应用上的迁移。
- **分解粒度**：“代执行”同时拿掉选位置/参数和动作执行，二者谁更难没有拆开。只测找到并点中单个目标，不测完整导航。

我们的阅读　判断，非作者结果

- F1 归因：在这类任务上，把失败记成“grounding 不准”是记错了账——目标露出来后 Qwen3-VL 能点中八成，缺的是让它露出来的动作。
- 与首期 2412.10840、第二期 CogAgent 同一张卡，但它们测的是目标在图里时能否点准；本篇测定位之前的一步，两者不重复。
- 改进方向因此不同：补 Drag / Scroll / Move 的动作先验与参数选择，而不只是更细的坐标回归。