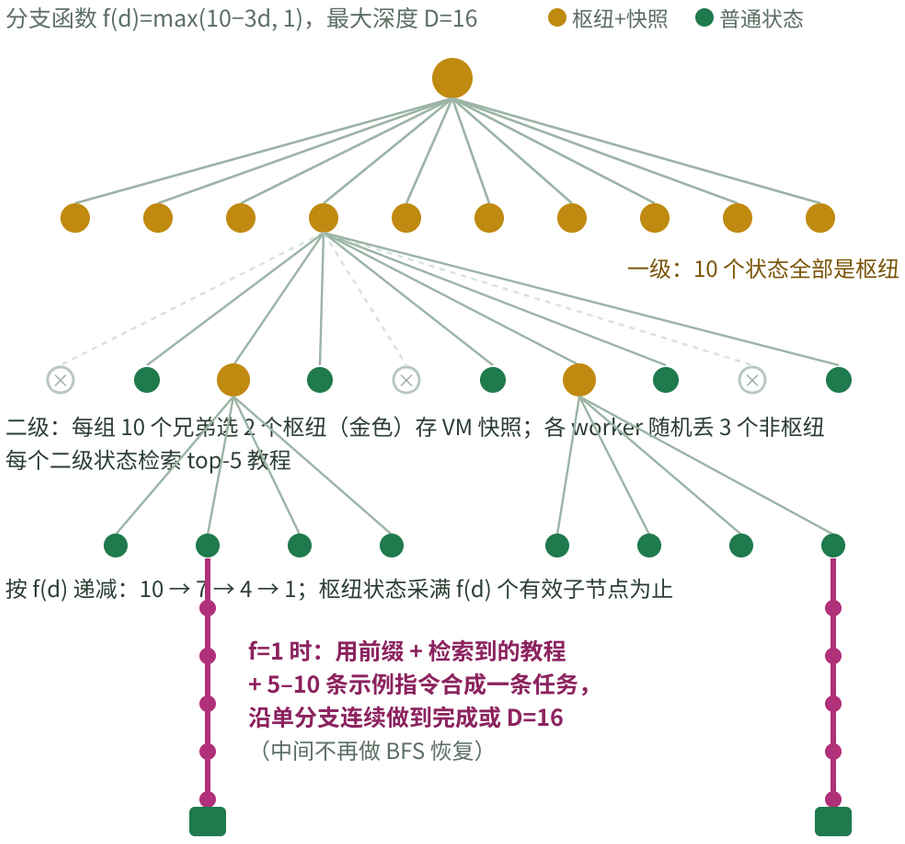
专业软件没有现成示范：用教程、原生命令和回到岔路口的探索去采轨迹，27B 模型 5.9% → 64.1%

ChimeraX、GRASS GIS、KAlgebra、Lean 4 这类软件，通用模型既不懂用法，GUI 流程又长，线性 rollout 还会漏掉分支，采集器连关键工作流都到不了。OS-Wizard 把教程检索、**GUI＋应用原生命令**的混合动作和**枢纽状态快照**放进同一个采集器，采到 10,919 条轨迹。用它微调 Qwen3.5-27B，ScienceBoard 从 **5.9%** 到 **64.1±0.7%**；同样只给 10K 样本，比两种已有合成方式高 **17.6–23.5 点**。

评测	采集	动作	通用应用占比
ScienceBoard	**54,938 样本**	**23.73% 含 code**	**31.75%**
6 个科研领域，作者的评测适配器，最多 50 步；“Ours”三次评测取均值±标准差	13 个应用；采样器 GPT-5.6-Sol / GPT-5.5 / Kimi-K2.5，GPT-5.6-Sol 兼任验证奖励模型	CODE 动作只对 ChimeraX、GRASS、KAlgebra、Lean、TeXstudio 开放；Celestia 与 OSWorld 只用 GUI	17,442 个样本来自 LibreOffice、Chrome、GIMP、VS Code 等，与 OSWorld 的应用重合

采集器的形状　示意，按 §3 与 Fig. 1–3 绘制

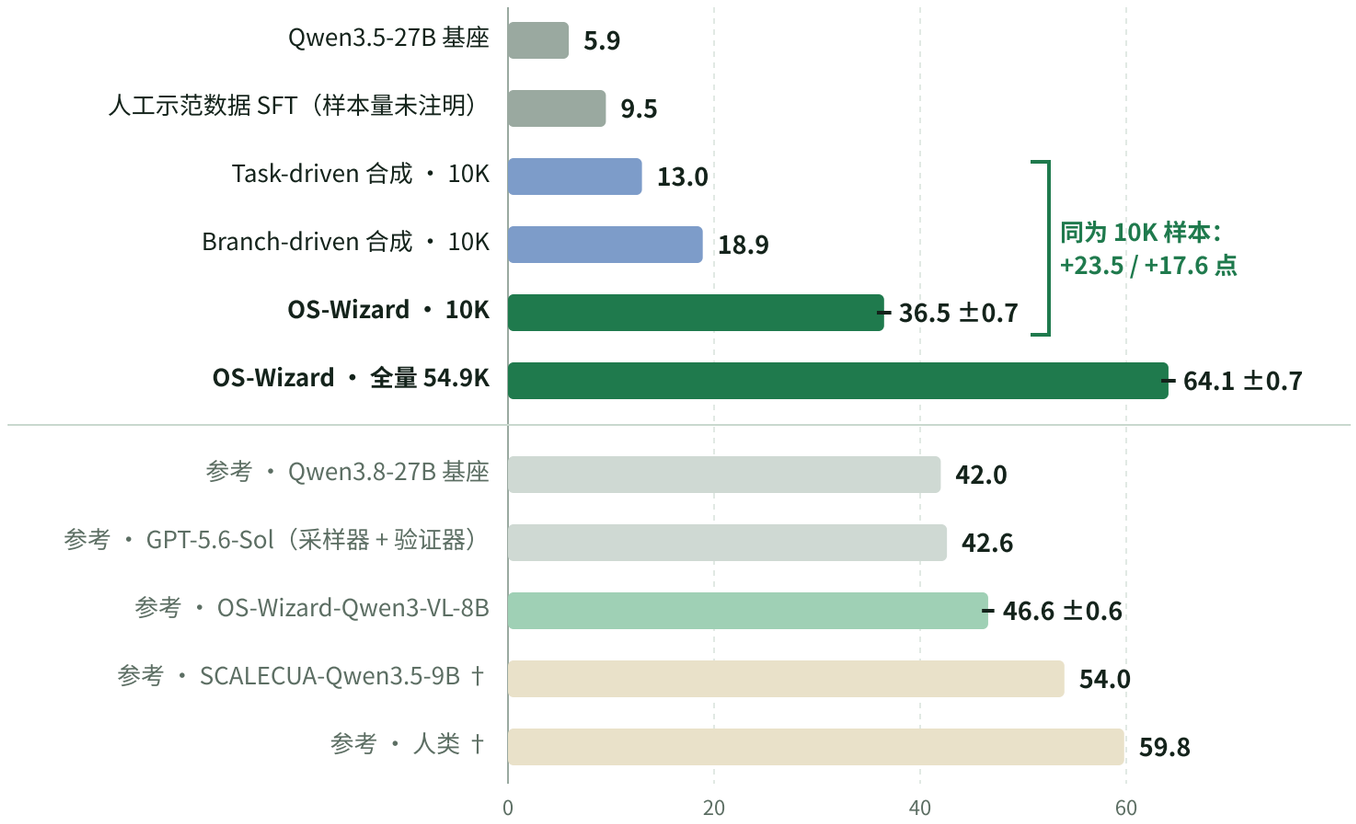


每一步怎么验收

- 所有动作必须执行无错；无任务指令时 GUI 转移还要奖励模型判有效，code 动作只要应用不报错就通过
- 有指令时奖励模型只判是否完成；只因深度上限终止的轨迹丢弃
- 恢复到某状态需重放的动作数：标准 BFS 15.7 → 枢纽快照 14.2 → 再加单分支连续执行 2.7（§5.3 实测）

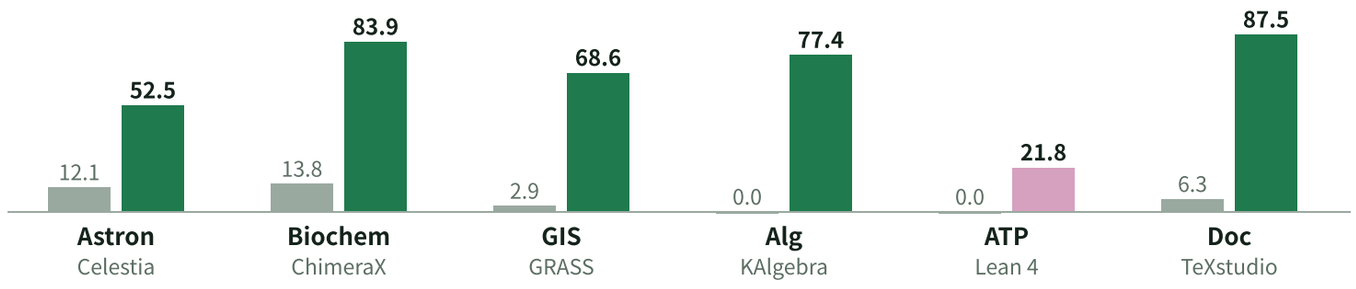
§3.1–3.4; §5.3; App. B

同一骨干 Qwen3.5-27B 的阶梯　ScienceBoard 总成功率 %，Table 1



† 来自其他论文报告，评测设置不同，只作参考，不与本表同条件比较（人类 59.8% 不能当作“超过人类”的依据）。GPT-5.6-Sol 既是采样器之一也是验证模型，它本身只有 42.6%。

六个领域：基座 → 全量微调　Table 1



同一个操作的三种走法　ChimeraX 显示氢键，Fig. 1

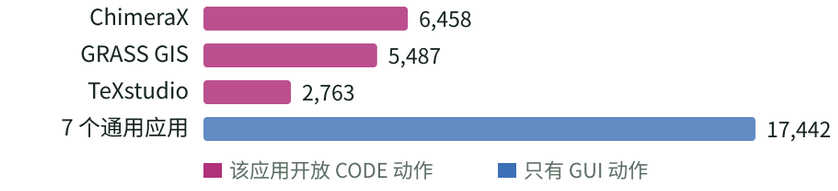
仅 GUI：开对话框、配参数、应用　10 步

在 GUI 里点输入框、键入命令、回车　3 步

CODE：直接提交原生命令　1 步

CODE 不提供 GUI 做不到的特权，只把能在命令行输入的命令直接提交；GRASS GIS 上作者改成在界面里模拟输入命令，让输出出现在截图中（App. A）。

样本从哪来　App. C Table 4 · 训练样本数



消融要带着混杂读　20K 样本，Qwen3.5-27B，单次，Fig. 4(b)



混杂项由我们按 App. C 的应用构成与 Table 3 的 CODE 定义推出，原文未讨论

作者的消融各自换掉了一部分**应用构成**，不是只拿掉一个机制。教程的作用只给了采集效率：不给文档时，KAlgebra 与 GRASS GIS 上 75.71% 的分支走到深度上限仍未完成而被丢弃（§5.1），没有下游成功率对照。

限制与证据边界

- 保留哪条轨迹由 GPT-5.6-Sol 判定（GUI 转移是否有效、任务是否完成），没有对保留轨迹做人工精度审计。
- Lean 训练轨迹来自 Formal Math Autoformalization Dataset 的 1,608 道题，原文没有报告它与 ScienceBoard ATP 题目的去重；ATP 从 0 到 21.8 的来源因此不能确认。
- Task-driven / Branch-driven 是作者按 OS-Genesis、ANCHOR 重实现的，是否同样可用 CODE 动作与教程没有写明，也没有误差条；“同 10K”是样本数相同，不是采集算力相同。
- OSWorld 39.1 → 42.9（只用 GUI）：训练里有 31.75% 的通用应用样本，这是同类应用上的 online 提升，不是迁移。
- 消融、数据量与模型规模实验都是单次训练；ScienceBoard 评测用的是作者改过的适配器（应用专属提示、CODE 分发、GRASS 控制台），基座和闭源模型也在同一适配器下由作者重测。

这改变什么（我们的阅读）

- 专业软件上，数据的瓶颈首先是**采集器到不到得了**专家工作流：把教程和原生命令交给采集器，比只扩大通用 GUI 合成更直接。
- 同样 10K 样本，这套管线的数据比任务驱动、分支驱动的合成更有用；但哪个组件贡献多少，现有消融分不开。
- 证据等级：**online**（ScienceBoard 交互评测；训练与测试是同一批应用，不是 transfer）。数字取自作者表图；采集树与三种走法为示意，阶梯、领域条、消融条由我们按表重绘。