动作做完 ≠ 替这个用户做对：最强代理动作完成分 91.6，整题成功率 47.7%；只有用户本人知道的信息，最多只问到 44%

真实请求常常说不全，例如“帮我订常去那家，明天”。iPrefBench 在可执行的 iOS 模拟器（26 个 mock app）里给代理一个用户的 **3,051 条活动历史**和一个 **ask_user** 通道，并在构造时规定每个省略的信息**要么能从历史推断，要么只能问**。130 个任务、7 个前沿模型同一 harness：动作完成分 77.5–91.6，整题成功率 26.2–47.7%；平均每题有 0.89 个“只能问”的信息，代理每题只发 0.08–0.35 次提问。

01 · 研究动作：先给每个缺口钉死来源，再看代理怎么补

按原文 §1 与 §3.3 的餐厅例子重画（示意）

用户说
“帮我订常去那家，明天。”
省略了 3 个由用户决定的值

哪家餐厅
几点
几个人

另设 34 个扰动题：
指令推翻历史 11 · 偏好近期改变 10 · 首选项缺货 13

任务经两轮人工审核与执行验证；历史证据不足时由审核者**改写种子数据**使偏好清晰（§3.3、App. D.1）

可推断（inferable）· 从活动历史里找
过往订位、外卖、评分里的主导模式；问了反而是打扰。平均每题 1.98 个

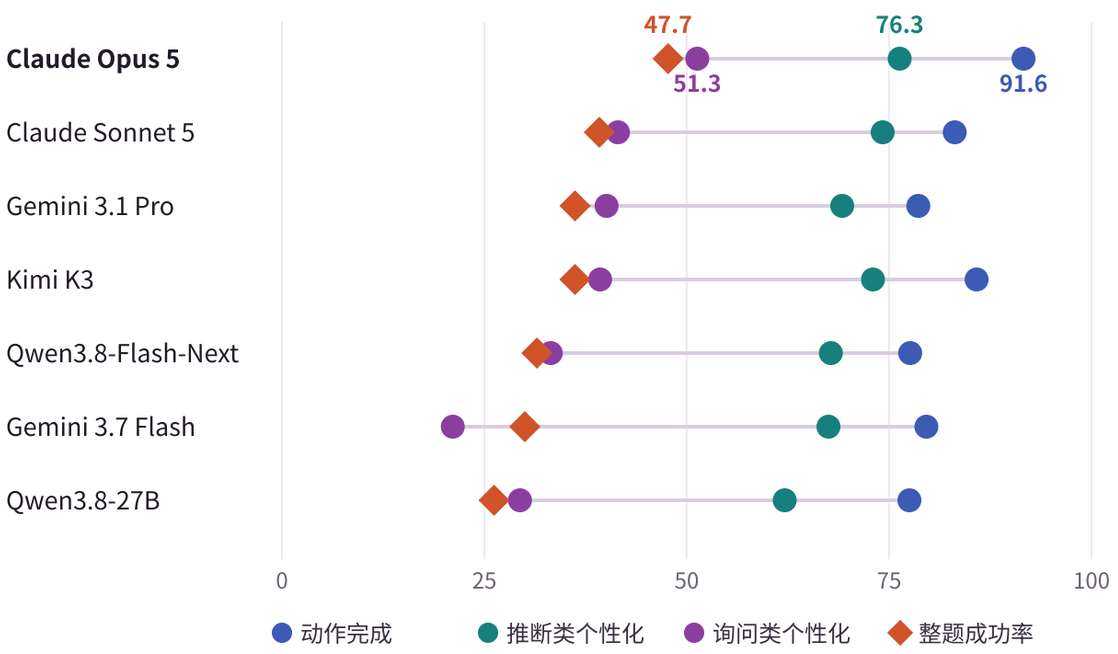
评分三层：**动作完成**（订位做没做成，不看值）· **推断类** · **询问类个性化**
全部满足才算整题成功；另用提问的 recall / precision 衡量“该问的问到没有、问的是不是该问的”。

只能问（ask-only）· 通过 ask_user 问模拟用户
本次场合的信息历史里没有；值尽量设成不同于 app 默认值，防止靠默认值蒙对。平均每题 0.89 个

用户画像（13 维 92 条）只给模拟用户与评分器，代理看不到；模拟用户只答所问，不主动补充

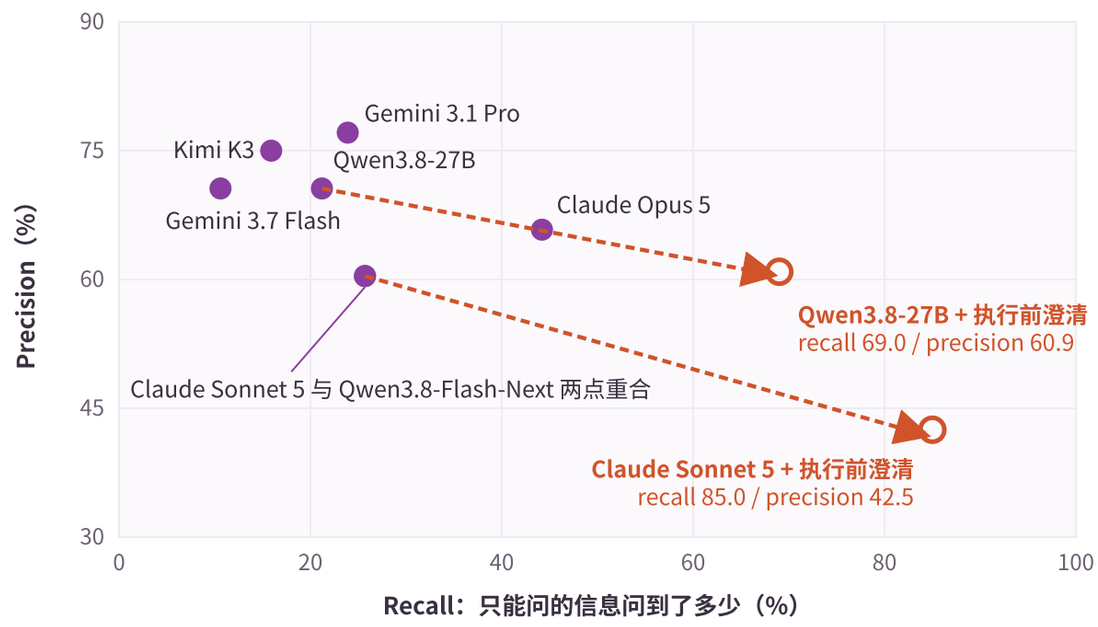
02 · 7 个模型，同一 harness，单次运行（Tab.1）

四个刻度：越往下越接近“替用户做对”



动作完成分与个性化分按条目、按任务宏平均，整题成功率按任务计：**分母不同，两者之差不是“因个性化失败的任务比例”**。

该问的问到没有 × 问的是不是该问的 Tab.1、Tab.2



让代理执行前先澄清：Claude Sonnet 5 整题成功 **39.2→53.8%**、每题提问 0.24→1.37 次；Qwen3.8-27B **26.2→35.4%**、0.21→0.84 次。recall 上去了，precision 一起掉下来。

人工标注的失败类型：认出了缺口没有 × 该从哪里补 §4.3、App. F.2

	认出这是待定的值	根本没当成待定的值
只能问	**自己猜（Silent Guess）** “和朋友打车”，没问几人，按最多 4 人下单，实际 5 人	**用默认（Silent Default）** 往返机票没给日期，app 预填日期原样通过
可推断	**推错（Wrong Inference）** “我平时的晨练”按用户已放弃的旧习惯来	**漏推（Missed Inference）** 用户每次订居酒屋都选吧台位，代理留了“无偏好”

逐条标注 Claude Sonnet 5 的 79 个和 Qwen3.8-27B 的 96 个失败任务：**89% / 84%** 至少含一种个性化错误，而不是导航失败。Qwen 推理里常出现“要不要问？”，随后说服自己去猜。

多给历史：会推断了，但更不问了 §4.4、Fig.4

按任务指令检索相关事件放进上下文：Qwen3.8-27B 的**推断类个性化**只给前 50 条相关事件就从 **35%** 升到 **63%**，再给全量历史不再提高；**询问类个性化**几乎不动。

历史越多，提问越少、precision 越高，但只能问的信息 recall 反而从 **33.6** 降到 **21.2**：历史帮代理避开不必要的问题，没有帮它认出真正缺的东西。

首选项缺货的扰动题里，代理提问是平均的 2.3 倍，询问类个性化对每个代理都提高——明确的环境障碍会让代理开口，需要自己察觉的不确定性不会。

评分与模拟用户校验过 §4.5、App. C.4、E.4



限制（画报口径以此为界）

- **只有一个虚构用户 Jordan Avery、26 个 mock iOS app**；部分种子数据被改写成清晰偏好，真实用户的混合偏好未测
- 用户由 LLM 模拟、成功由 LLM 评分（都用 Claude Sonnet 5，它也是被测模型之一；换 Gemini 3.7 Flash 评分一致）；不是真人满意度
- 每个设置单次运行，没有报告运行间波动；相近模型的排名不稳
- 没有“禁用 ask_user”或真人代做的对照；专用 GUI 代理因上下文或动作格式问题未纳入

我们的阅读　改变的是**判断**：只报“操作做成了没有”会高估个人代理；评估提问要把 recall 与 precision 一起报，并先分清哪些信息本可从历史推断。“鼓励多问”换来的是另一种失败。

与本仓首期 2503.19537 同卡不同题：那篇是离线单步、无历史，主要测出**问得太多**（precision 0.08–0.19）；本篇在线执行、带历史，主要测出**该问的不问**（recall ≤44.2%）。