目标在视口外，代理常去点看得见的错目标；截图上标出可滑动区域后，18 个滑动任务成功率 64.8→82.7%

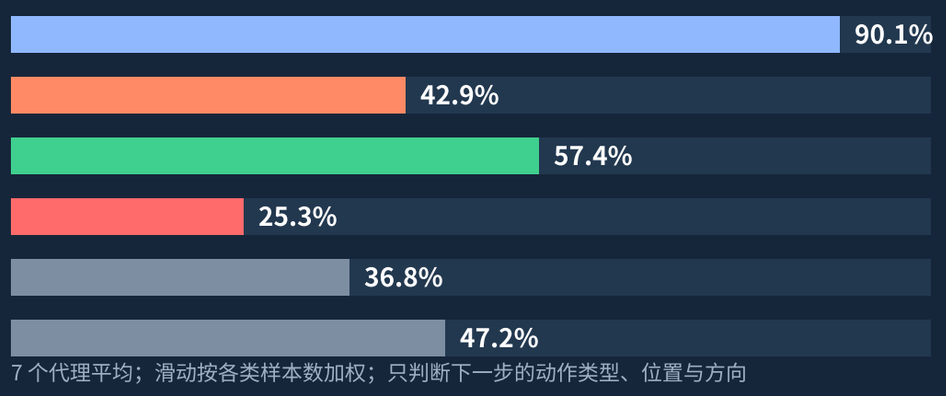
手机界面里很多目标要先滑动才看得见。有 swipe 动作不等于会用：7 个代理在 192 个需要滑动的步骤上只有 **42.9%** 选对，失败里 **83.73%** 是去点了当前可见的错目标。作者用 667 张人工标注截图微调 Qwen3.5-9B 得到 **Hagasu**，只改截图和提示词、不接管动作；在 3 个骨干、18 个探索依赖任务、各跑 3 次的在线实验中，平均成功率 **64.81%→82.72%**，每题多花 **33–71 秒**。

01 · 问题：看得见的里面挑一个，还是先去把看不见的翻出来

示意 · 仿原文 Fig.1/Fig.4 重画



预研：会点，不会滑　§2.3，Tab.1；218 个单步交互，55 个 app，7 个代理，同一截图与目标描述



7 个代理平均；滑动按各类样本数加权；只判断下一步的动作类型、位置与方向

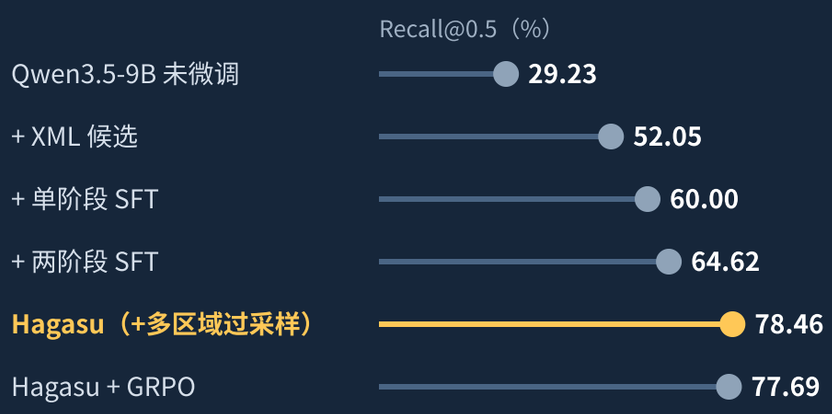
83.73%
失败的滑动题里，代理选择点击一个可见的错误目标（选错区域或方向的不到 30%）

100% → 35–42%
GUI-Owl、UI-Venus 1.5、MAI-UI 点击题全对，滑动题按样本加权只有 42.2 / 35.4 / 40.6%

研究动作：**只在部署时可见的截图上**预测所有可滑动区域，编号框画回截图并加一句提示；XML 只用来辅助人工标注，推理时不需要。代理仍自己决定点、滑或别的动作（§3.4）。

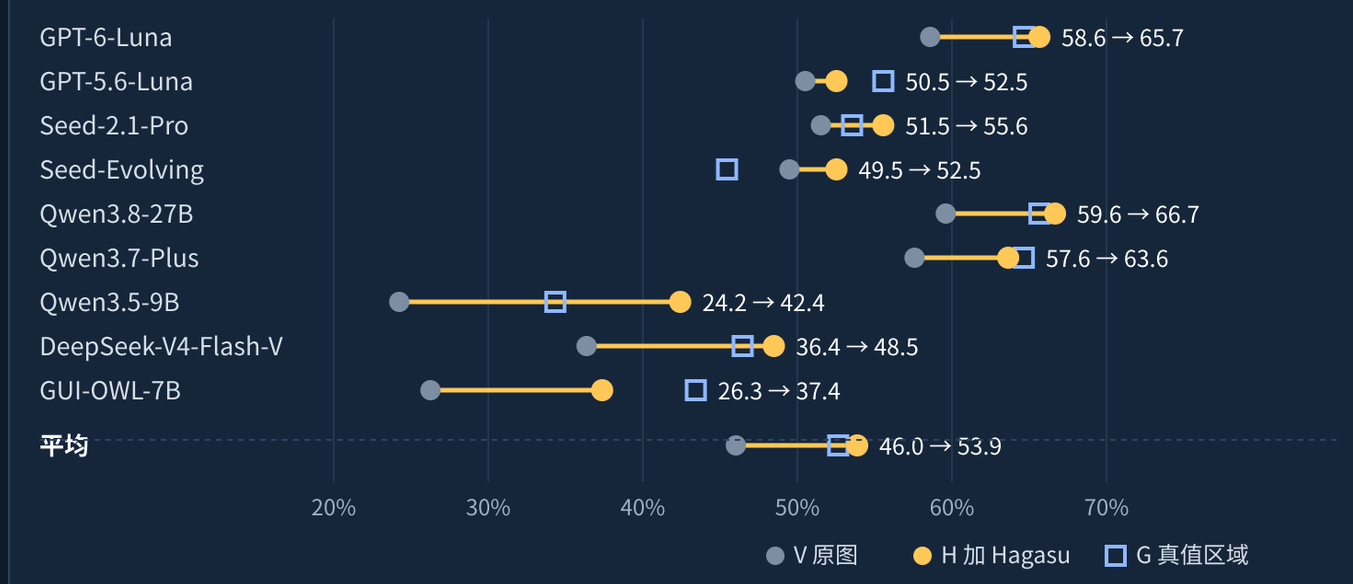
02 · 感知器与离线规划（9 个 VLM，同一骨干的 V / H / G 三种输入）

区域检测：微调才够用　Tab.2，67 张测试截图，IoU≥0.5



完整区域集合全对（Exact Match）只有 **43.28%**；加 GRPO 无增益。训练/验证/测试是按截图随机划分，不是按 app 留出。

该滑的步，有没有判断成滑　Tab.3；60 个任务 245 步，99 步应滑



9 个模型应滑步召回全部上升（+2.0 到 +18.2 点）；应点击步召回平均 95.21→93.53，Qwen3.5-9B 降 8.22 点。**换成人工标注的真值区域（G）并不更好**：平均 52.64 对 Hagasu 的 53.87。

03 · 在线：收益与耗时一起记账（Tab.4，Android 16 真机，每题每设置 3 次，人工判定成功）



平均 64.81 → 82.72（+17.90）；18 个任务来自 16 个 Android app，同一指令与动作预算；σ 为三轮成功率的总体标准差。Qwen 两个代理平均步数下降，GPT-6-Luna 步数上升（10.11 → 11.59）。

反例：提示不完整时，代理会被它带偏　§6.1，Fig.6

原始截图（成功的一次）
整页上滑 → 露出 View more
→ 进入完整目录 → 横滑分类栏
→ South Korea → KORAIL PASS

加 Hagasu（失败的一次）
只框出横向轮播，漏掉整页纵向区
→ 在轮播里反复左滑，到头无变化
→ 没去滚页面，在首页返回 finish

Qwen3.8-27B，TrainPal 首页任务；作者结论：保留动作自主权不能完全防止不完整感知误导规划

限制（画报口径以此为界）

- **在线只有 3 个骨干、18 个探索依赖任务**，按离线 H 设置下滑动召回最高选出；摘要里的“九个代理”指离线实验
- 在线没有测普通（不需滑动）任务，额外提示对一般任务的副作用只有离线点击召回可看
- 没有“只加文字提示、不画框”或等额外推理预算的对照；G≈H 说明区域更准也没有更多收益，收益里有多少来自“提醒去滑”本身未分开
- 成功由人工判定；训练截图与在线任务的 app 是否重叠未报告
- 每题多 33–71 秒（已计入 62–70% 的截图缓存命中）

我们的阅读

改变的是**能力**：把“这里还能滑”显式交给代理，是不改模型权重、只改观察的 harness 改动；在所测的 Android 探索依赖任务上，三个骨干都提高了在线成功率。

尚未改变的：**什么时候该停止探索**。G≈H 与 TrainPal 反例都说明瓶颈有一部分在规划而不在感知；作者自己的下一步是把区域感知与任务规划联合训练。