点在框外，不一定点错：按点击产生的结果评分，被框规则拒掉的点击里约 1/5 到 1/3 其实达成了目标

GUI grounding 基准只认“落在唯一标注框内”的点击。作者把正确性改为**“与点击目标框产生同一结果”**，在自托管的 Gitea 代码托管站和 Django Oscar 网店上逐点执行、拦截会改服务器状态的请求并记录结果指纹。三个 7–8B grounder 被框规则拒掉的点击中，**Gitea 17.6–20.5%**、**Oscar 29.7–38.1%** 达成了目标结果；在 ScreenSpot-v2 上，审计估计的校正量为 **0.2–1.8 点**，与近年论文报告的同尺寸模型差距（中位 1.15 点）同一量级。

01 · 一个页面上，哪些像素能完成“打开这个提交”



研究动作：执行一次，留下结果指纹 §3.1–3.4

o_b = 框内最常见的非空结果

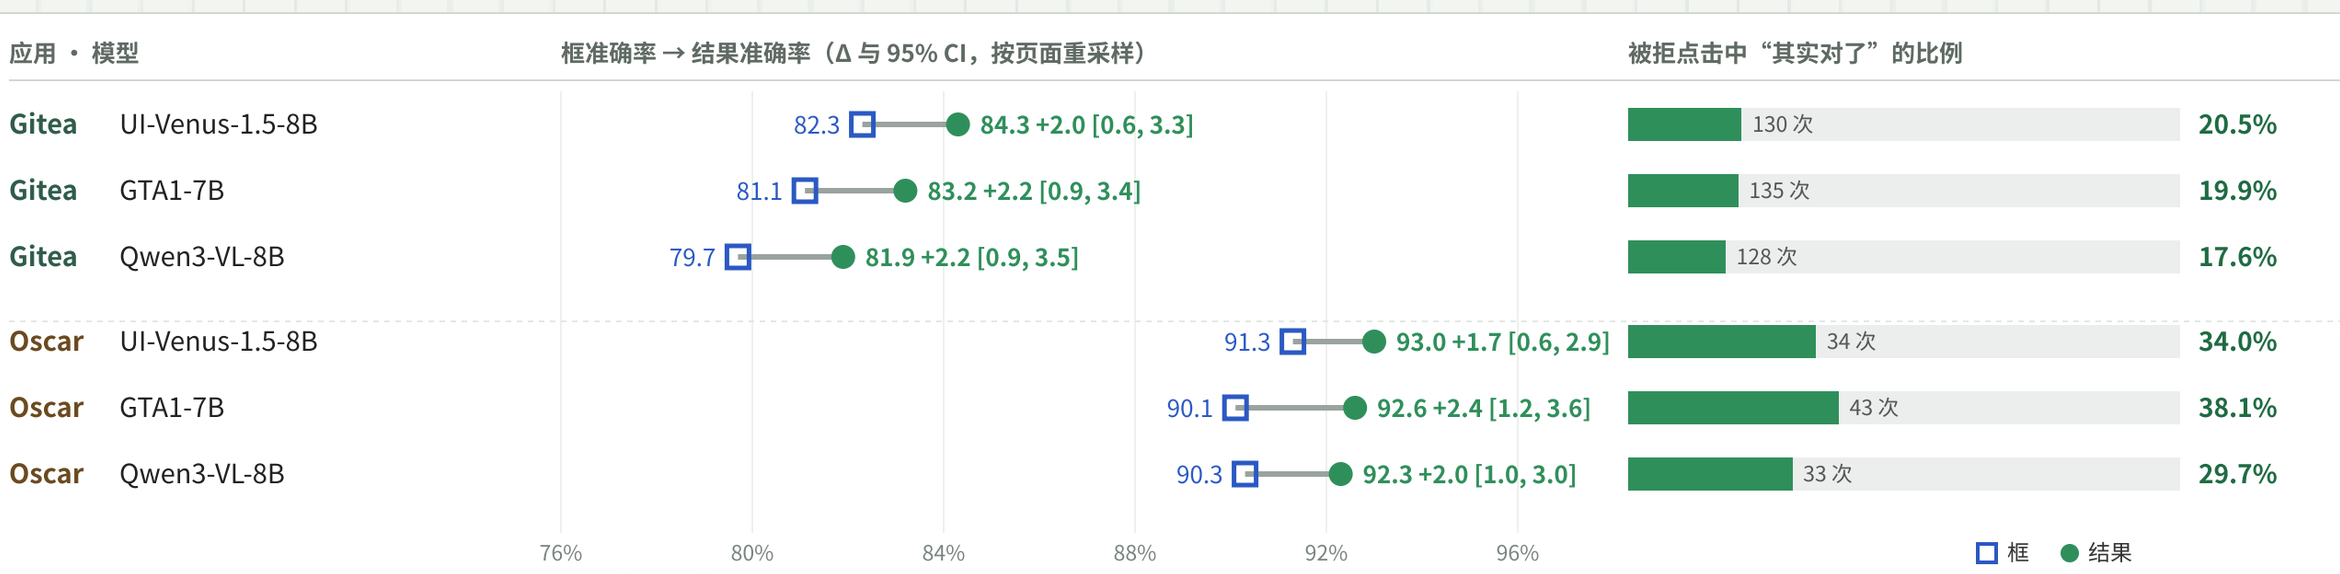
正确 ⇔ $o(s,p) = o_b$

E \ b：被拒的正确点击 · b \ E：被收的无效点击

- Chromium 1280×720 逐点悬停→点击→等待请求结束；结果按顺序取第一个命中的指纹：主框架跳转 / 新窗口 / 非 GET 请求 / 对话框 / 可见页面变化 / 无效果
- 跳转与非 GET 请求**被拦截**，服务器状态不变；Oscar 另用中间件回滚每个事务
- 每页约 700–1,000 次点击得到“结果地图”；同一探针执行模型预测即成判卷器，**不需新增标注**
- 仪器自检：重载后结果一致 97.9 / 99.8%，框中心复现目标结果 98.1 / 98.7%，重复执行判决一致 98.6 / 98.7%

Gitea 94 页 4,970 个活目标中 17.7% 与框不一致；Oscar 56 页 1,224 个中 31.2%（Tab.1、§4.1）

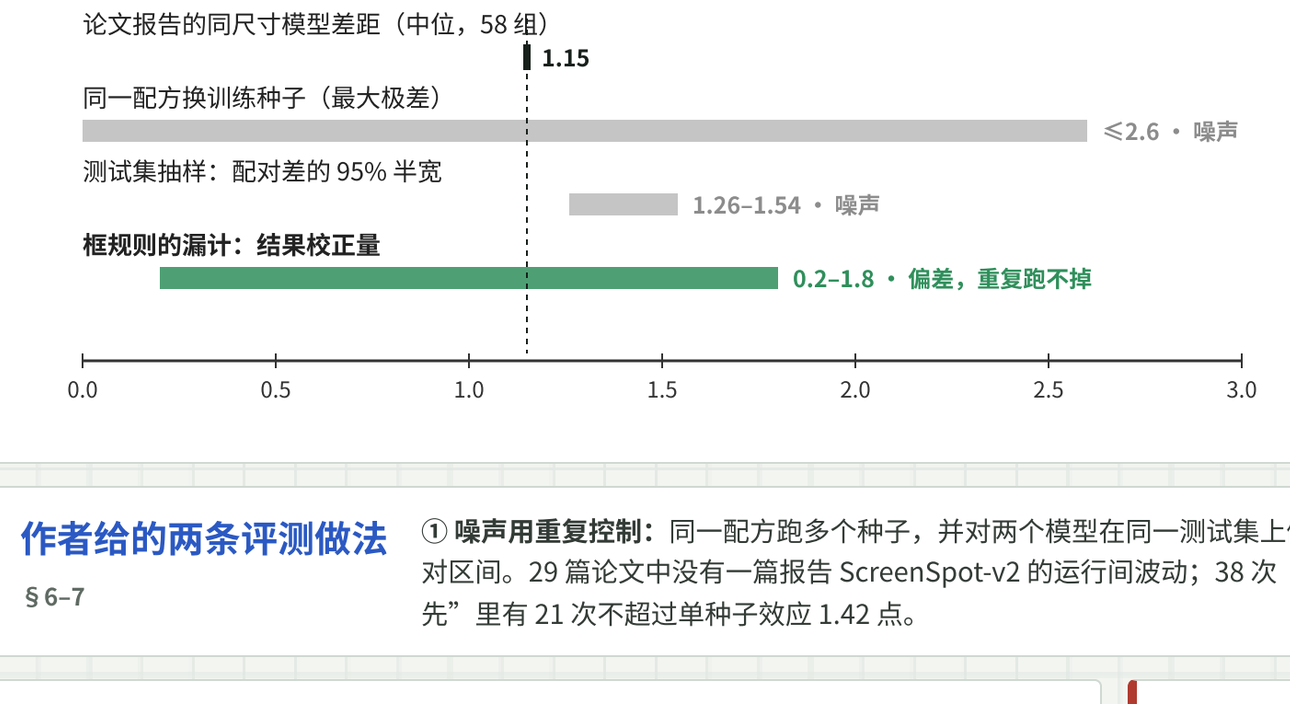
02 · 被框规则拒掉的点击，有多少达成了目标结果（执行判卷，Tab.3）



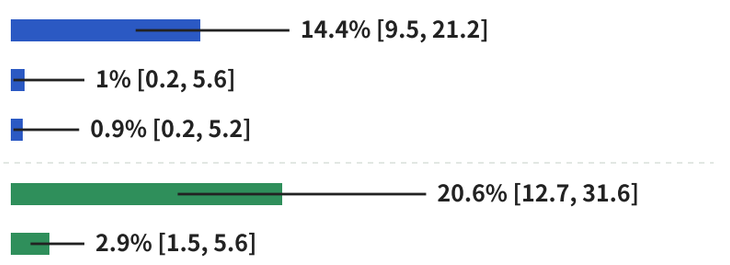
Gitea 3,586 题，Oscar 1,147 题；指令模板 Click the <role> "<text>"。指令改写为自然任务后，比例仍为 14.3%（Gitea）与 34.8%（Oscar），框准确率下降 10–16 点。

03 · 这种偏差有多大：与“一点之差”放在同一把尺上（§6，ScreenSpot-v2）

单位：准确率点（ScreenSpot-v2，7–8B 及 3B 模型）。各行统计含义不同，只比较量级，不能相加。



Web 截图上更常见，越强的模型越常见 Tab.4、Fig.4



360 个被拒点击单元，隐藏模型名盲审；两位独立评审在 60 单元上 κ=0.95。按审计估计的校正后，GTA1-7B 与 UI-Venus-1.5-8B 的差距由 2.9 缩到 1.7 点；有 3 对模型的点估计顺序反转，但区间都含 0，**新顺序同样未定**。

作者给的两条评测做法 §6–7

① **噪声用重复控制：**同一配方跑多个种子，并对两个模型在同一测试集上做配对区间。29 篇论文中没有一篇报告 ScreenSpot-v2 的运行间波动；38 次“领先”里有 21 次不超过单种子效应 1.42 点。

② **偏差只能改规则：**Web 题目给出等价元素清单，或直接执行判卷，把“同一结果”的点击记为正确。移动/桌面原生控件多为单一点击区，框规则在那里基本够用。

放进训练奖励：没有稳定收益 §5、Tab.5

Qwen2.5-VL-3B + LoRA GRPO，三种奖励只差奖励定义，各 3 个种子；评测为 Gitea 留出版式（执行）、Oscar（执行）、ScreenSpot-v2 与 Mind2Web（框）。

	Gitea 留出	Oscar	SSv2	Mind2Web
框奖励（均值）	85.2	89.6	80.5	86.5
结果奖励 − 框奖励	**−0.18**	**+0.06**	**−0.08**	**+0.23**

单种子时 SSv2 上 seed 42 显著赢（p=0.03）、seed 44 显著输（p=0.02），不可复现

评测侧的对应现象：Gitea 上 193 个“指令文字对应多个同结果元素”的题，三模型框准确率只有 **28.5–35.2%**，结果准确率 **90.7–100%**；文字唯一的 3,092 题上两种分数相差不到框中心自身的漂移。

训练侧：同版式重复项上，所有训练模型都已 100% 达成目标结果（只有 27–29% 点中被标注那一份），所以奖励里多给的分几乎没有可改进的余地。作者也说明这是本规模下的上限，不是“永远无用”。

限制（画报口径以此为界）

- **执行判卷只在两个自托管 Web 应用上**（对应 WebArena 的 GitLab 与购物站）；移动/桌面截图只做了人工审计，等价点击约 1%
- 结果指纹靠拦截请求得到：表单提交后服务器端的真实效果没有执行检验，1.5 s 等待也排除不了更慢的延迟效应
- 自检 30 个不一致目标中 2 个是假阳性（共享确认框被合并、搜索框已聚焦）
- ScreenSpot-v2 校正来自 360 单元抽样；改变的只是“分差在一点以内的模型”的顺序，粗排名不变
- 训练实验只有 3B、约 400 次更新；更大模型或更长训练未测

我们的阅读：这篇改变的是“grounding 正确”的定义与比较精度，不是某个模型更强。