暂停式评测替模型等待：同一批小游戏不再等它，通过率 75% → 9%

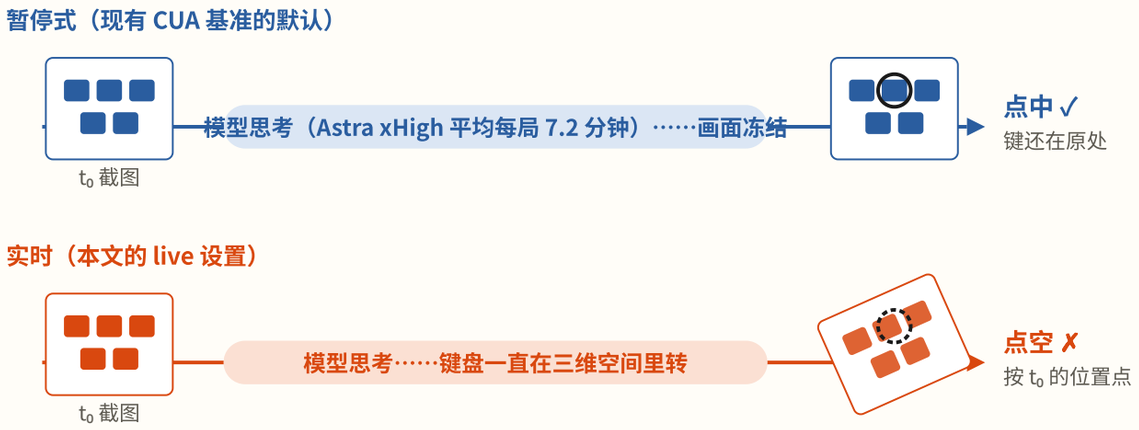
计算机使用基准在两步之间都“等”代理思考。作者造了 100 个必须边看边动的网页小游戏（截图 + 键鼠），同一游戏、同一种子、同一判分器只改时钟：最强的 GPT-6 Astra（xHigh）**暂停时 75%**，**实时 9%**，环境放慢 64 倍也只到 57%。同任务对照把“太慢”从“不会做”里分了出来；每个配置只跑一次。



同一游戏 · 同一种子 · 只换时钟（示意）

01 问题：观察与动作之间，世界在动

§1；§2；图 3

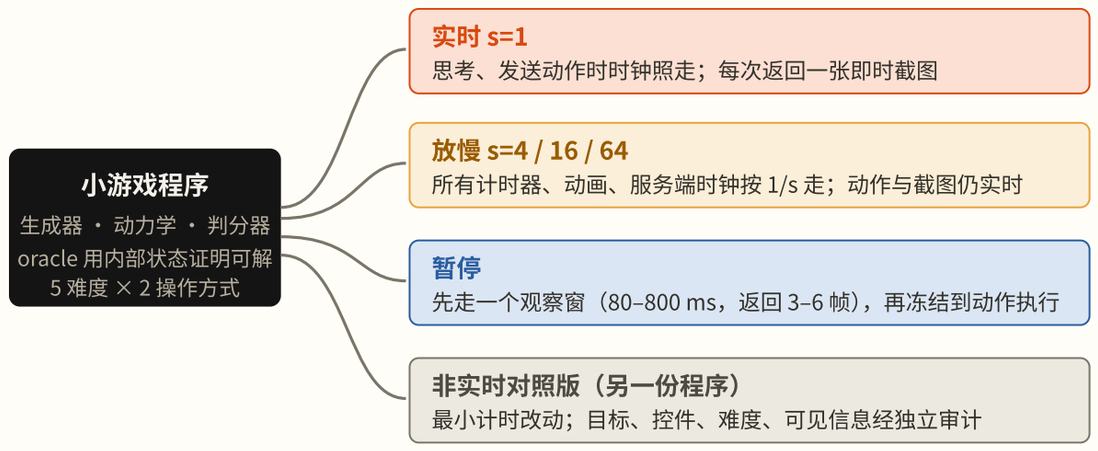


示意，按原文“旋转屏幕键盘”（图 3）的机制重画；数字 7.2 分钟为表 3 的每局平均用时，不是每一步。

现有 CUA 基准（OSWorld 等）在两步之间等代理，**从不测“状态在变时行动”**；游戏基准是实时的，但一个游戏同时考 3D、时序、陌生操作，分不清是慢还是不会（§1）。

02 研究动作：一个程序，四种时钟

§2.2–2.5；附录 B、E、F

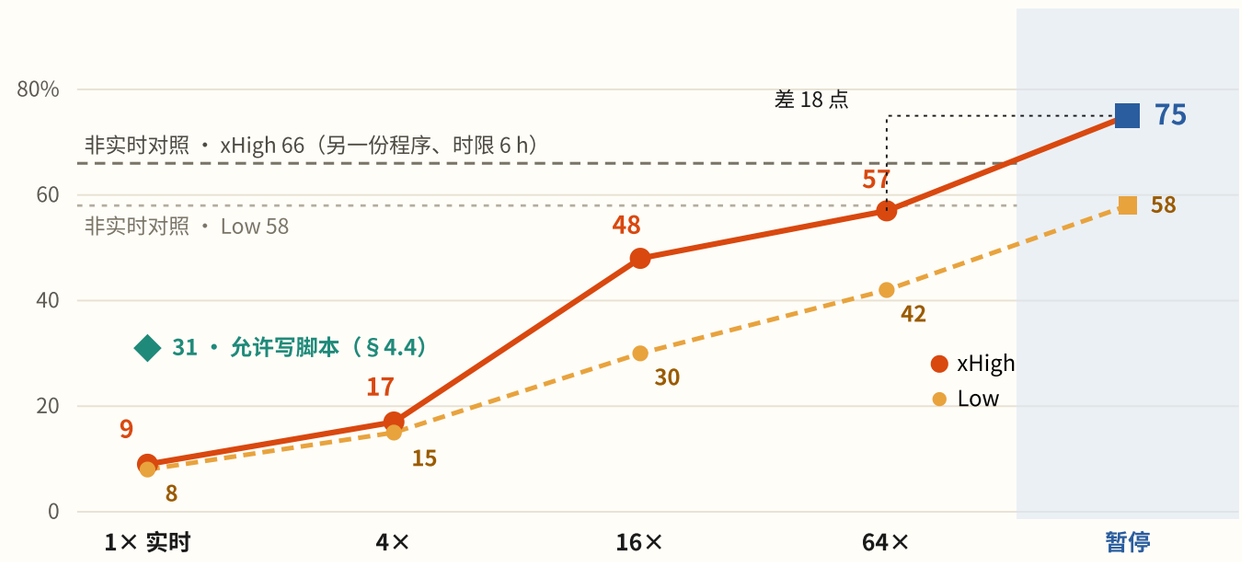


100 个实时小游戏 + 100 个对照 × 5 难度 × 2 操作方式 = **2,000 个配置**（表 1）。动作→截图中位延迟 <50 ms（附录 E.1）。**造题、审计、难度与能力标注全部由 GPT-6 Astra 完成**（§2、附录 B），它也是被测最强模型。

03 结果：同一批题，只给更多时间，通过率一路上升

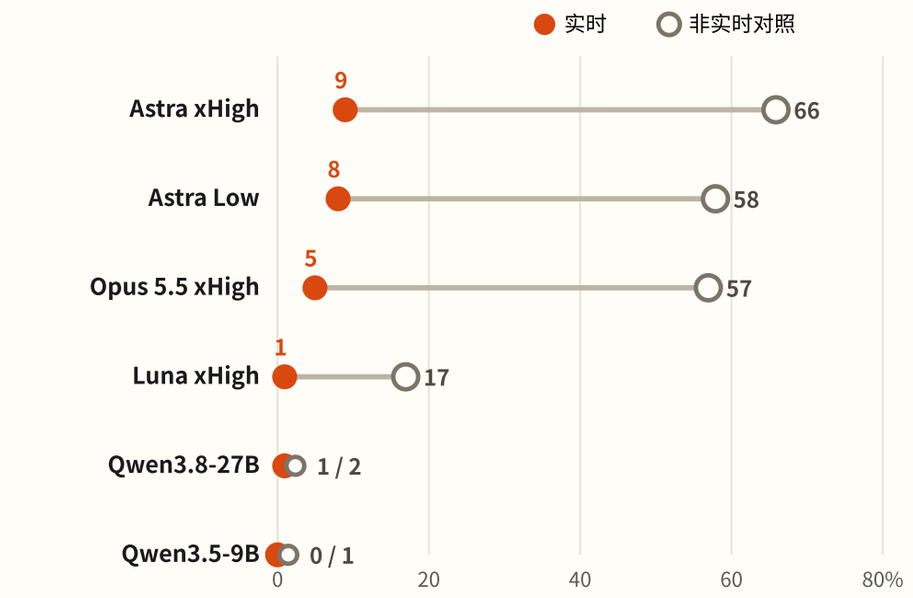
图 4、图 5；§4.2–4.3；难度 5、完整操作

GPT-6 Astra 在 100 个实时游戏上的通过率 图 5 · 每点 = 100 题各一次



实时下 Low 8 与 xHigh 9 几乎相同——多想要多花时间；环境越慢，xHigh 越拉开（64× 时 57 vs 42）。**暂停 75 高于非实时对照 66**：两者不是同一控制（对照是改过计时的另一份程序，暂停还多给 3–6 帧）。

六个模型：实时 vs 非实时对照 图 4 · 每题一次



前沿模型的失败主要来自“实时”这一条件；两个开源模型连对照都只有 1–2%，失败不专属于实时（§4.2）。

04 把“实时那部分”交给代码，补回一截

表 2、表 3；附录 F.5、G

模型	实时 · 不写代码	实时 · 写代码	对照 · 不写	对照 · 写
Astra xHigh	9	31	66	74
Astra Low	8	14	58	63
Luna xHigh	1	5	17	18

动作空间不变，只是可以在沙箱里跑程序、经同一 HTTP 接口截图和发键鼠。Astra 写模板匹配脚本找转动的键、200 ms 内点下；用齿轮标记的角速度预测松离合时机（附录 G）。仍远低于暂停 75。

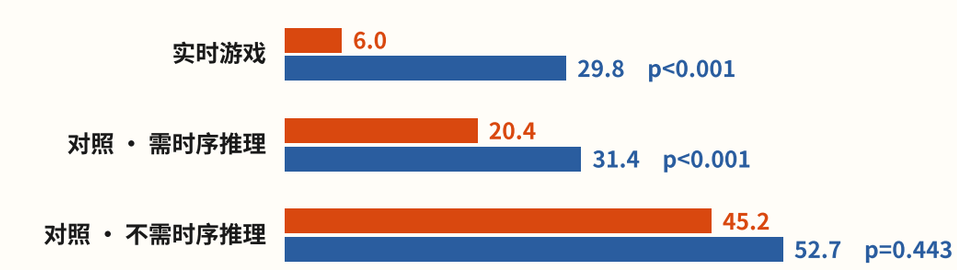
实时、难度 5（表 3）	通过	平均用时	平均花费
Astra xHigh / Low	9 / 8	7.2 / 4.3 分	$4.50 / $2.76
Opus 5.5 xHigh	5	15.8 分	$6.40
Luna xHigh	1	6.4 分	$0.07
人类（一位作者，随机 20 题）	45	2.2 分	—

多花钱不等于多做对：Opus 5.5 每局最贵、最慢，通过 5；Luna 最便宜，通过 1。脚本也会失败——倾斜球盘里 Astra 估计了球速、按航点移动，仍未过（附录 G）。人类基线只覆盖 20 题，不能与 100 题直接比。

05 慢不是唯一原因（GPT-6 Luna 诊断）

图 6–8、表 4；§4.6–4.9

暂停带来的提升 五个难度平均 · 完整操作 · Holm 校正



不需要快速行动的对照题，只要涉及“读懂变化的画面”，暂停也显著有帮助——**时序推理是另一处瓶颈**。给陌生界面附上规则书：11.3 → 16.2（需探索的游戏）。

Luna xHigh · 实时 · 完整操作（表 4）	难度 1	2	3	4	5	全部
实时游戏	15.0	6.0	4.0	4.0	1.0	6.0
非实时对照	35.0	33.0	22.0	18.0	17.0	25.0
差距	**20.0**	**27.0**	**18.0**	**14.0**	**16.0**	**19.0**

最容易的一级，实时也比对照低 20 点：慢在每个难度都是主要失败来源；难度级别让较弱模型也有可测进步空间。

限制（写在读之前）

- **每个配置只跑一次**，通过率是 100 题中的个数；Low 8 vs xHigh 9 分不开，主差距（9 vs 66/75）远大于抽样波动。
- **暂停不只是“多给时间”**：每次观察返回 3–6 帧，实时只有一帧（附录 E）；对照版是另一份程序。“速度是主瓶颈”的最干净证据是放慢曲线 9→57。
- **时限不对称**：Astra xHigh 在实时 1×/4×/16× 与暂停设 1 小时上限，其余 6 小时（附录 F.3）。
- **造题与审计全由 GPT-6 Astra**，同时它是最强被测模型；人类基线只有一位作者、20 题。
- 对象是自建网页小游戏，不是完整游戏、真实应用或物理设备；作者也说迁移未知（附录 A）。

怎么读

- **改变的是评测这一环**：在“环境会自己变”的界面上，暂停式结果会把慢当成会。读 CUA 成绩时先看时钟是否暂停（我们的阅读判断）。
- 同卡相关：第七期 2610.39282（页面加载导致点击过期）讲“截图过期”的另一来源；第十二期备注 Game-TARS 未见游戏是暂停时钟下的结果。
- 可复用的方法：同任务改时钟 + 最小改动对照 + oracle 可解性，把一个能力从混合任务里剥出来。