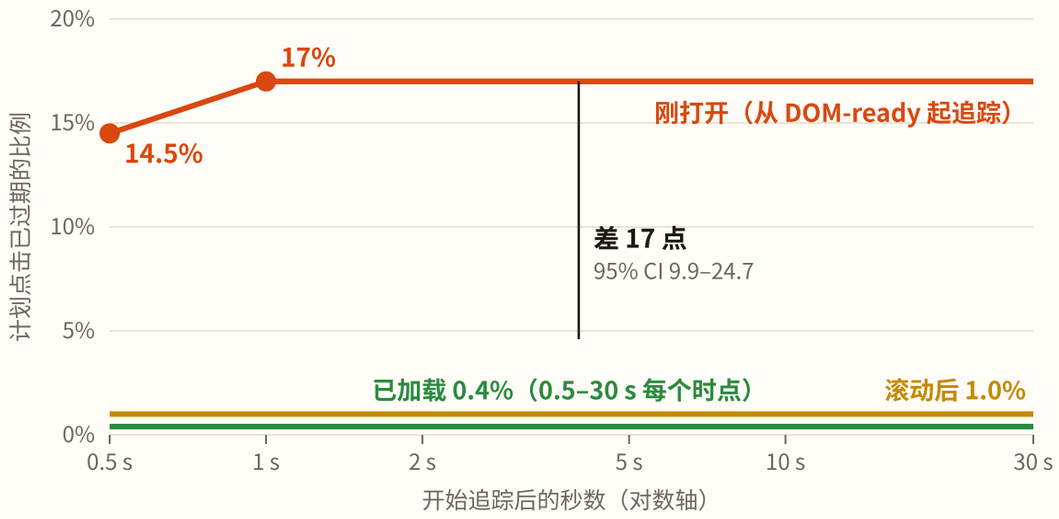
点击落空，多半不是因为模型想得慢，而是页面还在加载：已加载页面上 30 秒内只有 0.4% 的点击过期，刚打开的第一秒是 17%

截图式代理先截图、规划几秒、再按坐标点击；这期间页面一变，点击就落到别的元素上。先前工作把风险归给**规划耗时**，于是主张缩短规划或每步都做检查。作者在 **31 个公开网页**上逐个追踪约 1,300 个计划点击（三种起始状态 × 三轮），复刻 **10 个开源代理**的导航后等待规则，用 HTTP Archive 爬取记录估计商业首页，再在 6 个按设计会移动的合成页面上比较像素检查与 VLM。14 条假设全部预注册，**6 条成立、8 条被推翻**，全部报告。

01 过期集中在打开后的第一秒　RQ1 · 31 个公开页面



已加载页面在 0.5–30 秒的每个时点都是 0.4%，并**不随时间增加**；滚动后 1.0%。刚打开（DOM-ready）时 0.5 秒内 14.5%、1 秒内 17%，之后不再上升。两者差 **17 个点（95% CI 9.9–24.7）**，按页面类型从 5 点（仪表盘）到 38 点（参考站）。

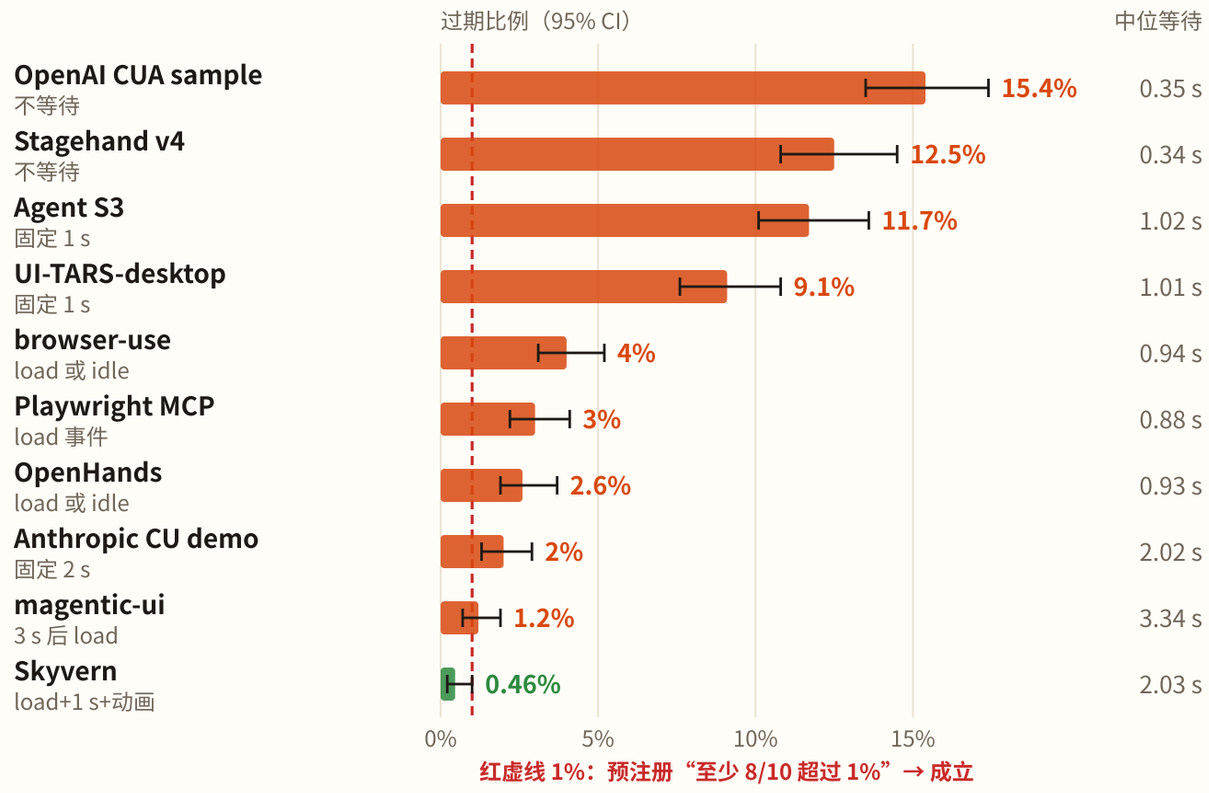
截图前的等待规则 → 过期比例（DOM-ready 起计时）

不等待 14.4%	0.5 s 2.5%	load 事件 3.0%	布局稳定 0.5 s 2.8%	元素框稳定 1.8%	1 s 3.1%

network idle 0.46%（中位 1.24 s）

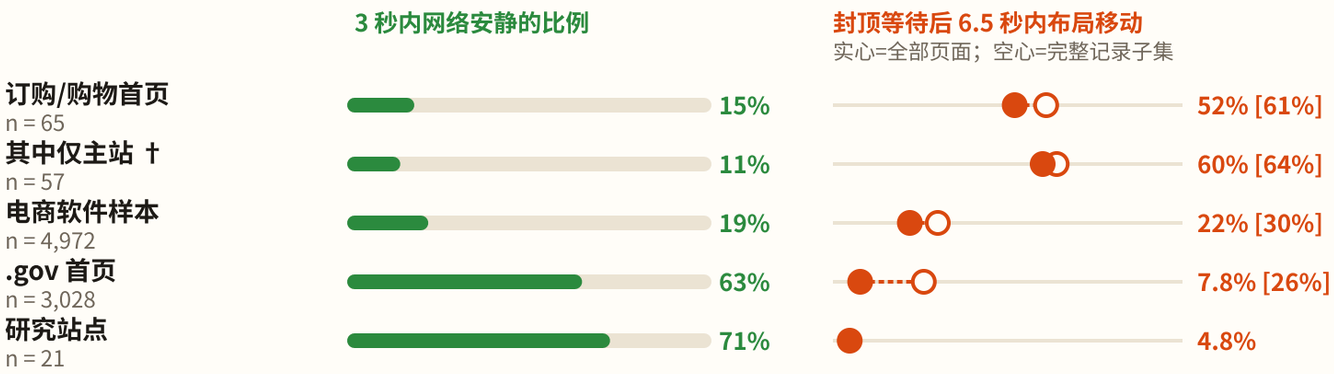
§5.1 正文与 Fig.2 左、Tab.1 左；只画原文写出的数值点，连线为重绘　重绘

02 多数代理等得不够　导航后截图前的等待规则 · 6.5 秒内过期



Tab.1 右：按各代理 2026-10 代码默认设置在作者的 harness 中复刻等待规则，**代理本身没有运行**。两个固定 1 秒的代理从服务器首次响应开始计时，7% 的截图拍在 HTML 解析之前

03 商业首页加载得更久　HTTP Archive 2026-10 桌面爬取 · 未访问任何商业网站



在 network idle 等待封顶 3 秒后，65 个订购/购物首页中 **52%** 在 6.5 秒内发生布局移动，.gov 为 7.8%（差 44.5 点，CI 32.4–56.9）。只看完整记录的页面仍是 61% 对 26%。但**移动端差距消失**（27% 对 28%），而且在研究站点上爬取的布局移动**跟不上实测过期率**（Spearman ρ=−0.12，预注册检验被推翻），所以商业页面的真实过期率仍未测出。

§5.1 “Commercial pages keep loading”、Tab.2、Fig.3；方括号为完整记录子集；† 事后分析，去掉 8 个子域名页面

05 检查何时值得做　§3 公式 1 · §5.3

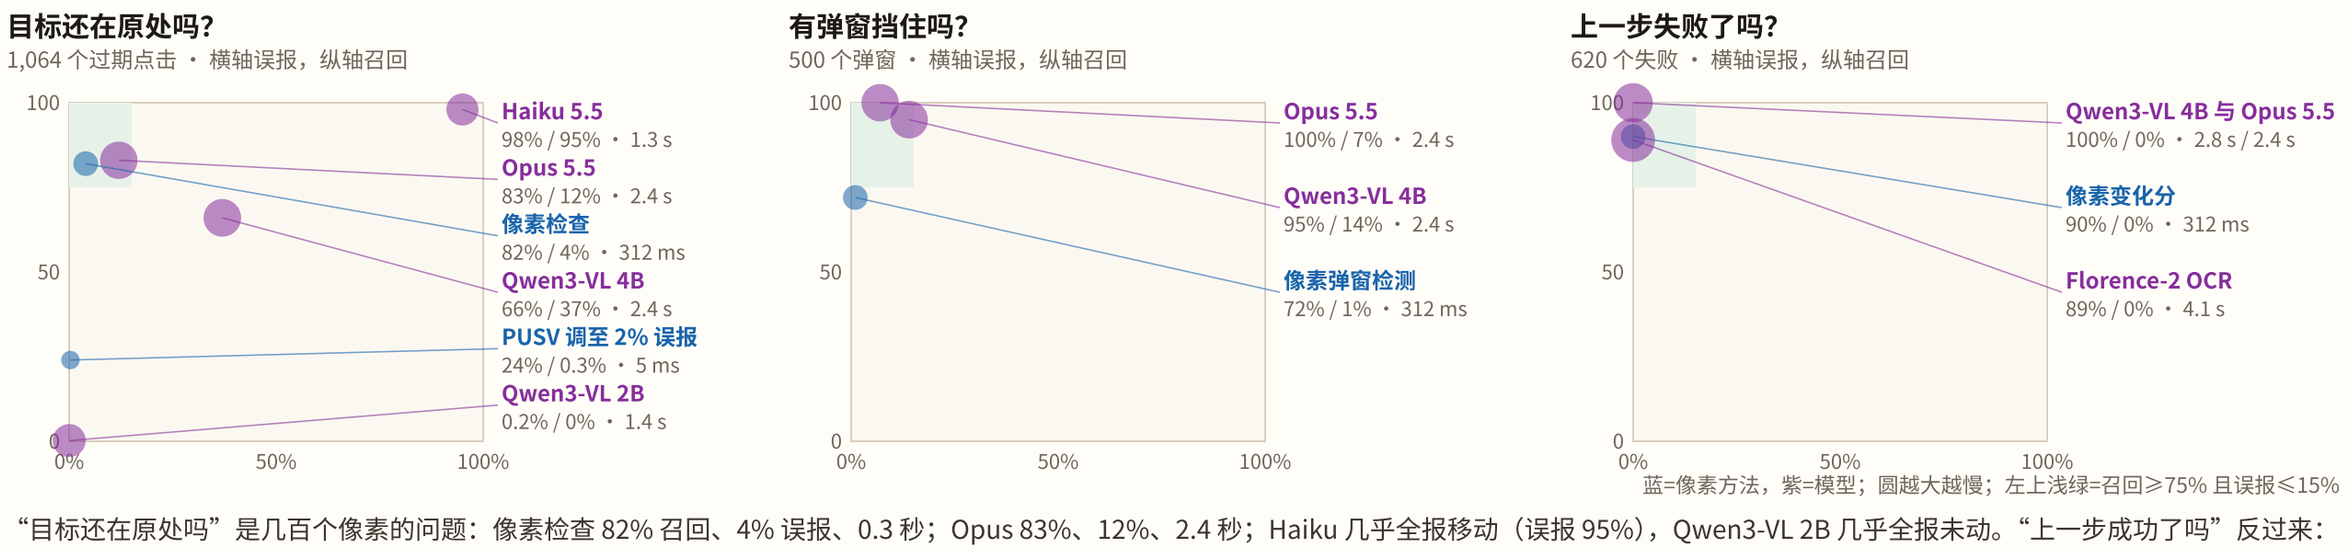
$$p > p^* = (\delta/C + f) \,/\, (r(k-1) + f)$$

p 目标在点击前变化的概率；C 规划耗时；δ、r、f 检查的耗时、召回、误报；k 一次过期点击的代价（普通点击 k=2，付款、删除更高）

≈10%	1.2%	>50%
像素检查对普通点击回本的过期率（C=6.5 s）	不可逆点击（k=10）时的回本点	Opus 当检查器，过期率到 50% 仍不回本

用调参布局的数值代入，**检查/跳过**决定与留出回放一致 94.7%（3,000 例，错误 148/158 偏向检查）；但精确回本点只有 70% 落在 ±0.03 内，**低于预注册的 80%**。

04 像素回答“在哪”，模型回答“发生了什么”　RQ2 · 6 个合成移动页面的留出布局 · 阈值在看测试标签前冻结



“目标还在原处吗”是几百个像素的问题：像素检查 82% 召回、4% 误报、0.3 秒；Opus 83%、12%、2.4 秒；Haiku 几乎全报移动（误报 95%），Qwen3-VL 2B 几乎全报未动。“上一步成功了吗”反过来：Qwen3-VL 4B 与 Opus 都是 100% 召回、0 误报——作者自己指出这组失败样本**偏容易**。检查触发后**别去调整原点击**：像素重定位最好仍有 11% 点错，让 Haiku 重找元素 34% 点错且和重新规划一样慢；多数触发其实是目标已被移除或遮挡（像素法认出 260/267）。

§2、§5.2 Tab.3、§5.3 “Responding to a failed check”；小模型在平衡子集上评估，托管模型跑全部样本

06 作者给开发者的三条规则　§6

1. **截图前等网络安静**，封顶约 3 秒。公开页面上每页约多等 1 秒，去掉大部分过期；订购/购物首页 85% 到封顶仍未安静，保护更多落在规则 2。
2. **检查要对准问题**。已加载页面上的普通点击不必检查（0.4% 不回本）；不可逆点击前做 0.3 秒像素检查；提交后的结果用小模型或 OCR 核对，前沿模型没有增益。
3. **检查触发就从新截图重新规划**，不要修补原来的点击。

实时回路（Haiku 规划，移动页面各 400 步）：像素检查把过期点击从 65–69% 降到 9–11%，触发的重规划 581/606 是必要的；按预注册的 6.5 秒/次计费，每步多花 28–105% 时间，**超过预设的 10% 上限**；按实测 1.1 秒计费则每步省 0.2–0.3 秒。

限制与证据边界

- **真实页面只有 31 个**：公开、非商业、条款允许自动访问；一个浏览器、三天。商业页面只从爬取记录推断**加载与布局移动**，其过期点击率没有测，且爬取信号与实测过期不相关（ρ=−0.12）。
- 只测桌面首页；结账、登录后页面未爬取；遮挡目标但不引起布局移动的变化（研究页面上占过期的 18%）爬取看不到。
- 10 个代理只复刻了导航后的等待规则，没有端到端运行；有的系统在自己的动作后等待更久（如 AOI 2 秒），结论限于页面导航。
- 合成页面约 70% 点击过期，远高于真实页面的 0.4%，只用来压测检查器。动作结果失败集合偏容易；实时回路只有一个规划器，它约 70% 的自身错误来自相似标签，任何点击前检查都抓不到。
- 没有测任务成功率；单作者独立研究，数据与预注册在 preflight-bench 仓库。

我们的阅读：本文把风险来源从“规划耗时”改到“页面加载”，并给出能算的检查回本条件；它没有测任务成功率，也没有证明任何代理改用这些规则后完成率会提高。同期候选 WaitLens（2610.32482）在工业移动测试中用视觉模型判断动作后何时“就绪”，仍有 15.64% 过早返回——等多久、何时检查，都要按页面与平台类型标定。