手机上的 GUI 代理，每一步都在重算同一段提示：按寿命复用、按阶段裁剪

不换模型、不重训：把提示里不变的部分挪到前面复用 KV，按输出阶段换小词表，只对格式与推理文字投机，动作与坐标仍由原模型逐字生成。同模型、同量化、同手机，**推理时间平均快 2.4 倍**，四个设置的任务成功平均 **58.1% → 57.7%**（最多降 0.9 点）。“端到端”指视觉 + 预填充 + 解码的推理时间合计。

模型	MAI-UI-2B · GELab-Zero-4B
量化 / 运行时	INT8 GPTQ · MNN
手机	OnePlus 13 · Find X8 · K50
任务	AndroidWorld 116 · 自建 111
基线	MNN 原模板，同权重同种子

1 问题：每一步都从头算

§1；§2；图 2–3

观察—推理—行动每转一圈，运行时就把**系统指令、工具、输出格式、用户目标、历史**连同新截图重新预填充一遍；输出再对 151,669 个词全表投影。基线（OnePlus 13、MAI-UI-2B）AndroidWorld 每题推理 **85.8 s**，困难题 283 s；自建集“购物”类 833 s（表 1）。导出模型里词嵌入与输出头占 **34.3%** 权重（§4）。

7,000+ 条真实代理轨迹里的输出词（图 3）

出现过 14,162 种 / 词表 151,669（9.3%）

- **209** 种覆盖 80%
- **349** 种覆盖 90%
- **580** 种 95%

3-token 片段 69.1%、4-token 57.6% 在 ≥20 条轨迹中重复出现（图 2）

2 研究动作：沿着一圈循环拆开

§3；算法 1；式 (1)–(5)

输入：按“寿命”重排提示

P_can = 固定 ‖ 半固定 ‖ 动态（区内顺序不变）

固定段 — 离线算好 KV、随包存盘
系统指令 · 工具定义 · 输出格式 — 加载前核对模型 / 模板

半固定段 — 每个任务算一次
用户目标 · 稳定的任务上下文 — 换目标即重建

动态段 — 每步只算这一段
截图视觉 token · OCR · 最近界面状态

无法安全归类的字段一律放动态段；同 token、同位置时恢复 KV 等价于重算

输出：一个格式自动机分阶段解码

结构 → 推理 → 动作 🔒 → 坐标/参数 🔒

可投机阶段
结构：直接提格式字面量
推理：n-gram 表取后缀续写（离线表 + 本任务已验证输出）
原模型一次批量验证，只提交最长匹配前缀

受保护阶段
动作名、坐标、其他参数
一律由原模型逐 token 生成
草稿若跨进这里，只保留之前的安全前缀
错的坐标会点到别的控件

每个阶段只投影一张小词表

完整词表 151,669 行

全局裁剪：保留出现过的 14,162 行 + 格式所需 + 特殊符号 + 256 个字节 token

按自动机状态选该阶段的输出头

宽度为示意，原文未给各阶段词表大小。字节 token 兜底，罕见文本仍可拼出；选中行映射回原 token ID，接口不变。

裁剪本身是近似：可能改变原模型会给出的输出。

步数越多，省得越多 图 6 · 全部评测

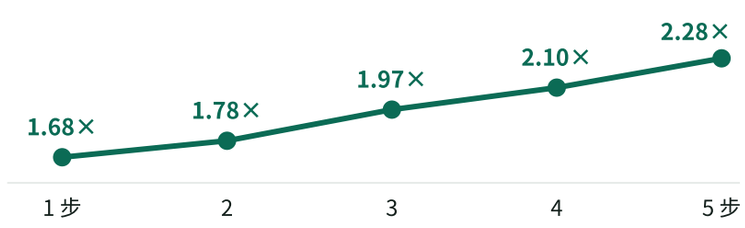

1 步任务 11.47 → 6.83 s，5 步任务 96.53 → 42.39 s（§4）：可复用的前缀和已验证输出随轨迹累积。

3 结果：两个模型 × 两个任务集 × 三台手机，都快 2.1–2.8 倍

每题推理时间（秒）：基线 vs MobiInfer 图 5 标注值 · 倍数为我们复算

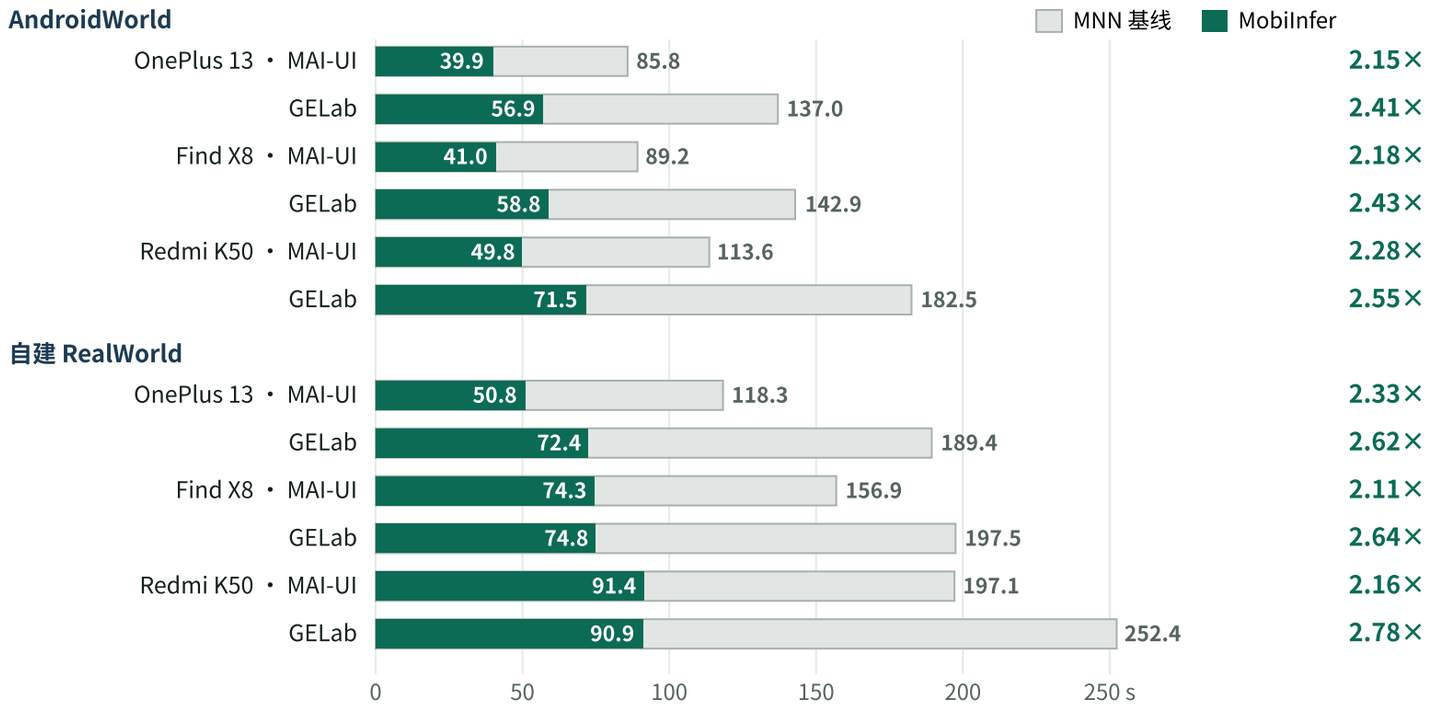

十二组平均 2.39 倍，与原文“平均 2.4×”一致。AndroidWorld 模板化任务里重复结构更多；越长、越难的任务省得越多（表 1：困难题 3.19× / 3.60×，购物类 4.48× / 5.38×）。视觉编码那一段几乎不变（图 5）。

谁贡献了速度 图 7 · OnePlus 13 · 自建集 · 各 3 次

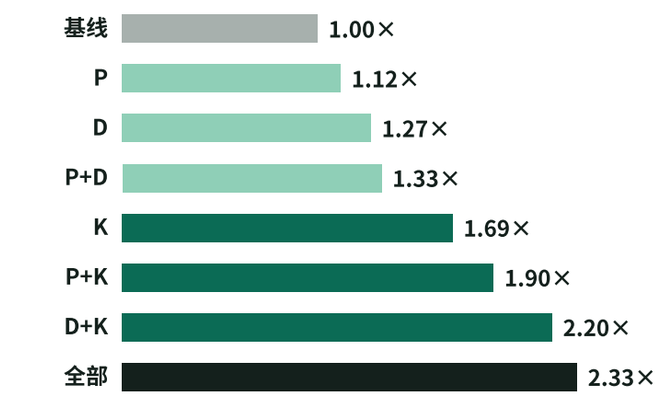

K = 按寿命复用前缀 KV，D = 分阶段投机，P = 分阶段词表。**大头是 K**；P 主要省输出头计算、内存和存储，单独提速只 1.12×。

同一组配置，换别的投机方法 表 3 · MAI-UI-2B · OnePlus 13 · 自建集

方法	推理	解码	成功
MNN 基线	118.3 s	1.00×	42.3%
+ Lookahead	103.4 s	1.23×	41.4%
+ EAGLE-3	126.5 s	1.15×	39.6%
+ 格式引导投机	**93.2 s**	**1.84×**	**41.4%**

Lookahead 从提示里找重复 n-gram；EAGLE-3 用训练过的草稿模型，解码吞吐变高，但草稿与验证开销让手机上的总时间**反而变长**。表中“推理”为每题推理时间，“解码”为解码吞吐倍数。

4 代价：同截图逐步比对，输出约 2% 变了

表 2；图 4；§4

同一截图、同一任务状态、贪心解码 表 2

变体	平均 IoU	IoU≥0.5	动作类型准确	与原输出一致
原提示 + 全词表	0.782	76.4%	91.8%	100.0%
重排提示 + 全词表	0.780	76.1%	91.7%	98.9%
原提示 + 裁剪词表	0.779	75.8%	91.5%	98.5%
重排 + 裁剪（MobiInfer）	**0.777**	**75.5%**	**91.3%**	**98.1%**

57.7 % ← 58.1
四个“模型 × 任务集”平均任务成功；单个设置最多降 0.9 点（图 4）

−31.8 %
峰值内存 PSS（OnePlus 13：3,770 → 2,570 MiB；三台均降约 31%）

3,280 → 2,297 MB（−30.0%）
完整部署体积，已计入 27.5 MB n-gram 表与 108.3 MB 预存 KV（表 4，MAI-UI-2B）

按难度与类别拆开 表 1 · MAI-UI-2B · OnePlus 13 · 每题推理秒数

AndroidWorld	简单	中等	困难	自建集	导航	系统	搜索	购物
基线	49.3	96.2	283.3	基线	21.3	70.1	86.6	832.7
MobiInfer	26.7	43.5	88.7	MobiInfer	12.2	34.4	39.9	185.8
倍数	**1.84×**	**2.21×**	**3.19×**	**倍数**	**1.75×**	**2.04×**	**2.17×**	**4.48×**

长任务收益最大，但加速后购物类每题推理仍约 3 分钟。数值与图 5 的 OnePlus 13 标注一致（我们比对）；原文注明吞吐取三次重复平均。

限制（写在读之前）

- **“端到端”是推理时间**：表 1 的“E2E latency”与图 5、图 7 的视觉 + 预填充 + 解码堆叠值相同（如 118.3 s），不含动作执行与等页面；表 1 数值对应 OnePlus 13。
- **不是原策略的精确加速**：提示重排与词表裁剪都是近似，同截图下约 1.9% 的输出与原输出不同；投机只对“裁剪后的策略”无损。
- **词表与 n-gram 表来自 7,000+ 条采集轨迹**，它们与 AndroidWorld / 自建测试任务是否分开，正文没有说明；分设置成功率与任务清单放在补充材料，arXiv 版未附。
- 成功率差小于误差线，“<1 点”不是统计非劣检验；只测了 2B / 4B 两个 INT8 模型、三台手机。

怎么读

- **改变的是循环的“推理成本”这一环**：动作接口和模型都不变，靠代理工作负载的结构（不变的前缀、可预测的格式）省时间——我们的阅读判断。
- 加速后困难题每题推理仍约 89–127 s；手机端代理离“可交互”还有距离。
- 同卡对照：agent_loop_context_control 此前关注“该留哪些历史”，本篇关注“留下的历史别重复算”。