代理看手机用的是读屏器那棵树：AndroidControl 里 42.7% 该写描述的元素没有 content-desc，被示范点中的图标却多 9 点有描述

content-desc = ø

Kraishan、Jitkajornwanich（Texas Tech）逐个编码 **17,373,614** 个界面元素：Rico（2017 爬取）与 AndroidControl（2024，解析 20 个分片中的 10 个）。问的是训练与评测数据里“目标叫什么”这一栏有多空，以及示范轨迹是否专挑好认的目标。**两语料之差不是七年进步**：选 app、采集方式、系统版本都不同。

01 一个元素什么时候算“欠债”

§IV-A–C · 图 1（重绘）

1. 纳入：标为可见**且**面积 > 0（Rico 48.7% 节点面积 ⩽ 0）
2. 有 content-desc → labelled
3. 容器、WebView 豁免；自己显示文字 → named_by_text
4. 无文字的**图片或可交互**元素没有描述 → unlabelled = 欠债
5. 其余 → not_applicable；覆盖率分母只算“需要描述”的元素

icon-like：可点、无文字的 image / button——缺描述几乎必是缺陷，全文所有主结论都在这一层重算一遍。

κ .96 / .91	11 / 20	.96 / .95
两名作者盲编 300 元素：角色 / 标签状态	标签状态分歧落在“装饰 vs 未标注”边界	自动编码与两人标签状态的 κ

示意 左图为自绘界面：绿框 = 有描述，橙虚线 = 欠债；不是论文截图。

02 “需要描述”的元素里有描述的比例

§V-A–B · 表 I

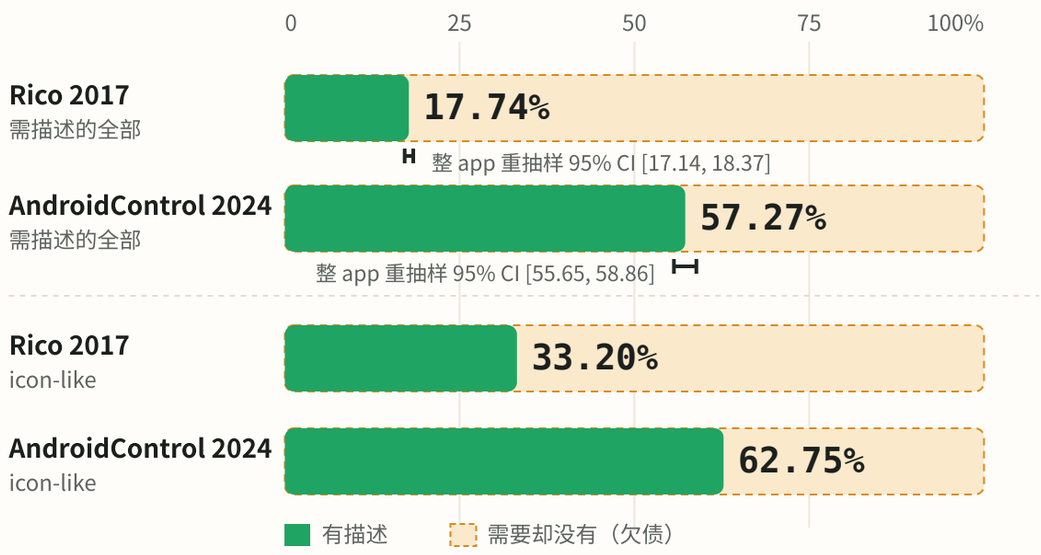

Rico 需描述 502,585 个、有 89,146；AndroidControl 需 1,462,544 个、有 837,536。差 **39.53 点**（整 app 重抽样 [37.81, 41.21]）。作者自己写明：AndroidControl 的 833 个 app 是为示范挑的，**“这只是两个数据集之差，不测量随时间的变化”**。

03 按角色：最需要名字的输入框最没有

§V-A · 表 II

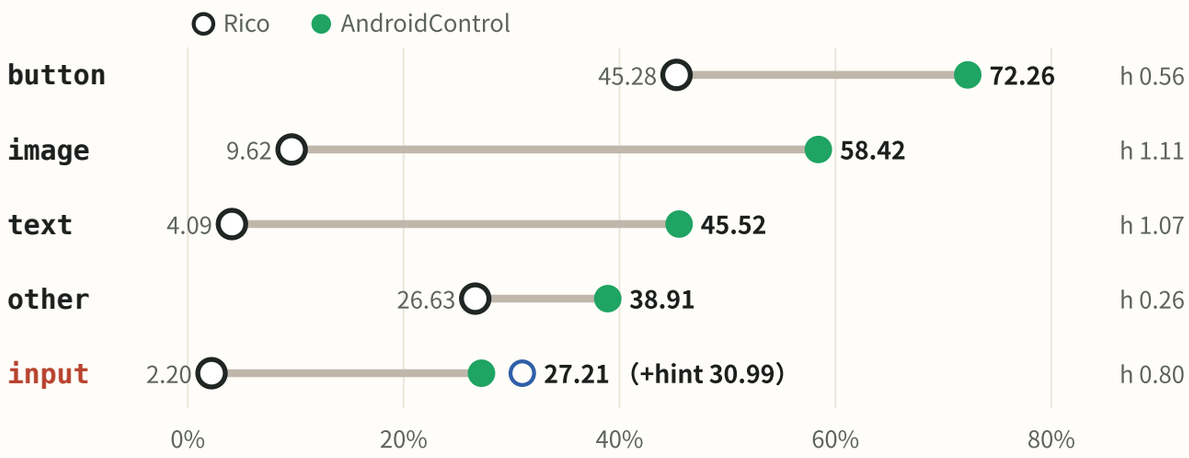

输入框的另一个发声来源是 hint：AndroidControl 记 hint 后输入框覆盖 27.21 → **30.99%**，仍最低（Rico 不记录 hint）。旧语料的描述也更空：“image”“button”、资源 ID、单字符这类占位串占 Rico 描述的 **10.25%**，AndroidControl **1.95%**。

04 换五种编码规则，差距不翻转

§V-E · 表 VI

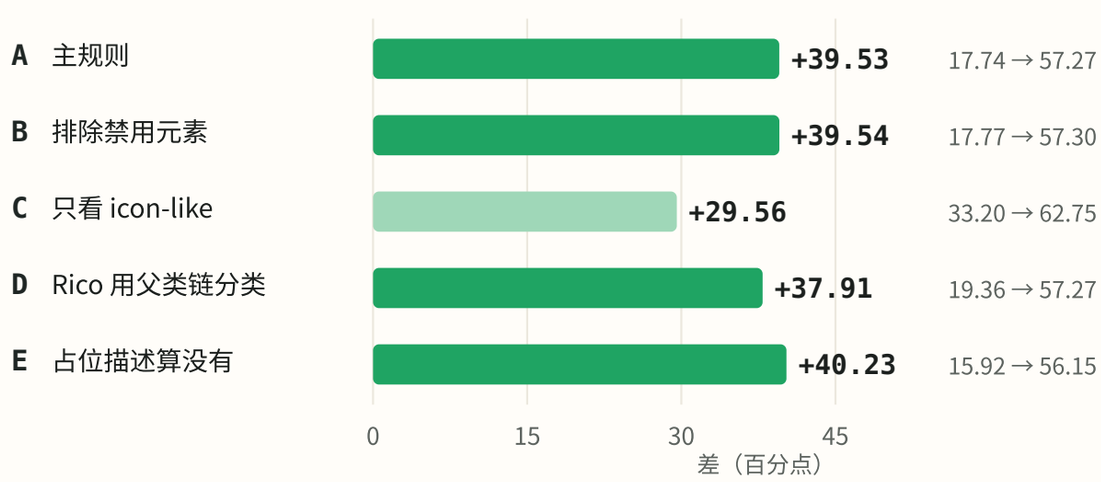

D 回应“Rico 只是因分类器少看了元数据”：用父类链重分 Rico 的 320,059 个元素，差距只缩 1.6 点（约 4%）。E 把占位描述算作没有，差距反而**扩大**。最窄的是最严格的 icon-like（C）。

05 示范点中的元素 vs 同一屏上的其余元素

§V-C · 表 III

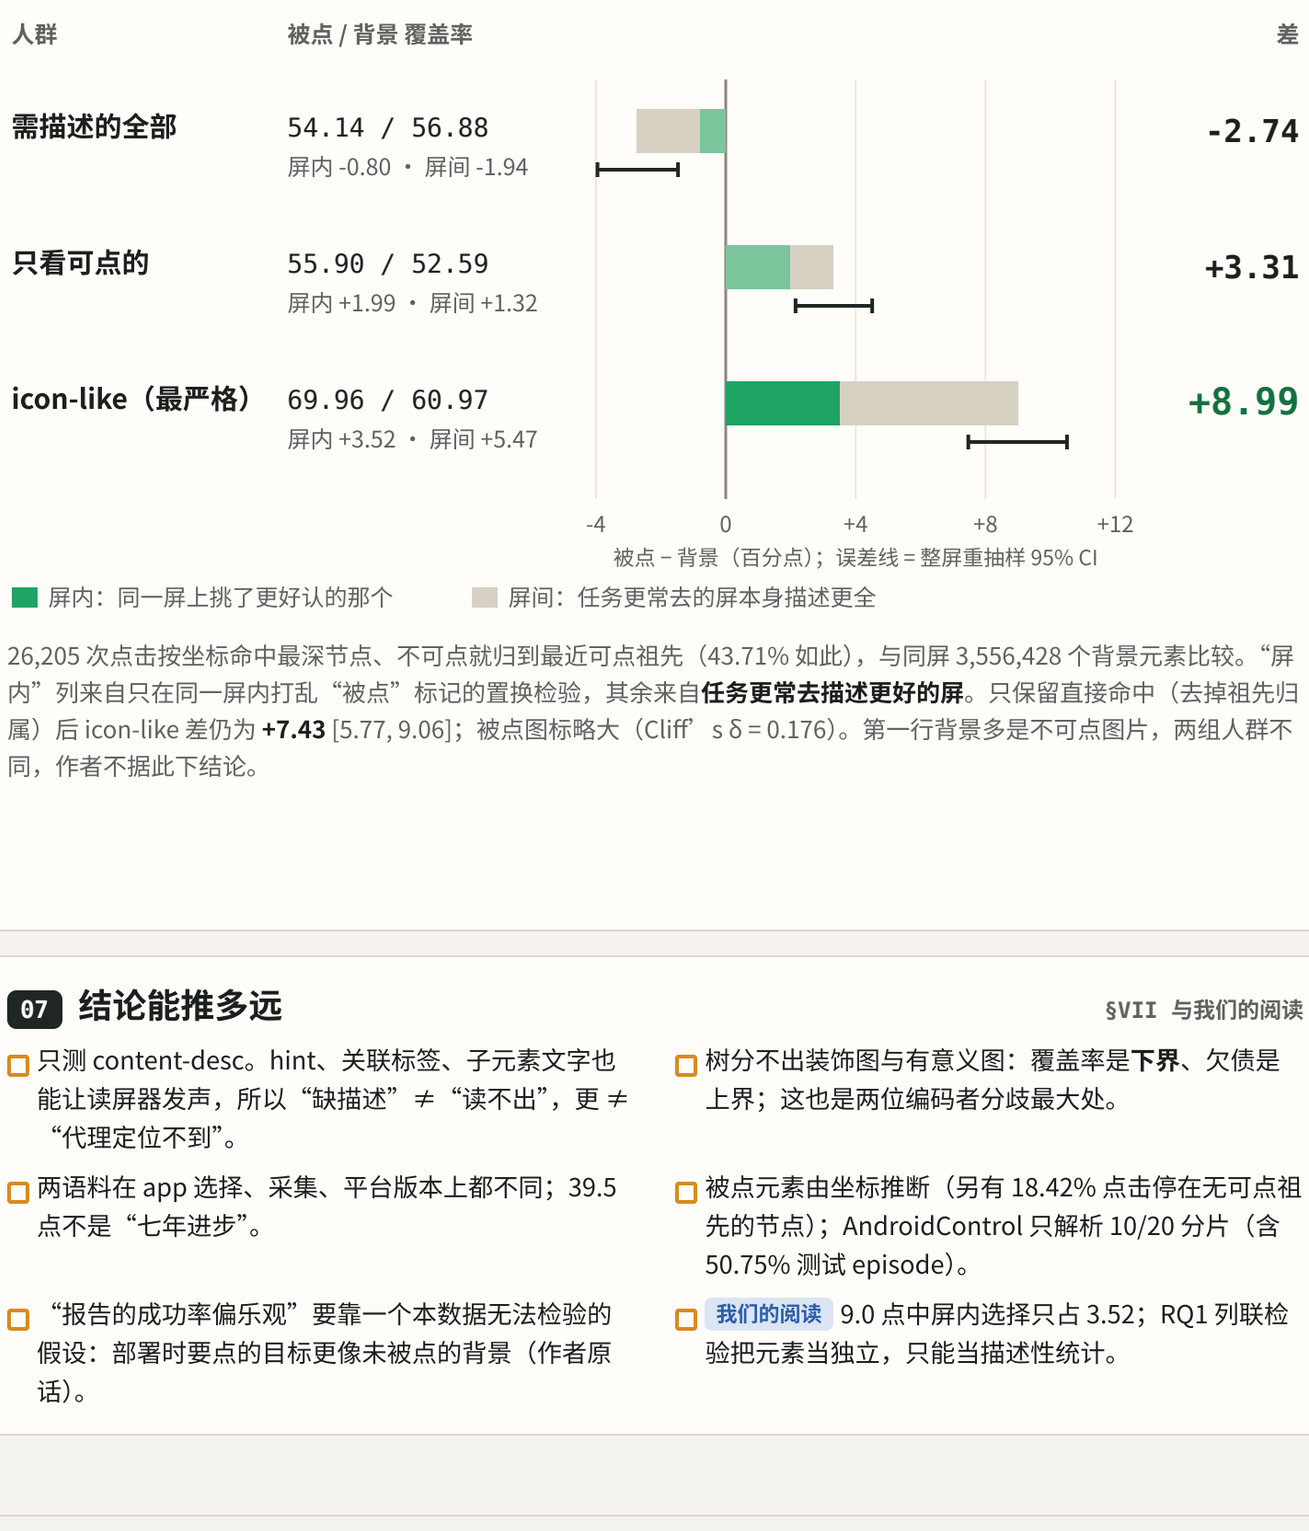

26,205 次点击按坐标命中最深节点、不可点就归到最近可点祖先（43.71% 如此），与同屏 3,556,428 个背景元素比较。“屏内”列来自只在同一屏内打乱“被点”标记的置换检验，其余来自**任务更常去描述更好的屏**。只保留直接命中（去掉祖先归属）后 icon-like 差仍为 **+7.43** [5.77, 9.06]；被点图标略大（Cliff’s δ = 0.176）。第一行背景多是不可点图片，两组人群不同，作者不据此下结论。

06 描述多少与示范长短：控制好暴露就没关系

§V-D · 表 IV–V

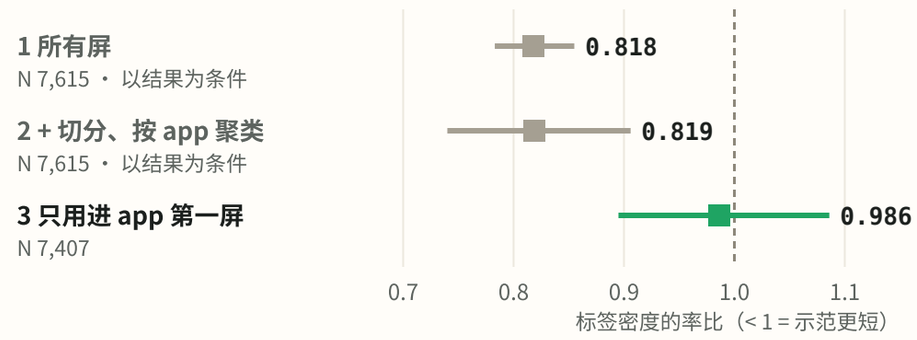

模型 1–2 的元素数是对所访各屏求和，随步数一起涨（与 log 步数 r = 0.80），等于以结果为条件；模型 3 只取进入 app 后第一屏的密度与元素数（7,407 个 episode），率比 0.986，p = .78。四个泛化切分的覆盖率 54.78–56.26%，几乎持平（V = 0.013）。

AndroidControl 测试切分	episode	覆盖率	平均步数
同分布	364	55.17%	5.37
未见类别	349	56.20%	5.77
未见 app	318	54.78%	5.74
未见任务	401	56.26%	5.72

切分有重叠：1,432 个成员身份来自 780 个不同 episode（表 V）。未见 app 更难，不是因为它的屏描述更少。

注意：结果变量是**人类示范的步数**，AndroidControl 没有代理 rollout——本文没有测代理成功率。

07 结论能推多远

§VII 与我们的阅读

- ☐ 只测 content-desc。hint、关联标签、子元素文字也能让读屏器发声，所以“缺描述” ≠ “读不出”，更 ≠ “代理定位不到”。
- ☐ 两语料在 app 选择、采集、平台版本上都不同；39.5 点不是“七年进步”。
- ☐ “报告的成功率偏乐观”要靠一个本数据无法检验的假设：部署时要点的目标更像未被点的背景（作者原话）。
- ☐ 树分不出装饰图与有意义图：覆盖率是**下界**、欠债是上界；这也是两位编码者分歧最大处。
- ☐ 被点元素由坐标推断（另有 18.42% 点击停在无可点祖先的节点）；AndroidControl 只解析 10/20 分片（含 50.75% 测试 episode）。
- ☐ 我们的阅读 9.0 点中屏内选择只占 3.52；RQ1 列联检验把元素当独立，只能当描述性统计。

08 拿来怎么用

§VI（作者建议，未实验）

做语料的：数据卡里报告覆盖率——总体、分角色、icon-like 三层；作者已开源编码手册与流水线。

做基准的：按“目标有无描述”分层报告成功率；只在有描述目标上成功的代理和两类都成功的代理是两种系统。

做代理的：只读树的系统继承这块盲区，像素侧语义恢复应作为树的补充。